Vzorcovník – 4ST204 (Python)

1 Statistická teorie

Míry úrovně a polohy

- **Aritmetický průměr:** $\bar{x} = \frac{\sum x_i}{n}$. Klasický průměr pro data bez extrémních hodnot.
- **Geometrický průměr:** $\bar{x}_G = \sqrt[n]{\prod x_i}$. Pro multiplikativní data (tempa růstu, úroky).
- **Harmonický průměr:** $\bar{x}_h = \frac{n}{\sum \frac{1}{x_i}}$. Používá se pro poměrové veličiny (např. rychlost v km/h), kde je konstantní čitatel (např. ujetá vzdálenost).
- **Modus ($\hat{x}$):** Nejpravděpodobnější (nejčetnější) hodnota.
- **Kvartily:** Dolní Q_1 (25 %), Medián Q_2 (50 %) a Horní Q_3 (75 %).
- **Sturgesovo pravidlo:** $k = 1 + \log_2 n$ (doporučený počet intervalů).

Kvantily (Pozice a výpočet)

Pozice p-tého kvantilu: $z_p = n \cdot p$. Hodnota $\tilde{x}_p$ se určí z uspořádaného souboru $x_{(1)} \leq \cdots \leq x_{(n)}$:

$$\tilde{x}_p = \begin{cases} x_{(\lceil z_p \rceil)} & \text{pokud } z_p \notin \mathbb{Z} \\ \frac{x_{(z_p)} + x_{(z_p+1)}}{2} & \text{pokud } z_p \in \mathbb{Z} \end{cases}$$

L^p Normy (Vzdálenosti a penalizace)

Obecně: $\|x\|_p = \left(\sum |x_i|^p\right)^{1/p}$. Klíčové pro metriky chyb a regularizaci.

- **L^1 (Manhattan):** $\|x\|_1 = \sum |x_i|$. Využití: **Lasso regrese**.
- **L^2 (Euklid):** $\|x\|_2 = \sqrt{\sum x_i^2}$. Využití: **Ridge regrese** (metoda nejmenších čtverců).
- **L^∞ (Max):** $\|x\|_\infty = \max(|x_i|)$. Reprezentuje nejhorší možnou chybu.

2 Práce s poli (Standardní Python)

Funkce / Operace	Příklad použití	Vysvětlení
List Comprehension	`[x**2 for x in range(5)]`	Dynamické generování pole pomocí cyklu.
`x[start:stop:krok]`	`pole[1:10:2]`	Výřez (stop je exkluzivní). `[::-1]` pro otočení.
`x.copy()` vs `deepcopy`	`a = b.copy()`	`copy` je plytká, `deepcopy` kopíruje i vnořená pole.
`x.append(v)`	`data.append(10)`	Přidání jednoho prvku na konec pole.
`x.extend(a)`	`data.extend([1,2,3])`	Přidání více prvků na konec pole.

3 Základní Python (Built-in & Math)

Funkce / Operace	**Příklad použití**	**Vysvětlení**
`help(funkce)`	`help(print)`	Dokumentace pro zadanou funkci.
`range(start, stop)`	`list(range(0, 5))`	Vygeneruje sekvenci `[0, 1, 2, 3, 4]`.
`math.log(x, b)`	`math.log(8, 2)`	Logaritmus čísla x o základu b.
`math.sqrt(x)`	`math.sqrt(16)`	Druhá odmocnina čísla.
`math.ceil / floor`	`math.ceil(2.1)`	Zaokrouhlení nahoru (3) / dolů (2).
`math.trunc(x)`	`math.trunc(2.9)`	Odříznutí desetinné části (2).
`math.comb(n, k)`	`math.comb(10, 3)`	Kombinační číslo (počet kombinací k prvků z n).

4 Knihovna NumPy (Statistika a Matice)

Funkce / Operace	Příklad použití	Vysvětlení
`np.array([...])`	`np.array([1, 2, 3])`	Vytvoření základního NumPy pole (vektoru nebo matice).
`np.sum(x)`	`np.sum(data, axis=0)`	Součet všech prvků v poli (nebo podél zvolené osy).
`np.mean(x)`	`np.mean(data)`	Průměr všech prvků v poli.
`np.prod(x)`	`np.prod(data)`	Součin všech prvků v poli.
`np.sqrt(x)`	`np.sqrt(data)`	Druhá odmocnina z každého prvku v poli.
`np.random.rand(n)`	`np.random.rand(100)`	Generování pole n náhodných čísel z rovnoměrného rozdělení na $[0, 1)$.
`np.random.uniform(a, b, n)`	`np.random.uniform(10, 50, 100)`	Generuje n náhodných **desetinných** čísel v rozsahu $[a, b)$.
`np.quantile(x, q)`	`np.quantile(x, 0.75)`	Výpočet kvantilu ($q \in [0, 1]$).
`np.log10(x)`	`np.log10(data)`	Dekadický logaritmus (základ 10). Často se používá pro normalizaci dat.
`np.std(x, ddof=1)`	`np.std(data, ddof=1)`	Výběrová směrodatná odchylka (`ddof=1` je nutné pro nestranný odhad).
`np.linalg.norm(x, p)`	`np.linalg.norm(x, ord=2)`	Výpočet L^1, L^2 nebo L^∞ (`np.inf`) normy.
`np.insert / np.delete`	`np.insert(A, 1, [..], axis=0)`	Vloží/Smaže řádek (`axis=0`) nebo sloupec (`axis=1`).
`stats.gmean(x)`	`stats.gmean(x)`	Geometrický průměr (knihovna Scipy).
`Geometrický průměr`	`10**np.mean(np.log10(x))`	Výpočet geometrického průměru pomocí logaritmů.
`stats.hmean(x)`	`stats.hmean(x)`	Harmonický průměr (knihovna Scipy).

5 Knihovna Pandas (Analýza dat)

Funkce / Operace	Příklad použití	Vysvětlení
`df.describe()`	`df.describe()`	Souhrnné statistiky (mean, std, kvartily, atd.).
`df.loc` vs `df.iloc`	`df.loc[0, 'Sloupec']`	Výběr dat podle **názvů** (`loc`) vs. **pozice** (`iloc`).
`df.value_counts()`	`df['A'].value_counts()`	Tabulka četností pro kategorická data.
`df.isna().sum()`	`df.isna().sum()`	Počet chybějících (null) hodnot v tabulce.