Vzorcovník – 4ST204 (Python)

1 Statistická teorie

Míry úrovně a polohy

- **Aritmetický průměr:** $\bar{x} = \frac{\sum x_i}{n}$. Klasický průměr pro data bez extrémních hodnot.
- **Geometrický průměr:** $\bar{x}_G = \sqrt[n]{\prod x_i}$. Pro multiplikativní data (tempa růstu, úroky).
- **Harmonický průměr:** $\bar{x}_h = \frac{n}{\sum \frac{1}{x_i}}$. Používá se pro poměrové veličiny (např. rychlost v km/h), kde je konstantní čitatel (např. ujetá vzdálenost).
- **Modus ($\hat{x}$):** Nejpravděpodobnější (nejčetnější) hodnota.
- **Kvartily:** Dolní Q_1 (25 %), Medián Q_2 (50 %) a Horní Q_3 (75 %).
- **Sturgesovo pravidlo:** $k = 1 + \log_2 n$ (doporučený počet intervalů).

Kvantily (Pozice a výpočet)

Pozice p-tého kvantilu: $z_p = n \cdot p$. Hodnota $\tilde{x}_p$ se určí z uspořádaného souboru $x_{(1)} \leq \cdots \leq x_{(n)}$:

$$\tilde{x}_p = \begin{cases} x_{(\lceil z_p \rceil)} & \text{pokud } z_p \notin \mathbb{Z} \\ \frac{x_{(z_p)} + x_{(z_p+1)}}{2} & \text{pokud } z_p \in \mathbb{Z} \end{cases}$$

L^p Normy (Vzdálenosti a penalizace)

Obecně: $\|x\|_p = \left(\sum |x_i|^p\right)^{1/p}$. Klíčové pro metriky chyb a regularizaci.

- L^1 **(Manhattan):** $\|x\|_1 = \sum |x_i|$. Využití: **Lasso regrese**.
- L^2 **(Euklid):** $\|x\|_2 = \sqrt{\sum x_i^2}$. Využití: **Ridge regrese** (metoda nejmenších čtverců).
- L^∞ **(Max):** $\|x\|_\infty = \max(|x_i|)$. Reprezentuje nejhorší možnou chybu.

Kombinatorika

Mějme množinu n prvků, ze které vybíráme k prvků.

- **Permutace (Pořadí všech n prvků):**
  - Bez opakování: $P(n) = n!$
  - S opakováním: $P'_{k_1,k_2,\ldots,k_m}(n) = \frac{n!}{k_1! \cdot k_2! \cdot \ldots \cdot k_m!}$
- **Variace (Výběr k prvků z n, záleží na pořadí):**
  - Bez opakování: $V(k,n) = \frac{n!}{(n-k)!}$
  - S opakováním: $V'(k,n) = n^k$
- **Kombinace (Výběr k prvků z n, nezáleží na pořadí):**
  - Bez opakování: $K(k,n) = \binom{n}{k} = \frac{n!}{k!(n-k)!}$
  - S opakováním: $K'(k,n) = \binom{n+k-1}{k} = \frac{(n+k-1)!}{k!(n-1)!}$

Míry variability

Variabilita vyjadřuje různorodost hodnot v souboru. Čím více jsou hodnoty vzdálené od průměru, tím je variabilita vyšší.

- **Variační rozpětí (R):** Rozdíl mezi maximální a minimální hodnotou: $R = x_{max} - x_{min}$.
- **„Klasický“ rozptyl (s_x^2):** Průměrná čtvercová odchylka od průměru (používá se pro celou populaci):
$$s_x^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2$$
- **Výběrový rozptyl (S^2):** Používá se pro odhad rozptylu z náhodného výběru (v NumPy `ddof=1`):
$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$
- **Směrodatná odchylka (s_x):** Odmocnina z rozptylu, udává variabilitu v původních jednotkách: $s_x = \sqrt{s_x^2}$.
- **Variační koeficient (v_x):** Relativní míra variability (bezrozměrná), slouží k porovnání souborů s různými průměry: $v_x = \frac{s_x}{\bar{x}}$.

Rozklad rozptylu

Pokud máme data rozdělená do k skupin (např. pobočky firmy), můžeme celkový rozptyl rozložit na dvě složky:
$$s_x^2 = \underbrace{\bar{s}_i^2}_{\text{vnitroskupinový}} + \underbrace{s_{\bar{x}}^2}_{\text{meziskupinový}}$$

- **Vnitroskupinový rozptyl ($\bar{s}_i^2$):** Průměr rozptylů jednotlivých skupin (vyjadřuje kolísání uvnitř skupin):
$$\bar{s}_i^2 = \frac{\sum_{i=1}^{k} s_i^2 n_i}{\sum_{i=1}^{k} n_i}$$
- **Meziskupinový rozptyl ($s_{\bar{x}}^2$):** Rozptyl skupinových průměrů od celkového průměru (vyjadřuje rozdíly mezi skupinami):
$$s_{\bar{x}}^2 = \frac{\sum_{i=1}^{k}(\bar{x}_i - \bar{x})^2 n_i}{\sum_{i=1}^{k} n_i}$$

2 Užitečné knihovny (Importy a přehled)

Funkce / Operace	Příklad použití	Vysvětlení
`import numpy as np`	`np.array([...])`	Základ pro matice, vektory a rychlé matematické operace.
`import pandas as pd`	`pd.DataFrame(matice)`	Nejdůležitější pro analýzu tabulek (DataFrame) a práci s CSV.
`from scipy import stats`	`stats.hmean(data)`	Vědecká statistika: vážené průměry, rozdělení, testy.
`import statistics`	`statistics.multimode(x)`	Vestavěná knihovna pro základní statistiku (i bez NumPy).
`import matplotlib.pyplot as plt`	`plt.hist(data)`	Tvorba grafů, histogramů a vizualizace dat.
`import math`	`math.sqrt(x)`	Základní matematické funkce pro skalární čísla (ne pro pole).

3 Práce s poli (Standardní Python)

Funkce / Operace	Příklad použití	Vysvětlení
List Comprehension	`[x**2 for x in range(5)]`	Dynamické generování pole pomocí cyklu.
`x[start:stop:krok]`	`pole[1:10:2]`	Výřez (stop je exkluzivní). `[::-1]` pro otočení.
`x.copy()` vs `deepcopy`	`a = b.copy()`	`copy` je plytká, `deepcopy` kopíruje i vnořená pole.
`x.append(v)`	`data.append(10)`	Přidání jednoho prvku na konec pole.
`x.extend(a)`	`data.extend([1,2,3])`	Přidání více prvků na konec pole.

4 Základní Python (Built-in & Math)

Funkce / Operace	Příklad použití	Vysvětlení
`help(funkce)`	`help(print)`	Dokumentace pro zadanou funkci.
`range(start, stop)`	`list(range(0, 5))`	Vygeneruje sekvenci `[0, 1, 2, 3, 4]`.
`math.log(x, b)`	`math.log(8, 2)`	Logaritmus čísla x o základu b.
`math.sqrt(x)`	`math.sqrt(16)`	Druhá odmocnina čísla.
`math.ceil / floor`	`math.ceil(2.1)`	Zaokrouhlení nahoru (3) / dolů (2).
`math.trunc(x)`	`math.trunc(2.9)`	Odříznutí desetinné části (2).
`math.comb(n, k)`	`math.comb(10, 3)`	Kombinační číslo (počet kombinací k prvků z n).
`def function(...):`	`def funkce(x, y, z):`	Definice vlastní funkce s parametry.

5 Statistika a Matice (Knihovna NumPy a jiné)

Funkce / Operace	Příklad použití	Vysvětlení
`np.sum(x)`	`np.sum(data, axis=0)`	Součet všech prvků v poli (nebo podél zvolené osy).
`np.mean(x)`	`np.mean(data)`	Průměr všech prvků v poli.
`np.prod(x)`	`np.prod(data)`	Součin všech prvků v poli.
`np.sqrt(x)`	`np.sqrt(data)`	Druhá odmocnina z každého prvku v poli.
`np.random.rand(n)`	`np.random.rand(100)`	Generování pole n náhodných čísel z rovnoměrného rozdělení na $[0, 1)$.
`np.random.uniform(a, b, n)`	`np.random.uniform(10, 50, 100)`	Generuje n náhodných **desetinných** čísel v rozsahu $[a, b)$.
`np.quantile(x, q)`	`np.quantile(x, 0.75, method='midpoint')`	Výpočet kvantilu ($q \in [0, 1]$).
`Modus`	`statistics.multimode(data)`	`Vrací modus z pole (i více prvků)`
`np.log10(x)`	`np.log10(data)`	Dekadický logaritmus (základ 10). Často se používá pro normalizaci dat.
`np.linalg.norm(x, p)`	`np.linalg.norm(x, ord=2)`	Výpočet L^1, L^2 nebo L^∞ (`np.inf`) normy.
`np.insert / np.delete`	`np.insert(A, 1, [..], axis=0)`	Vloží/Smaže řádek (`axis=0`) nebo sloupec (`axis=1`).
`stats.gmean(x)`	`stats.gmean(x)`	Geometrický průměr (knihovna Scipy).
`stats.hmean(x)`	`stats.hmean(x, weights=[...])`	Harmonický průměr (knihovna Scipy).
`np.var(x, ddof=0)`	`np.var(data, ddof=0)`	**Klasický rozptyl** s_x^2 (děleno n).
`np.var(x, ddof=1)`	`np.var(data, ddof=1)`	**Výběrový rozptyl** S^2 (děleno $n-1$).
`np.std(x, ddof=0)`	`np.std(data, ddof=0)`	Klasická směrodatná odchylka s_x.
`np.std(x, ddof=1)`	`np.std(data, ddof=1)`	Výběrová směrodatná odchylka S.
`np.ptp(x)`	`np.ptp(data)`	**Variační rozpětí** $R = x_{max} - x_{min}$.
`v_x = std / mean`	`np.std(x) / np.mean(x)`	**Variační koeficient** v_x (relativní variabilita).
`np.where(cond, x, y)`	`np.where(df['am'] == 0, 'aut', 'man')`	**Podmíněný sloupec**: Pokud platí `cond`, vlož `x`, jinak `y` (jako IF v Excelu).

6 Knihovna Pandas (Analýza dat)

Funkce / Operace	Příklad použití	Vysvětlení
`pd.read_csv(file)`	`pd.read_csv('titanic.txt')`	Načte data z CSV souboru a vytvoří DataFrame.
`df[columns]`	`df[["A", "B", "C"]]`	Výběr určitých sloupců.
`Filtrování`	`df[df['Věk'] >= 18]`	Vybere pouze řádky splňující danou podmínku.
`df.quantile(p)`	`df.quantile(0.25, interpolation = 'midpoint')`	Vrátí p-tý kvantil z vybraného dataframe dle "VŠE"vzorce.
`df.describe()`	`df.describe()`	Souhrnné statistiky (mean, std, kvartily, atd.).
`df.loc` vs `df.iloc`	`df.loc[0, 'Sloupec']`	Výběr dat podle **názvů** (`loc`) vs. **pozice** (`iloc`).
`df.value_counts()`	`df['A'].value_counts()`	Tabulka četností pro kategorická data.
`df.isna().sum()`	`df.isna().sum()`	Počet chybějících (null) hodnot v tabulce.
`df.columns`	`list(df.columns)`	Vrátí seznam názvů všech sloupců v tabulce.
`df.index`	`df.index.tolist()`	Vrátí indexy řádků (názvy nebo čísla).
`df['A'].values`	`df['A'].values`	Převede sloupec zpět na **NumPy pole** (vhodné pro math funkce).
`df.sort_values()`	`df.sort_values(by='X')`	Seřadí tabulku podle hodnot ve sloupci 'X'.
`df.head(n) / tail`	`df.head(5)`	Zobrazí prvních / posledních n řádků tabulky.
`df.groupby('A')`	`df.groupby('A').mean()`	**Seskupování**: Výpočet statistik podle kategorií ve sloupci 'A'.
`df.drop()`	`df.drop(columns=['ID'])`	Odstraní vybraný sloupec nebo řádek.
`df.rename()`	`df.rename(columns={'A':'X'})`	Přejmenování sloupců pomocí slovníku.
`df.groupby()`	`df.groupby('A', as_index=False).mean()`	**Seskupování**: `as_index=False` zajistí, že sloupce zůstanou sloupci a nebudou v indexu.
`df.cumsum()`	`df['cetnost'].cumsum()`	**Kumulativní součet**: Pro výpočet kumulativních absolutních/relativních četností.
`pd.crosstab()`	`pd.crosstab(df['A'], df['B'])`	**Kontingenční tabulka četností**: Rychlý počet (count) pro kombinaci dvou kategorií.
`pd.pivot_table()`	`df.pivot_table(index='A', columns='B', values='C', aggfunc='mean')`	**Pivotní tabulka**: Univerzální. `values` je co počítám, `aggfunc` je co s tím dělám (mean, sum, count).

7 Vizualizace dat (Knihovna Matplotlib)

Boxploty a statistické grafy

Funkce / Operace	Příklad použití	Vysvětlení
`df.boxplot()`	`df.boxplot(column='Y', by='X', grid=False)`	**Boxplot (Pandas)**: `column` je osa Y, `by` je osa X (skupiny).
`sns.boxplot()`	`sns.boxplot(data=df, x='X', y='Y', palette='Set2')`	**Boxplot (Seaborn)**: Často hezčí a jednodušší syntaxe pro skupiny.
`df['X'].hist()`	`df['X'].hist(bins=10, edgecolor='black')`	**Histogram (Pandas)**: Nejrychlejší cesta k rozdělení četností.

Základní typy grafů

Funkce / Operace	Příklad použití	Vysvětlení
`df.plot()`	`df.plot(kind="bar", figsize=(4,3))`	Umožňuje interpretaci grafů rovnou z dataframe.
`plt.hist(x)`	`plt.hist(data, bins=15, edgecolor='black')`	**Histogram**: Rozdělení četností. `bins` = počet intervalů, `density=True` pro hustotu.
`plt.bar(x, y)`	`plt.bar(kategorie, hodnoty, width=0.5)`	**Sloupcový graf**: Porovnání kategorií. `width` mění šířku sloupců.
`plt.barh(x, y)`	`plt.barh(kategorie, hodnoty)`	**Vodorovný sloupcový graf**: Vhodný pro dlouhé názvy kategorií.
`plt.scatter(x, y)`	`plt.scatter(x, y, alpha=0.5, marker='o')`	**Bodový graf**: Závislost dvou proměnných. `alpha` nastavuje průhlednost.
`plt.plot(x, y)`	`plt.plot(x, y, linestyle='-', linewidth=2)`	**Spojnicový graf**: Vývoj v čase nebo trend.

Nastavení a úprava grafu (Vzhled)

Funkce / Operace	Příklad použití	Vysvětlení
`plt.title(s)`	`plt.title("Název grafu", fontsize=16)`	Nastaví hlavní nadpis grafu.
`plt.xlabel / ylabel`	`plt.xlabel("Čas [s]")`	Nastaví popisky os x a y.
`plt.xticks / yticks`	`plt.xticks(rotation=45)`	Nastavení značek na osách. `rotation` otočí popisky.
`plt.legend()`	`plt.legend(loc='upper right')`	Zobrazí legendu (vyžaduje parametr `label` v definici grafu).
`plt.grid()`	`plt.grid(True, axis='y', linestyle=':')`	Zobrazí mřížku. `axis` určuje směr (x, y, both).
`plt.xlim / ylim`	`plt.xlim(0, 100)`	Nastaví rozsah (měřítko) osy od–do.
`plt.axvline / hline`	`plt.axvline(np.mean(x), color='r')`	Vykreslí svislou/vodorovnou čáru (např. pro vyznačení průměru).
`plt.figure()`	`plt.figure(figsize=(10, 6))`	Nastaví velikost plátna grafu v palcích.
`plt.savefig()`	`plt.savefig("graf.pdf", bbox_inches='tight')`	Uloží graf. `bbox_inches='tight'` zajistí, že se neoříznou popisky.