VYSOKÁ ŠKOLA EKONOMICKÁ V PRAZE
FAKULTA INFORMATIKY A STATISTIKY

STATISTIKA PRO INFORMATIKY

VZORCE PRO 4ST204

Obsah

1 Popisná Statistika **3**
1.1 Četnosti . . . 3
1.1.1 Absolutní četnost . . . 3
1.1.2 Součet absolutních četností . . . 3
1.1.3 Relativní Četnost . . . 3
1.1.4 Součet relativních četností . . . 3
1.2 Charakteristiky polohy . . . 4
1.2.1 Aritmetický průměr . . . 4
1.2.2 Vážený aritmetický průměr (z četnostní tabulky) . . . 4
1.2.3 Aritmetický průměr pomocí relativních četností . . . 5
1.2.4 Harmonický průměr . . . 6
1.2.5 Geometrický průměr . . . 6
1.2.6 Vztah mezi průměry . . . 7
1.2.7 Medián . . . 7
1.2.8 Kvantily a kvartily . . . 8
1.2.9 Interkvartilové rozpětí (IQR) . . . 9
1.3 Charakteristiky variability . . . 10
1.3.1 Variační rozpětí . . . 10
1.3.2 Rozptyl statistického souboru . . . 11
1.3.3 Výběrový rozptyl . . . 12
1.3.4 Vážený rozptyl . . . 12
1.3.5 Směrodatná odchylka statistického souboru . . . 13
1.3.6 Výběrová směrodatná odchylka . . . 14
1.3.7 Variační koeficient . . . 14

2 Teorie pravděpodobnosti **15**
2.1 Počet pravděpodobnosti . . . 15
2.1.1 Klasická definice pravděpodobnosti . . . 15
2.1.2 Pravděpodobnost komplementárního jevu . . . 15
2.1.3 Horní odhad pravděpodobnosti průniku . . . 16
2.1.4 Průnik nezávislých jevů . . . 16
2.1.5 Sjednocení dvou jevů . . . 16
2.1.6 Sjednocení neslučitelných jevů . . . 16
2.2 Náhodné veličiny . . . 17
2.2.1 Pravděpodobnostní funkce diskrétní náhodné veličiny . . . 17
2.2.2 Distribuční funkce diskrétní náhodné veličiny . . . 17
2.2.3 Pravděpodobnost intervalu . . . 17
2.2.4 Střední hodnota diskrétní náhodné veličiny . . . 17
2.2.5 Rozptyl diskrétní náhodné veličiny . . . 18
2.2.6 Hustota pravděpodobnosti spojité náhodné veličiny . . . 18
2.2.7 Normalizační podmínka hustoty pravděpodobnosti . . . 18
2.2.8 Distribuční funkce spojité náhodné veličiny . . . 18
2.2.9 Pravděpodobnost intervalu spojité náhodné veličiny . . . 19
2.2.10 Střední hodnota spojité náhodné veličiny . . . 19
2.2.11 Rozptyl spojité náhodné veličiny . . . 19
2.2.12 Směrodatná odchylka náhodné veličiny . . . 20

3 Kombinatorika a Metriky **20**
3.1 Kombinatorika . . . 20
3.2 L^p Normy (Vzdálenosti a penalizace) . . . 20

4 Testování hypotéz **20**

5 Práce s daty v Pythonu (Cheatsheet) **22**

5.1 Užitečné knihovny a základy 22
5.2 Práce s poli (Standardní Python) 22
5.3 Základní Python (Built-in & Math) 23
5.4 Statistika a Matice (Knihovna NumPy a jiné) 24
5.5 Pandas: Analýza dat 25
5.6 Matplotlib a Seaborn: Vizualizace 26
5.7 Náhodné veličiny a rozdělení 26
5.8 Intervaly spolehlivosti a velikost výběru 28
5.9 Testování hypotéz 29

1 Popisná Statistika

1.1 Četnosti

1.1.1 Absolutní četnost

Absolutní četnost i-té hodnoty je počet výskytů dané hodnoty ve výběru.

$$n_i$$

kde

- n_i je počet výskytů i-té hodnoty ve výběru.

1.1.2 Součet absolutních četností

Součet absolutních četností všech hodnot (nebo tříd) ve výběru se rovná celkovému počtu pozorování.

$$\sum_{i=1}^{k} n_i = n$$

kde

- $\sum$ je sumační znak (značí sčítání),
- i je index hodnoty nebo třídy,
- k je počet různých hodnot nebo tříd,
- n_i je absolutní četnost i-té hodnoty (nebo třídy),
- n je celkový počet pozorování.

1.1.3 Relativní Četnost

Relativní četnost i-té hodnoty ve výběru je definována jako podíl absolutní četnosti dané hodnoty a celkového počtu pozorování,

$$p_i = \frac{n_i}{n}$$

kde

- p_i je relativní četnost i-té hodnoty,
- n_i je absolutní četnost i-té hodnoty (kolikrát se hodnota vyskytla),
- n je celkový počet pozorování v souboru.

1.1.4 Součet relativních četností

Součet relativních četností všech hodnot (nebo tříd) ve výběru je roven jedné.

$$\sum_{i=1}^{k} p_i = 1$$

kde

- $\sum$ je sumační znak (značí sčítání),
- i je index hodnoty nebo třídy,
- k je počet různých hodnot nebo tříd,
- p_i je relativní četnost i-té hodnoty (nebo třídy).

1.2 Charakteristiky polohy

1.2.1 Aritmetický průměr

Aritmetický průměr (výběrový průměr) je definován jako součet všech hodnot statistického souboru dělený počtem pozorování.

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

kde

- $\bar{x}$ je aritmetický průměr,
- $\sum$ je sumační znak (součet hodnot),
- x_i je i-tá hodnota statistického souboru,
- i je index hodnoty,
- n je počet pozorování.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`mean(x)`	`x <- c(1,2,3,4,5)` `mean(x)`	Vrací aritmetický průměr hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.mean(x)`	`import numpy as np`
	`x = np.array([1,2,3,4,5])`
	`np.mean(x)`
		Vrací aritmetický průměr pole pomocí knihovny `numpy`.

1.2.2 Vážený aritmetický průměr (z četnostní tabulky)

Pokud jsou data zadána pomocí četnostní tabulky, aritmetický průměr lze vypočítat jako vážený průměr hodnot.

$$\bar{x} = \frac{\sum_{i=1}^{k} x_i n_i}{\sum_{i=1}^{k} n_i}$$

kde

- $\bar{x}$ je aritmetický průměr,
- $\sum$ je sumační znak (součet),
- x_i je i-tá hodnota znaku,
- n_i je absolutní četnost i-té hodnoty,
- k je počet různých hodnot nebo tříd,
- $\sum_{i=1}^{k} n_i$ je celkový počet pozorování.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`weighted.mean(x, w)`	`x <- c(1,2,3)`
	`w <- c(2,3,5)`
	
	`weighted.mean(x, w)`
		Vrací vážený průměr hodnot ve vektoru `x` s váhami `w`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.average(x, weights=w)`	`import numpy as np`
	
	`x = np.array([1,2,3])`
	`w = np.array([2,3,5])`
	
	`np.average(x, weights=w)`
		Vrací vážený průměr hodnot ve vektoru `x` s váhami `w`.

1.2.3 Aritmetický průměr pomocí relativních četností

Pokud jsou data vyjádřena pomocí relativních četností, lze aritmetický průměr vypočítat jako vážený součet hodnot.

$$\bar{x} = \sum_{i=1}^{k} x_i p_i$$

kde

- $\bar{x}$ je aritmetický průměr,
- $\sum$ je sumační znak (součet),
- x_i je i-tá hodnota znaku,
- p_i je relativní četnost i-té hodnoty,
- i je index hodnoty,
- k je počet různých hodnot nebo tříd.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`sum(x * p)`	`x <- c(1,2,3)`
	`p <- c(0.2,0.3,0.5)`
	
	`sum(x * p)`
		Vrací aritmetický průměr vypočtený pomocí relativních četností.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.sum(x * p)`	`import numpy as np`
	
	`x = np.array([1,2,3])`
	`p = np.array([0.2,0.3,0.5])`
	
	`np.sum(x * p)`
		Vrací aritmetický průměr vypočtený pomocí relativních četností pomocí knihovny `numpy`.

1.2.4 Harmonický průměr

Harmonický průměr je definován jako podíl počtu pozorování a součtu převrácených hodnot jednotlivých pozorování.

$$\bar{x}_H = \frac{n}{\sum_{i=1}^{n} \frac{1}{x_i}}$$

kde

- $\bar{x}_H$ je harmonický průměr,
- n je počet pozorování,
- $\sum$ je sumační znak (součet),
- x_i je i-tá hodnota statistického souboru,
- $\frac{1}{x_i}$ je převrácená hodnota i-tého pozorování.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`n / sum(1/x)`	`x <- c(1,2,4,5)`
	`n <- length(x)`
	
	`n / sum(1/x)`
		Vrací harmonický průměr hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`scipy.stats.`
`hmean(x)`
	`from scipy.stats import`
	`  hmean`
	
	`x = [1,2,4,5]`
	
	`hmean(x)`
		Vrací harmonický průměr pomocí funkce `hmean` z knihovny `scipy.stats`.

1.2.5 Geometrický průměr

Geometrický průměr je definován jako n-tá odmocnina součinu všech hodnot statistického souboru.

$$\bar{x}_G = \sqrt[n]{\prod_{i=1}^{n} x_i} = \sqrt[n]{x_1 \cdot x_2 \cdots x_n}$$

kde

- $\bar{x}_G$ je geometrický průměr,
- $\prod$ je znak pro součin (násobení všech hodnot),
- x_i je i-tá hodnota statistického souboru,
- i je index hodnoty,
- n je počet pozorování,
- $\sqrt[n]{\cdot}$ značí n-tou odmocninu.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`exp(mean(log(x)))`	`x <- c(1,2,3,4)`
	
	`exp(mean(log(x)))`
		Vrací geometrický průměr hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`scipy.stats.gmean(x)`	`from scipy.stats import gmean`
	
	`x = [1,2,3,4]`
	
	`gmean(x)`
		Vrací geometrický průměr pomocí funkce `gmean` z knihovny `scipy.stats`.

1.2.6 Vztah mezi průměry

$$\bar{x}_H \leq \bar{x}_G \leq \bar{x}$$

kde

- $\bar{x}_H$ je harmonický průměr,
- $\bar{x}_G$ je geometrický průměr,
- $\bar{x}$ je aritmetický průměr.

1.2.7 Medián

Medián je hodnota, která rozděluje uspořádaný statistický soubor na dvě stejně početné části. Medián také vyjadřuje 50% kvantil.

$$\tilde{x} = \begin{cases} x_{\left(\frac{n+1}{2}\right)}, & \text{je-li } n \text{ liché,} \\ \frac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2}, & \text{je-li } n \text{ sudé.} \end{cases}$$

kde

- $\tilde{x}$ je medián,
- $x_{(i)}$ je i-tá hodnota v uspořádaném statistickém souboru,
- n je počet pozorování.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`median(x)`	`x <- c(1,3,2,5,4)` `median(x)`	Vrací medián hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.median(x)`	`import numpy as np`
	
	`x = np.array([1,3,2,5,4])`
	`np.median(x)`
		Vrací medián hodnot ve vektoru `x`.

1.2.8 Kvantily a kvartily

Kvantily rozdělují uspořádaný statistický soubor na části se stejným počtem pozorování.

q-kvantil je hodnota x_q, pro kterou platí

$$P(X \leq x_q) = q$$

kde

- x_q je q-kvantil,
- $q \in (0, 1)$ je pořadí kvantilu,
- $P(X \leq x_q)$ je pravděpodobnost, že náhodná veličina nabývá hodnot menších nebo rovných x_q.

Speciálním případem kvantilů jsou kvartily, které rozdělují data na čtyři stejně velké části.

$$Q_1 = x_{0.25}, \qquad Q_2 = x_{0.5}, \qquad Q_3 = x_{0.75}$$

kde

- Q_1 je první kvartil (25% dat je menších),
- Q_2 je druhý kvartil, který odpovídá mediánu,
- Q_3 je třetí kvartil (75% dat je menších).

Implementace v R

Funkce	Příklad použití	Vysvětlení

`quantile(x)`	`x <- c(1,2,3,4,5,6,7,8)`
	
	`quantile(x)`
		Vrací kvantily datového vektoru.

`quantile(x, probs=c(0.25, 0.5, 0.75))`	`x <- c(1,2,3,4,5,6,7,8)`
	
	`quantile(x, probs=c`
	`(0.25,0.5,0.75))`
		Vrací první, druhý a třetí kvartil.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.quantile(x,q)`	`import numpy as np`
	
	`x = np.array`
	`([1,2,3,4,5,6,7,8])`
	
	`np.quantile(x,0.5)`
		Vrací q-kvantil pole.

`np.quantile(x, [0.25,0.5,0.75])`	`import numpy as np`
	
	`x = np.array`
	`([1,2,3,4,5,6,7,8])`
	
	`np.quantile(x`
	`,[0.25,0.5,0.75])`
		Vrací první, druhý a třetí kvartil.

1.2.9 Interkvartilové rozpětí (IQR)

Interkvartilové rozpětí (IQR) je rozdíl mezi třetím a prvním kvartilem. Vyjadřuje rozptyl prostředních 50 % dat.

$$IQR = Q_3 - Q_1$$

kde

- IQR je interkvartilové rozpětí,
- Q_1 je první kvartil,
- Q_3 je třetí kvartil.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`IQR(x)`	`x <- c(1,2,3,4,5,6,7,8)`
	
	`IQR(x)`
		Vrací interkvartilové rozpětí datového vektoru.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.quantile(x,0.75) - np.quantile(x,0.25)`	`import numpy as np`
	
	`x = np.array ([1,2,3,4,5,6,7,8])`
	
	`np.quantile(x,0.75) - np. quantile(x,0.25)`
		Vrací interkvartilové rozpětí pole.

1.3 Charakteristiky variability

1.3.1 Variační rozpětí

Variační rozpětí je rozdíl mezi maximální a minimální hodnotou statistického souboru.

$$R = x_{\max} - x_{\min}$$

kde

- R je variační rozpětí,
- $x_{\max}$ je maximální hodnota v souboru,
- $x_{\min}$ je minimální hodnota v souboru.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`max(x) - min(x)`	`x <- c(3,7,2,9,5)`
	
	`max(x) - min(x)`
		Vrací variační rozpětí hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.max(x) - np.min(x)`	`import numpy as np`
	
	`x = np.array([3,7,2,9,5])`
	
	`np.max(x) - np.min(x)`
		Vrací variační rozpětí hodnot ve vektoru `x`.

1.3.2 Rozptyl statistického souboru

Rozptyl vyjadřuje průměrnou kvadratickou odchylku hodnot od aritmetického průměru.

$$s_x^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n}$$

kde

- s_x^2 je rozptyl statistického souboru,
- $\sum$ je sumační znak (součet),
- x_i je i-tá hodnota statistického souboru,
- $\bar{x}$ je aritmetický průměr,
- $x_i - \bar{x}$ je odchylka hodnoty od průměru,
- $(x_i - \bar{x})^2$ je čtverec odchylky,
- n je počet pozorování.

Výpočetní tvar rozptylu:

$$s_x^2 = \frac{\sum_{i=1}^{n} x_i^2}{n} - \left(\frac{\sum_{i=1}^{n} x_i}{n}\right)^2$$

Implementace v R

Funkce	Příklad použití	Vysvětlení

`mean((x - mean(x))`^{2}`)`	`x <- c(2,4,6,8)`
	
	`mean((x-mean(x))^2)`
		Vrací nevýběrový (populační) rozptyl hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.var(x)`	`import numpy as np`
	
	`x = np.array([2,4,6,8])`
	
	`np.var(x)`
		Vrací nevýběrový (populační) rozptyl pomocí knihovny `numpy`.

1.3.3 Výběrový rozptyl

Výběrový rozptyl je nezkreslený odhad rozptylu populace a vznikne úpravou rozptylu statistického souboru pomocí Besselovy korekce.

$$S^2 = \frac{n}{n-1} s_x^2$$

kde

- S^2 je výběrový rozptyl,
- s_x^2 je rozptyl statistického souboru,
- n je počet pozorování,
- $n - 1$ je korekce při odhadu rozptylu (Besselova korekce).

Implementace v R

Funkce	Příklad použití	Vysvětlení
`var(x)`	`x <- c(2,4,6,8)` `var(x)`	Vrací výběrový rozptyl hodnot ve vektoru `x` (dělí se $n - 1$).

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.var(x, ddof=1)`	`import numpy as np`
	`x = np.array([2,4,6,8])`
	`np.var(x, ddof=1)`
		Vrací výběrový rozptyl pomocí knihovny `numpy` (Besselova korekce).

1.3.4 Vážený rozptyl

Vážený rozptyl vyjadřuje variabilitu hodnot znaku, když mají jednotlivé hodnoty různé váhy nebo relativní četnosti.

$$s^2 = \sum_{i=1}^{k} p_i (x_i - \bar{x})^2$$

kde

- s^2 je vážený rozptyl,
- x_i je i-tá hodnota znaku,
- $\bar{x}$ je vážený aritmetický průměr,
- p_i je váha nebo relativní četnost i-té hodnoty,
- k je počet různých hodnot nebo tříd.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`weighted.mean( (x-mean(x))^2, w)`	`x <- c(1,2,3,4)`
	`w <- c(0.1,0.2,0.3,0.4)`
	
	`weighted.mean((x-weighted.mean(x,w))^2, w)`
		Vrací vážený rozptyl hodnot s váhami `w`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.average( (x-xbar)**2, weights=w)`	`import numpy as np`
	
	`x = np.array([1,2,3,4])`
	`w = np.array([0.1,0.2,0.3,0.4])`
	
	`xbar = np.average(x, weights=w)`
	`np.average((x-xbar)**2, weights=w)`
		Vrací vážený rozptyl hodnot s váhami `w` pomocí knihovny `numpy`.

1.3.5 Směrodatná odchylka statistického souboru

Směrodatná odchylka je druhá odmocnina rozptylu statistického souboru.

$$s_x = \sqrt{s_x^2}$$

kde

- s_x je směrodatná odchylka,
- s_x^2 je rozptyl statistického souboru,
- $\sqrt{\cdot}$ značí druhou odmocninu.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`sqrt(mean((x-mean(x))^2))`	`x <- c(2,4,6,8)`
	
	`sqrt(mean((x-mean(x))^2))`
		Vrací směrodatnou odchylku statistického souboru.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.std(x)`	`import numpy as np`
	
	`x = np.array([2,4,6,8])`
	
	`np.std(x)`
		Vrací směrodatnou odchylku pole (nevýběrovou).

1.3.6 Výběrová směrodatná odchylka

Výběrová směrodatná odchylka je odmocnina z výběrového rozptylu.

$$S = \sqrt{S^2}$$

kde

- S je výběrová směrodatná odchylka,
- S^2 je výběrový rozptyl,
- $\sqrt{\cdot}$ značí druhou odmocninu.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`sd(x)`	`x <- c(2,4,6,8)`
	
	`sd(x)`
		Vrací výběrovou směrodatnou odchylku (dělí se $n-1$).

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.std(x, ddof=1)`	`import numpy as np`
	
	`x = np.array([2,4,6,8])`
	
	`np.std(x, ddof=1)`
		Vrací výběrovou směrodatnou odchylku (Besselova korekce).

1.3.7 Variační koeficient

Variační koeficient vyjadřuje relativní variabilitu dat a udává poměr směrodatné odchylky k aritmetickému průměru.

$$v_x = \frac{s_x}{\bar{x}}$$

kde

- v_x je variační koeficient,
- s_x je směrodatná odchylka,
- $\bar{x}$ je aritmetický průměr.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`sd(x) / mean(x)`	`x <- c(2,4,6,8)`
	
	`sd(x) / mean(x)`
		Vrací variační koeficient hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.std(x) / np.mean(x)`	`import numpy as np`
	
	`x = np.array([2,4,6,8])`
	
	`np.std(x) / np.mean(x)`
		Vrací variační koeficient hodnot ve vektoru `x`.

2 Teorie pravděpodobnosti

2.1 Počet pravděpodobnosti

2.1.1 Klasická definice pravděpodobnosti

Pravděpodobnost jevu A při klasické definici pravděpodobnosti je podíl počtu příznivých výsledků a celkového počtu stejně pravděpodobných výsledků.

$$P(A) = \frac{m}{n}$$

kde

- $P(A)$ je pravděpodobnost jevu A,
- m je počet příznivých výsledků,
- n je počet všech možných výsledků.

2.1.2 Pravděpodobnost komplementárního jevu

Pravděpodobnost opačného (komplementárního, doplňkového) jevu k jevu A je rovna jedné minus pravděpodobnost jevu A.

$$P(\overline{A}) = 1 - P(A)$$

kde

- $P(\overline{A})$ je pravděpodobnost opačného jevu k A,
- $P(A)$ je pravděpodobnost jevu A.

2.1.3 Horní odhad pravděpodobnosti průniku

Pravděpodobnost současného nastání dvou jevů nemůže být větší než pravděpodobnost kteréhokoli z nich.

$$P(A \cap B) \leq \min(P(A), P(B))$$

kde

- $P(A \cap B)$ je pravděpodobnost, že nastanou oba jevy současně,
- $P(A)$ je pravděpodobnost jevu A,
- $P(B)$ je pravděpodobnost jevu B,
- $\min(\cdot)$ označuje minimum z daných hodnot.

2.1.4 Průnik nezávislých jevů

Jsou-li jevy A a B nezávislé, pak pravděpodobnost jejich současného nastání je rovna součinu jejich pravděpodobností.

$$P(A \cap B) = P(A)P(B)$$

kde

- $P(A \cap B)$ je pravděpodobnost současného nastání jevů A a B,
- $P(A)$ je pravděpodobnost jevu A,
- $P(B)$ je pravděpodobnost jevu B.

2.1.5 Sjednocení dvou jevů

Pravděpodobnost, že nastane alespoň jeden z jevů A nebo B, je rovna součtu jejich pravděpodobností minus pravděpodobnost jejich současného nastání.

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

kde

- $P(A \cup B)$ je pravděpodobnost, že nastane alespoň jeden z jevů,
- $P(A)$ je pravděpodobnost jevu A,
- $P(B)$ je pravděpodobnost jevu B,
- $P(A \cap B)$ je pravděpodobnost současného nastání jevů A a B.

2.1.6 Sjednocení neslučitelných jevů

Pokud jsou jevy A a B neslučitelné (nemohou nastat současně), pak pravděpodobnost jejich sjednocení je rovna součtu pravděpodobností těchto jevů.

$$P(A \cup B) = P(A) + P(B)$$

kde

- $P(A \cup B)$ je pravděpodobnost, že nastane jev A nebo B,
- $P(A)$ je pravděpodobnost jevu A,
- $P(B)$ je pravděpodobnost jevu B.

2.2 Náhodné veličiny

2.2.1 Pravděpodobnostní funkce diskrétní náhodné veličiny

Pravděpodobnost, že diskrétní náhodná veličina X nabývá konkrétní hodnoty x.

$$P(x) = P(X = x)$$

kde

- $P(x)$ je pravděpodobnost hodnoty x,
- $P(X = x)$ je pravděpodobnost, že náhodná veličina X má hodnotu x,
- X je náhodná veličina,
- x je konkrétní hodnota náhodné veličiny.

2.2.2 Distribuční funkce diskrétní náhodné veličiny

Distribuční funkce (kumulativní pravděpodobnost) udává pravděpodobnost, že náhodná veličina X bude menší nebo rovna hodnotě x.

$$F(x) = P(X \leq x) = \sum_{x_j \leq x} P(x_j)$$

kde

- $F(x)$ je distribuční funkce,
- $P(X \leq x)$ je pravděpodobnost, že X je menší nebo rovno x,
- $\sum$ je součet pravděpodobností,
- x_j jsou jednotlivé možné hodnoty náhodné veličiny,
- $P(x_j)$ je pravděpodobnost, že $X = x_j$.

2.2.3 Pravděpodobnost intervalu

Pravděpodobnost, že náhodná veličina X nabývá hodnot v intervalu $(x_1, x_2]$.

$$P(x_1 < X \leq x_2) = \sum_{x_1 < x \leq x_2} P(x) = F(x_2) - F(x_1)$$

kde

- $P(x_1 < X \leq x_2)$ je pravděpodobnost, že X leží mezi x_1 a x_2,
- X je náhodná veličina,
- x_1, x_2 jsou hranice intervalu,
- $\sum$ je součet pravděpodobností všech hodnot v intervalu,
- $P(x)$ je pravděpodobnost, že $X = x$,
- $F(x)$ je distribuční funkce.

2.2.4 Střední hodnota diskrétní náhodné veličiny

Střední hodnota (očekávaná hodnota) diskrétní náhodné veličiny je vážený průměr všech možných hodnot, kde váhami jsou jejich pravděpodobnosti.

$$E(X) = \sum_{x} x\, P(x)$$

kde

- $E(X)$ je očekávaná hodnota náhodné veličiny X,
- $\sum$ je součet přes všechny možné hodnoty,
- x jsou jednotlivé možné hodnoty náhodné veličiny,
- $P(x) = P(X = x)$ je pravděpodobnost, že X nabude hodnoty x.

2.2.5 Rozptyl diskrétní náhodné veličiny

Rozptyl náhodné veličiny vyjadřuje míru variability hodnot náhodné veličiny kolem její střední hodnoty.

$$D(X) = E(X^2) - [E(X)]^2 = \sum_x x^2 P(x) - \left(\sum_x xP(x)\right)^2$$

kde

- $D(X)$ je rozptyl náhodné veličiny X,
- $E(X)$ je očekávaná hodnota náhodné veličiny,
- $E(X^2)$ je očekávaná hodnota druhé mocniny náhodné veličiny,
- $\sum$ je součet přes všechny možné hodnoty,
- x jsou jednotlivé možné hodnoty náhodné veličiny,
- $P(x) = P(X = x)$ je pravděpodobnost, že X nabude hodnoty x.

2.2.6 Hustota pravděpodobnosti spojité náhodné veličiny

Hustota pravděpodobnosti vyjadřuje rychlost změny distribuční funkce spojité náhodné veličiny.

$$f(x) = F'(x)$$

kde

- $f(x)$ je hustota pravděpodobnosti,
- $F(x)$ je distribuční funkce,
- $F'(x)$ je derivace distribuční funkce podle x,
- x je hodnota náhodné veličiny.

2.2.7 Normalizační podmínka hustoty pravděpodobnosti

Celková pravděpodobnost spojité náhodné veličiny přes všechny možné hodnoty je rovna jedné.

$$\int_{-\infty}^{\infty} f(x)\, dx = 1$$

kde

- $\int$ označuje integrál (součet přes všechny hodnoty),
- $f(x)$ je hustota pravděpodobnosti,
- dx je integrační proměnná,
- $-\infty, \infty$ vyjadřují integraci přes všechny možné hodnoty náhodné veličiny.

2.2.8 Distribuční funkce spojité náhodné veličiny

Distribuční funkce spojité náhodné veličiny udává pravděpodobnost, že náhodná veličina X bude menší nebo rovna hodnotě x.

$$F(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)\, dt$$

kde

- $F(x)$ je distribuční funkce,
- $P(X \leq x)$ je pravděpodobnost, že náhodná veličina X je menší nebo rovna x,
- $\int$ označuje integrál,
- $f(t)$ je hustota pravděpodobnosti,
- t je integrační proměnná,
- $-\infty$ je dolní mez integrace,
- x je horní mez integrace.

2.2.9 Pravděpodobnost intervalu spojité náhodné veličiny

Pravděpodobnost, že spojitá náhodná veličina X nabývá hodnot v intervalu $(x_1, x_2]$.

$$P(x_1 < X \leq x_2) = \int_{x_1}^{x_2} f(x)\,dx = F(x_2) - F(x_1)$$

kde

- $P(x_1 < X \leq x_2)$ je pravděpodobnost, že X leží mezi x_1 a x_2,
- X je náhodná veličina,
- x_1, x_2 jsou hranice intervalu,
- $\int$ označuje integrál,
- $f(x)$ je hustota pravděpodobnosti,
- dx je integrační proměnná,
- $F(x)$ je distribuční funkce.

2.2.10 Střední hodnota spojité náhodné veličiny

Střední hodnota (očekávaná hodnota) spojité náhodné veličiny je vážený průměr všech možných hodnot, kde váhami jsou hodnoty hustoty pravděpodobnosti.

$$E(X) = \int_{-\infty}^{\infty} x f(x)\,dx$$

kde

- $E(X)$ je očekávaná hodnota náhodné veličiny X,
- $\int$ označuje integrál,
- x je hodnota náhodné veličiny,
- $f(x)$ je hustota pravděpodobnosti,
- dx je integrační proměnná,
- $-\infty, \infty$ vyjadřují integraci přes všechny možné hodnoty náhodné veličiny.

2.2.11 Rozptyl spojité náhodné veličiny

Rozptyl spojité náhodné veličiny vyjadřuje variabilitu hodnot náhodné veličiny kolem její střední hodnoty.

$$D(X) = \int_{-\infty}^{\infty} x^2 f(x)\,dx - \left[\int_{-\infty}^{\infty} x f(x)\,dx\right]^2$$

kde

- $D(X)$ je rozptyl náhodné veličiny X,
- $\int$ označuje integrál,
- x je hodnota náhodné veličiny,
- $f(x)$ je hustota pravděpodobnosti,

- dx je integrační proměnná,
- $\int xf(x)\,dx$ je očekávaná hodnota $E(X)$,
- $\int x^2 f(x)\,dx$ je očekávaná hodnota $E(X^2)$.

2.2.12 Směrodatná odchylka náhodné veličiny

Směrodatná odchylka vyjadřuje míru variability hodnot náhodné veličiny kolem její střední hodnoty.

$$\sigma = \sqrt{D(X)}$$

kde

- σ je směrodatná odchylka,
- $D(X)$ je rozptyl náhodné veličiny X,
- $\sqrt{\ }$ označuje druhou odmocninu.

3 Kombinatorika a Metriky

3.1 Kombinatorika

Mějme množinu n prvků, ze které vybíráme k prvků.

- **Permutace (Pořadí všech n prvků):** Bez opakování: $P(n) = n!$
  S opakováním: $P'_{k_1,\ldots,k_m}(n) = \frac{n!}{k_1!\cdot\ldots\cdot k_m!}$
- **Variace (Výběr k prvků z n, záleží na pořadí):** Bez opakování: $V(k,n) = \frac{n!}{(n-k)!}$
  S opakováním: $V'(k,n) = n^k$
- **Kombinace (Výběr k prvků z n, nezáleží na pořadí):** Bez opakování: $K(k,n) = \binom{n}{k} = \frac{n!}{k!(n-k)!}$
  S opakováním: $K'(k,n) = \binom{n+k-1}{k} = \frac{(n+k-1)!}{k!(n-1)!}$

3.2 L^p Normy (Vzdálenosti a penalizace)

Obecně: $\|x\|_p = (\sum |x_i|^p)^{1/p}$. Klíčové pro metriky chyb a regularizaci.

- L^1 **(Manhattan):** $\|x\|_1 = \sum |x_i|$. Využití: Lasso regrese.
- L^2 **(Euklid):** $\|x\|_2 = \sqrt{\sum x_i^2}$. Využití: Ridge regrese (metoda nejmenších čtverců).
- L^∞ **(Max):** $\|x\|_\infty = \max(|x_i|)$. Reprezentuje nejhorší možnou chybu.

4 Testování hypotéz

1. Stanovení hypotéz

- H_0 **(Nulová hypotéza)**: Předpokládá stav „bez změny“, „rovnost“ nebo „nezávislost“ (např. $\mu = \mu_0$).

- H_1 **(Alternativní hypotéza)**: Tvrzení, které chceme prokázat vyvrácením H_0. Může být oboustranná (např. $\mu \neq \mu_0$) nebo jednostranná (např. $\mu < \mu_0$).

2. Volba hladiny významnosti (α)

- α: Maximální přípustná pravděpodobnost chyby I. typu, tedy riziko, že chybně zamítneme pravdivou H_0 (tzv. odsouzení nevinného).

- Nejčastěji se volí $\alpha = 0,05$ nebo $\alpha = 0,01$. Vyžadujeme-li vyšší jistotu, volíme nižší hladinu významnosti.

3. Výpočet testové statistiky a kritické hodnoty

- **Testová statistika (např. u nebo t):** Vypočítaná hodnota ze vzorku dat, podle které se následně rozhodujeme.
- **Vzorec pro test průměru:** $u = \frac{\bar{x}-\mu_0}{s_x/\sqrt{n}}$.
  - $\bar{x}$: výběrový průměr.
  - μ_0: hypotetická střední hodnota (populační parametr) dle H_0.
  - s_x: výběrová směrodatná odchylka.
  - n: počet pozorování (rozsah výběru).
- **Vzorec pro test podílu/relativní četnosti:** $u = \frac{p-p_0}{\sqrt{p_0(1-p_0)/n}}$.
- **Kritická hodnota:** Hranice, která vymezuje kritický obor. V Pythonu ji najdeme např. jako `stats.norm.ppf(1 - α)` pro jednostranný test. Pokud statistika překročí tuto hranici do kritického oboru, H_0 se zamítá.

4. Rozhodnutí

- **p-hodnota**: Udává pravděpodobnost, že za platnosti H_0 získáme stejnou nebo ještě extrémnější hodnotu testového kritéria (v podstatě pravděpodobnost chyby 1. typu, pokud bychom H_0 zamítli).
- **Pravidlo rozhodování**:
  - Pokud $p \leq \alpha$: Data jsou v silném rozporu s H_0, a proto **zamítáme** H_0 ve prospěch H_1.
  - Pokud $p > \alpha$: Rozdíl lze vysvětlit náhodou, a proto **nezamítáme** H_0 na hladině významnosti α.

Jak se p-hodnota určí?

- P-hodnota představuje obsah plochy pod křivkou hustoty pravděpodobnosti v „extrémní“ oblasti, kterou vymezuje vámi vypočítaná testová statistika (t_{obs}).
- Neexistuje jeden univerzální algebraický vzorec, protože výpočet závisí na typu rozdělení (např. normální rozdělení, Studentovo t-rozdělení) a typu alternativní hypotézy:
  - **Pravostranný test** ($H_1 : \mu > \mu_0$): $p = P(T \geq t_{obs} \mid H_0)$.
  - **Levostranný test** ($H_1 : \mu < \mu_0$): $p = P(T \leq t_{obs} \mid H_0)$.
  - **Oboustranný test** ($H_1 : \mu \neq \mu_0$): $p = 2 \cdot P(T \geq |t_{obs}| \mid H_0)$.
- V Pythonu se tato hodnota určuje pomocí distribučních funkcí (`cdf` nebo `sf`) nebo je přímo výstupem testových funkcí (např. `stats.ttest_1samp`).

5 Práce s daty v Pythonu (Cheatsheet)

5.1 Užitečné knihovny a základy

Funkce	Příklad použití	Vysvětlení
`import numpy as np`	`np.array([...])`	Matice, vektory a rychlé matematické operace.
`import pandas as pd`	`pd.DataFrame(matice)`	Analýza tabulek a práce s CSV.
`import matplotlib.pyplot as plt`	`plt.hist(data)`	Tvorba grafů a vizualizace dat.
`math.comb(n, k)`	`math.comb(10, 3)`	Kombinační číslo (výběr k z n).
`List Comprehension`	`[x**2 for x in range(5)]`	Dynamické generování pole pomocí cyklu.

5.2 Práce s poli (Standardní Python)

Funkce	Příklad použití	Vysvětlení
List Comprehension	`[x**2 for x in range(5)]`	Dynamické generování pole pomocí cyklu.
`x[start:stop:krok]`	`pole[1:10:2]`	Výřez (stop je exkluzivní). `[::-1]` pro otočení.
`x.copy()` vs `deepcopy`	`a = b.copy()`	`copy` je plytká, `deepcopy` kopíruje i vnořená pole.
`x.append(v)`	`data.append(10)`	Přidání jednoho prvku na konec pole.
`x.extend(a)`	`data.extend([1,2,3])`	Přidání více prvků na konec pole.

5.3 Základní Python (Built-in & Math)

Funkce	Příklad použití	Vysvětlení
`help(funkce)`	`help(print)`	Dokumentace pro zadanou funkci.
`range(start, stop)`	`list(range(0, 5))`	Vygeneruje sekvenci `[0, 1, 2, 3, 4]`.
`math.log(x, b)`	`math.log(8, 2)`	Logaritmus čísla x o základu b.
`math.sqrt(x)`	`math.sqrt(16)`	Druhá odmocnina čísla.
`math.ceil / floor`	`math.ceil(2.1)`	Zaokrouhlení nahoru (3) / dolů (2).
`math.trunc(x)`	`math.trunc(2.9)`	Odříznutí desetinné části (2).
`math.comb(n, k)`	`math.comb(10, 3)`	Kombinační číslo (počet kombinací k prvků z n).
`def function(...):`	`def funkce(x, y, z):`	Definice vlastní funkce s parametry.

5.4 Statistika a Matice (Knihovna NumPy a jiné)

Funkce	Příklad použití	Vysvětlení
`np.sum(x)`	`np.sum(data, axis=0)`	Součet všech prvků v poli (nebo podél zvolené osy).
`np.mean(x)`	`np.mean(data)`	Průměr všech prvků v poli.
`np.prod(x)`	`np.prod(data)`	Součin všech prvků v poli.
`np.sqrt(x)`	`np.sqrt(data)`	Druhá odmocnina z každého prvku v poli.
`np.random.rand(n)`	`np.random.rand(100)`	Generování pole n náhodných čísel z rovnoměrného rozdělení na $[0, 1)$.
`np.random.uniform(a, b, n)`	`np.random.uniform(10, 50, 100)`	Generuje n náhodných **desetinných** čísel v rozsahu $[a, b)$.
`np.quantile(x, q)`	`np.quantile(x, 0.75, method='midpoint')`	Výpočet kvantilu ($q \in [0, 1]$).
`Modus`	`statistics.multimode(data)`	`Vrací modus z pole (i více prvků)`
`np.log10(x)`	`np.log10(data)`	Dekadický logaritmus (základ 10). Často se používá pro normalizaci dat.
`np.linalg.norm(x, p)`	`np.linalg.norm(x, ord=2)`	Výpočet L^1, L^2 nebo L^∞ (`np.inf`) normy.
`np.insert / np.delete`	`np.insert(A, 1, [..], axis=0)`	Vloží/Smaže řádek (`axis=0`) nebo sloupec (`axis=1`).
`stats.gmean(x)`	`stats.gmean(x)`	Geometrický průměr (knihovna Scipy).
`stats.hmean(x)`	`stats.hmean(x, weights=[...])`	Harmonický průměr (knihovna Scipy).
`np.var(x, ddof=0)`	`np.var(data, ddof=0)`	**Klasický rozptyl** s_x^2 (děleno n).
`np.var(x, ddof=1)`	`np.var(data, ddof=1)`	**Výběrový rozptyl** S^2 (děleno $n-1$).
`np.std(x, ddof=0)`	`np.std(data, ddof=0)`	Klasická směrodatná odchylka s_x.
`np.std(x, ddof=1)`	`np.std(data, ddof=1)`	Výběrová směrodatná odchylka S.
`np.ptp(x)`	`np.ptp(data)`	**Variační rozpětí** $R = x_{max} - x_{min}$.
`v_x = std / mean`	`np.std(x) / np.mean(x)`	**Variační koeficient** v_x (relativní variabilita).
`np.where(cond, x, y)`	`np.where(df['am'] == 0, 'aut', 'man')`	**Podmíněný sloupec**: Pokud platí `cond`, vlož `x`, jinak `y` (jako IF v Excelu).

5.5 Pandas: Analýza dat

Funkce	Příklad použití	Vysvětlení
`pd.read_csv(file)`	`pd.read_csv('data.csv')`	Načte data z CSV souboru a vytvoří DataFrame.
`df.describe()`	`df.describe()`	Souhrnné statistiky (průměr, std, kvartily, atd.).
`df[columns]`	`df[["A", "B", "C"]]`	Výběr určitých sloupců.
`Filtrování`	`df[df['Věk'] >= 18]`	Vybere pouze řádky splňující danou podmínku.
`df['A'].isin([list])`	`df[df['mesto'].isin(['Praha', 'Brno'])]`	Vybere řádky, kde hodnota sloupce odpovídá prvkům v seznamu.
`df.loc` vs `df.iloc`	`df.loc[0, 'Sloupec']`	Výběr dat podle **názvů** (`loc`) vs. **pozice** (`iloc`).
`df.isna().sum()`	`df.isna().sum()`	Počet chybějících (null) hodnot v tabulce.
`df.value_counts()`	`df['A'].value_counts()`	Tabulka četností pro kategorická data.
`df.groupby('A')`	`df.groupby('A').mean()`	Výpočet statistik podle kategorií ve sloupci 'A'.
`df.cumsum()`	`df['cetnost'].cumsum()`	**Kumulativní součet**: Pro výpočet kumulativních absolutních/relativních četností.
`pd.crosstab()`	`pd.crosstab(df['A'], df['B'])`	Kontingenční tabulka četností dvou kategorií.
`pd.pivot_table()`	`df.pivot_table(values='C', ...)`	Univerzální pivotní tabulka.
`df['A'].between(a, b)`	`df[df['mzda'].between(30000, 50000)]`	Filtrování hodnot v uzavřeném intervalu [a, b].

5.6 Matplotlib a Seaborn: Vizualizace

Funkce	Příklad použití	Vysvětlení
`df.boxplot()`	`df.boxplot(column='Y', by='X')`	**Boxplot (Pandas)**: Rozdělení dat do kvartilů dle skupiny.
`plt.hist(x)`	`plt.hist(data, bins=15)`	**Histogram**: Rozdělení četností. `bins` určuje intervaly.
`plt.scatter(x, y)`	`plt.scatter(x, y, alpha=0.5)`	**Bodový graf**: Závislost dvou proměnných.
`plt.title(s)`	`plt.title("Název", fontsize=16)`	Nastaví hlavní nadpis grafu.
`plt.xlabel / ylabel`	`plt.xlabel("Čas [s]")`	Nastaví popisky os x a y.
`plt.legend()`	`plt.legend(loc='upper right')`	Zobrazí legendu (nutný parametr `label` u dat).
`plt.savefig()`	`plt.savefig("graf.pdf")`	Uloží graf na disk.

5.7 Náhodné veličiny a rozdělení

`Importy:`

```
from scipy.stats import norm, binom, poisson, hypergeom, t
```

Normální rozdělení (`norm`)

Spojité rozdělení pro modelování např. času, délky či chyby měření.
Parametry: `x` = zkoumaná hodnota (hranice), `mu` (`loc`) = střední hodnota, `sigma` (`scale`) = směrodatná odchylka, `q` = zadaná pravděpodobnost (pro hledání kvantilu).

Funkce	Příklad použití	Vysvětlení
`norm.cdf(x, mu, sigma)`	`norm.cdf(16, loc=20, scale=4)`	`MÉNĚ NEŽ`: Šance, že hodnota bude maximálně x.
`norm.sf(x, mu, sigma)`	`norm.sf(20, loc=20, scale=4)`	`VÍCE NEŽ`: Ekvivalent `1 - cdf`. Šance, že hodnota překročí x.
`norm.cdf(b) - norm.cdf(a)`	`norm.cdf(28, 20, 4) - norm.cdf(12, 20, 4)`	`MEZI`: Šance, že se hodnota trefí do intervalu (a, b).
`norm.ppf(q, mu, sigma)`	`norm.ppf(0.4, loc=20, scale=4)`	`Hledání kvantilu`: Najde hodnotu x, pro kterou platí $P(X < x) = q$.

Binomické rozdělení (`binom`)

Diskrétní rozdělení. Počet úspěchů v pevně daném počtu nezávislých pokusů.
Aproximace: Pokud je počet pokusů $n \geq 30$ a pravděpodobnost úspěchu $p \leq 0.05$, blíží se Poissonovu rozdělení.
Parametry: `k` = zkoumaný počet úspěchů, `n` = celkový počet pokusů, `p` = pravděpodobnost úspěchu.

Funkce	Příklad použití	Vysvětlení
`binom.pmf(k, n, p)`	`binom.pmf(4, n=10, p=1/6)`	`Pravděpodobnost PŘESNĚ`: Šance, že úspěch nastane přesně k-krát.
`binom.cdf(k, n, p)`	`binom.cdf(2, n=10, p=1/6)`	`Pravděpodobnost NEJVÝŠE`: Šance, že úspěchů bude 0 až k (včetně).
`1 - binom.cdf(k, n, p)`	`1 - binom.cdf(2, n=10, p=1/6)`	`Pravděpodobnost VÍCE NEŽ`: Šance, že úspěchů bude striktně více než k.

Poissonovo rozdělení (`poisson`)

Diskrétní rozdělení. Počet výskytů události za jednotku času nebo prostoru, když známe průměr.
Parametry: `k` = zkoumaný počet událostí, `mu` = průměrný počet událostí (λ).

Funkce	Příklad použití	Vysvětlení
`poisson.pmf(k, mu)`	`poisson.pmf(2, mu=0.4)`	`Pravděpodobnost PŘESNĚ`: Šance, že nastanou přesně k události při průměru μ.
`poisson.cdf(k, mu)`	`poisson.cdf(2, mu=0.4)`	`Pravděpodobnost NEJVÝŠE`: Šance, že událostí bude 0 až k (včetně).
`1 - poisson.cdf(k, mu)`	`1 - poisson.cdf(2, mu=0.4)`	`Pravděpodobnost VÍCE NEŽ`: Šance na více než k událostí.

Hypergeometrické rozdělení (`hypergeom`)

Diskrétní rozdělení. Výběr **bez vracení** z konečné populace (např. zmetky v zásilce).
Aproximace: Pokud $N/M \leq 0.05$, výběr bez vracení se chová téměř jako výběr s vracením (Binomické).
Parametry: `k` = hledané prvky ve výběru, `M` = populace, `n` = hledané prvky v populaci, `N` = velikost výběru.

Funkce	Příklad použití	Vysvětlení
`hypergeom.pmf(k, M, n, N)`	`hypergeom.pmf(0, 200, 10, 5)`	`Pravděpodobnost PŘESNĚ`: Šance na k zmetků ve výběru N z M, kde je celkem n zmetků.

Studentovo t-rozdělení (`t`)

Spojité rozdělení. Používá se pro konstrukci intervalů spolehlivosti a testování (neznáme-li rozptyl populace).
Parametry: `df` = stupně volnosti, `q` = hladina (pravděpodobnost).

Funkce	Příklad použití	Vysvětlení
`t.pdf(x, df)`	`t.pdf(x, df=15)`	`Hustota pravděpodobnosti`: Hodnota křivky pro bod x.
`t.ppf(q, df)`	`t.ppf(1 - 0.05/2, df=19)`	`Kritická hodnota`: Kvantil pro t-rozdělení (pro meze intervalu spolehlivosti).

5.8 Intervaly spolehlivosti a velikost výběru

Interval pro průměr (μ)

Kdy použít: Pro odhad průměrné hodnoty měřitelného znaku (váha, čas, délka).

- **Normální rozdělení (`norm`):** Pokud známe rozptyl populace σ^2 nebo je výběr velký ($n \geq 30$).
- **Studentovo t-rozdělení (`t`):** Pokud rozptyl populace neznáme a výběr je malý ($n < 30$).
- **Typy kvantilů:** Pro **oboustranný** interval používáme $1 - \alpha/2$, pro **jednostranný** (jen horní nebo dolní mez) používáme $1 - \alpha$.

Parametry: `x_bar` (výběrový průměr), `s` (výběrová směr. odchylka), `n` (rozsah výběru), `alpha` (α, hladina významnosti).

Funkce	Příklad použití	Vysvětlení
`Kritická hodnota`	`crit = t.ppf(1 - alpha/2, df=n-1)`	Kvantil pro t-interval (neznámé σ). Pro velké n lze nahradit `norm.ppf`.
`Mezní chyba (Mean)`	`err = crit * (s / np.sqrt(n))`	Výpočet odchylky pro průměr. `s` je výběrová směrodatná odchylka.

Interval pro podíl (π)

Kdy použít: Pro odhad procentuálního zastoupení (např. podíl zmetků, preference voličů).

- Vždy využíváme **normální rozdělení** (Z-kvantil).
- **Typy kvantilů:** Obdobně jako u průměru platí $1 - \alpha/2$ pro oboustranný a $1 - \alpha$ pro jednostranný odhad.

Parametry: `p` (výběrová relativní četnost), `n` (celkový počet testovaných jednotek).

Funkce	Příklad použití	Vysvětlení
`Kritická hodnota`	`z_crit = norm.ppf(1 - alpha / 2)`	Pro podíl se vždy používá normální rozdělení (Z-kvantil).
`Mezní chyba (Prop)`	`err = z_crit * np.sqrt(p * (1-p) / n)`	Výpočet odchylky pro proporci p.
`Meze intervalu`	`lower, upper = p - err, p + err`	Skutečný parametr leží v intervalu s pravděpodobností $1 - \alpha$.

Potřebná velikost výběru (n)

Kdy použít: Hledáme, kolik jednotek musíme vybrat (n), aby se náš odhad nemýlil o více než stanovenou chybu Δ (`delta`).

- **Zaokrouhlování:** Protože n musí být celé číslo, výsledek se **vždy zaokrouhluje nahoru** (funkce `math.ceil`), jinak by chyba byla větší než povolená.

Parametry: `delta` (Δ, požadovaná přesnost), `sigma` (předpokládaná směr. odchylka).

Funkce	Příklad použití	Vysvětlení
`Minimální n (Mean)`	`n = math.ceil((z_crit * sigma / delta)**2)`	Pro průměr. Δ je cílová přesnost. Výsledek **vždy** zaokrouhli nahoru.
`Minimální n (Prop)`	`n = math.ceil(p*(1-p) * (z_crit/delta)**2)`	Pro podíl. Používá se pro plánování reprezentativního výzkumu.

5.9 Testování hypotéz

- **Oboustranný test:** $H_1 : \mu \neq \mu_0$. Zamítáme, pokud statistika $|U| \geq$ kvantil$(1 - \alpha/2)$.
- **Jednostranný test:** $H_1 : \mu > \mu_0$ (pravý) nebo $\mu < \mu_0$ (levý). Zamítáme při překročení kvantilu $(1 - \alpha)$.

Funkce	Příklad použití	Vysvětlení
`Testová statistika`	`u = (x_bar - mu0) / (s / np.sqrt(n))`	Vzorec pro průměr. Porovnáváme naměřený průměr s předpokladem μ_0.
`p-hodnota (oboustr.)`	`2 * (1 - norm.cdf(abs(u)))`	Pokud je $p < \alpha$, nulovou hypotézu zamítáme.