**VYSOKÁ ŠKOLA EKONOMICKÁ V PRAZE**
FAKULTA INFORMATIKY A STATISTIKY

# STATISTIKA PRO INFORMATIKY

**VZORCE PRO 4ST204**

# Obsah


**1 Popisná Statistika** **2**
1.1 Četnosti . . . 2
1.1.1 Absolutní četnost . . . 2
1.1.2 Součet absolutních četností . . . 2
1.1.3 Relativní Četnost . . . 2
1.1.4 Součet relativních četností . . . 2
1.1.5 Sturgesovo pravidlo . . . 2
1.2 Charakteristiky polohy . . . 2
1.2.1 Aritmetický průměr . . . 2
1.2.2 Vážený aritmetický průměr . . . 3
1.2.3 Harmonický průměr . . . 3
1.2.4 Geometrický průměr . . . 3
1.2.5 Vztah mezi průměry . . . 3
1.2.6 Modus . . . 3
1.2.7 Medián a Kvantily . . . 4
1.3 Charakteristiky variability . . . 4
1.3.1 Variační rozpětí a IQR . . . 4
1.3.2 Rozptyl statistického souboru (Populační) . . . 4
1.3.3 Výběrový rozptyl . . . 4
1.3.4 Směrodatná odchylka . . . 5
1.3.5 Variační koeficient . . . 5
1.3.6 Rozklad rozptylu . . . 5

**2 Teorie pravděpodobnosti** **5**
2.1 Počet pravděpodobnosti . . . 5
2.1.1 Klasická definice pravděpodobnosti . . . 5
2.1.2 Průnik a Sjednocení . . . 5
2.2 Náhodné veličiny . . . 5
2.2.1 Diskrétní náhodná veličina . . . 5
2.2.2 Spojitá náhodná veličina . . . 6

**3 Kombinatorika a Metriky** **6**
3.1 Kombinatorika . . . 6
3.2 $L^p$ Normy (Vzdálenosti a penalizace) . . . 6

**4 Práce s daty v Pythonu (Cheatsheet)** **6**
4.1 Užitečné knihovny a základy . . . 6
4.2 NumPy: Statistika a Matice . . . 7
4.3 Pandas: Analýza dat . . . 7
4.4 Matplotlib a Seaborn: Vizualizace . . . 7

# 1 Popisná Statistika

## 1.1 Četnosti

### 1.1.1 Absolutní četnost

Absolutní četnost $i$-té hodnoty je počet výskytů dané hodnoty ve výběru.

$$n_i$$

kde $n_i$ je počet výskytů $i$-té hodnoty ve výběru.

### 1.1.2 Součet absolutních četností

Součet absolutních četností všech hodnot (nebo tříd) ve výběru se rovná celkovému počtu pozorování.

$$\sum_{i=1}^{k} n_i = n$$

kde $k$ je počet různých hodnot nebo tříd, $n_i$ je absolutní četnost a $n$ je celkový počet pozorování.

### 1.1.3 Relativní Četnost

Relativní četnost $i$-té hodnoty ve výběru je definována jako podíl absolutní četnosti dané hodnoty a celkového počtu pozorování.

$$p_i = \frac{n_i}{n}$$

### 1.1.4 Součet relativních četností

Součet relativních četností všech hodnot (nebo tříd) ve výběru je roven jedné.

$$\sum_{i=1}^{k} p_i = 1$$

### 1.1.5 Sturgesovo pravidlo

Doporučený počet intervalů (tříd) $k$ pro tvorbu histogramu a rozdělení četností:

$$k = 1 + \log_2 n$$

## 1.2 Charakteristiky polohy

### 1.2.1 Aritmetický průměr

Aritmetický průměr (výběrový průměr) je definován jako součet všech hodnot statistického souboru dělený počtem pozorování. Klasický průměr pro data bez extrémních hodnot.

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

**Implementace v R a Pythonu**

| **Funkce / Operace** | **Příklad použití** | **Vysvětlení** |
|---|---|---|
| `mean(x)` (R) | `mean(c(1,2,3))` | Vrací aritmetický průměr. |
| `np.mean(x)` (Python) | `np.mean([1,2,3])` | Vrací aritmetický průměr pole. |

### 1.2.2 Vážený aritmetický průměr

Pokud jsou data zadána pomocí četnostní tabulky, aritmetický průměr lze vypočítat jako vážený průměr hodnot.

$$\bar{x} = \frac{\sum_{i=1}^{k} x_i n_i}{\sum_{i=1}^{k} n_i} = \sum_{i=1}^{k} x_i p_i$$

**Implementace v R a Pythonu**

| Funkce / Operace | Příklad použití | Vysvětlení |
|---|---|---|
| `weighted.mean(x, w)` (R) | `weighted.mean(x, w)` | Vážený průměr s váhami `w`. |
| `np.average(x, weights=w)` (Py) | `np.average(x, weights=w)` | Vážený průměr pomocí NumPy. |

### 1.2.3 Harmonický průměr

Používá se pro poměrové veličiny (např. rychlost v km/h), kde je konstantní čitatel (např. ujetá vzdálenost).

$$\bar{x}_H = \frac{n}{\sum_{i=1}^{n} \frac{1}{x_i}}$$

**Implementace v R a Pythonu**

| Funkce / Operace | Příklad použití | Vysvětlení |
|---|---|---|
| `n / sum(1/x)` (R) | `length(x) / sum(1/x)` | Harmonický průměr v R. |
| `stats.hmean(x)` (Python) | `scipy.stats.hmean(x)` | Z knihovny `scipy.stats`. |

### 1.2.4 Geometrický průměr

Geometrický průměr se využívá pro multiplikativní data (tempa růstu, úroky).

$$\bar{x}_G = \sqrt[n]{\prod_{i=1}^{n} x_i}$$

**Implementace v R a Pythonu**

| Funkce / Operace | Příklad použití | Vysvětlení |
|---|---|---|
| `exp(mean(log(x)))` (R) | `exp(mean(log(x)))` | Geometrický průměr v R. |
| `stats.gmean(x)` (Python) | `scipy.stats.gmean(x)` | Z knihovny `scipy.stats`. |

### 1.2.5 Vztah mezi průměry

$$\bar{x}_H \leq \bar{x}_G \leq \bar{x}$$

### 1.2.6 Modus

Nejpravděpodobnější (nejčetnější) hodnota ve statistickém souboru. Označuje se typicky $\hat{x}$. V Pythonu lze využít `statistics.multimode(x)`.

### 1.2.7 Medián a Kvantily

Kvantily rozdělují uspořádaný statistický soubor na části se stejným počtem pozorování. $q$-kvantil je hodnota $x_q$, pro kterou platí $P(X \leq x_q) = q$. Medián (50% kvantil) rozděluje uspořádaný statistický soubor na dvě stejně početné části.

Pozice $p$-tého kvantilu: $z_p = n \cdot p$. Hodnota $\tilde{x}_p$ se určí z uspořádaného souboru $x_{(1)} \leq \cdots \leq x_{(n)}$:

$$\tilde{x}_p = \begin{cases} x_{(\lceil z_p \rceil)} & \text{pokud } z_p \notin \mathbb{Z} \\ \frac{x_{(z_p)} + x_{(z_p+1)}}{2} & \text{pokud } z_p \in \mathbb{Z} \end{cases}$$

**Implementace v R a Pythonu**

| Funkce / Operace | Příklad použití | Vysvětlení |
|---|---|---|
| `median(x)` (R) | `median(x)` | Vrací medián. |
| `np.median(x)` (Python) | `np.median(x)` | Vrací medián. |
| `quantile(x, probs=q)` (R) | `quantile(x, probs=c(0.25, 0.75))` | Vrací kvartily. |
| `np.quantile(x, q)` (Python) | `np.quantile(x, [0.25, 0.75])` | Vrací kvartily. |

## 1.3 Charakteristiky variability

### 1.3.1 Variační rozpětí a IQR

Variační rozpětí ($R$) je rozdíl mezi maximální a minimální hodnotou: $R = x_{\max} - x_{\min}$.
Interkvartilové rozpětí ($IQR$) je rozdíl mezi třetím a prvním kvartilem: $IQR = Q_3 - Q_1$.

### 1.3.2 Rozptyl statistického souboru (Populační)

Rozptyl vyjadřuje průměrnou kvadratickou odchylku hodnot od aritmetického průměru.

$$s_x^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \frac{\sum_{i=1}^{n} x_i^2}{n} - \bar{x}^2$$

**Implementace v R a Pythonu**

| Funkce / Operace | Příklad použití | Vysvětlení |
|---|---|---|
| Nevýběrový rozptyl (R) | `mean((x - mean(x))^2)` | V R neexistuje přímá zkratka pro populaci. |
| `np.var(x, ddof=0)` (Py) | `np.var(x)` | Defaultní chování v NumPy. |

### 1.3.3 Výběrový rozptyl

Výběrový rozptyl je nezkreslený odhad rozptylu populace (Besselova korekce).

$$S^2 = \frac{n}{n-1}s_x^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

**Implementace v R a Pythonu**

| Funkce / Operace | Příklad použití | Vysvětlení |
|---|---|---|
| `var(x)` (R) | `var(x)` | Vrací výběrový rozptyl (dělí se $n-1$). |
| `np.var(x, ddof=1)` (Py) | `np.var(x, ddof=1)` | Musí se specifikovat `ddof=1`. |

### 1.3.4 Směrodatná odchylka

Odmocnina z rozptylu, udává variabilitu v původních jednotkách. Nevýběrová $s_x = \sqrt{s_x^2}$, výběrová $S = \sqrt{S^2}$. V Pythonu `np.std(x)` (populační) a `np.std(x, ddof=1)` (výběrová). V R slouží `sd(x)` pro výběrovou.

### 1.3.5 Variační koeficient

Relativní míra variability (bezrozměrná), slouží k porovnání souborů s různými průměry.

$$v_x = \frac{s_x}{\bar{x}}$$

### 1.3.6 Rozklad rozptylu

Pokud máme data rozdělená do $k$ skupin, můžeme celkový rozptyl rozložit na vnitroskupinový a meziskupinový:

$$s_x^2 = \underbrace{\bar{s}_i^2}_{\text{vnitroskupinový}} + \underbrace{s_{\bar{x}}^2}_{\text{meziskupinový}}$$

- **Vnitroskupinový rozptyl ($\bar{s}_i^2$):** Průměr rozptylů jednotlivých skupin. $\bar{s}_i^2 = \frac{\sum_{i=1}^k s_i^2 n_i}{\sum_{i=1}^k n_i}$
- **Meziskupinový rozptyl ($s_{\bar{x}}^2$):** Rozptyl skupinových průměrů od celkového průměru. $s_{\bar{x}}^2 = \frac{\sum_{i=1}^k (\bar{x}_i - \bar{x})^2 n_i}{\sum_{i=1}^k n_i}$

# 2 Teorie pravděpodobnosti

## 2.1 Počet pravděpodobnosti

### 2.1.1 Klasická definice pravděpodobnosti

Pravděpodobnost jevu $A$ je podíl počtu příznivých výsledků $m$ a celkového počtu stejně pravděpodobných výsledků $n$: $P(A) = \frac{m}{n}$. Komplementární jev: $P(\overline{A}) = 1 - P(A)$.

### 2.1.2 Průnik a Sjednocení

- **Horní odhad pravděpodobnosti průniku:** $P(A \cap B) \leq \min(P(A), P(B))$
- **Průnik nezávislých jevů:** $P(A \cap B) = P(A)P(B)$
- **Sjednocení dvou jevů:** $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
- **Sjednocení neslučitelných jevů:** $P(A \cup B) = P(A) + P(B)$

## 2.2 Náhodné veličiny

### 2.2.1 Diskrétní náhodná veličina

Pravděpodobnostní funkce: $P(x) = P(X = x)$. Distribuční funkce: $F(x) = P(X \leq x) = \sum_{x_j \leq x} P(x_j)$.

- **Pravděpodobnost intervalu:** $P(x_1 < X \leq x_2) = F(x_2) - F(x_1)$
- **Střední hodnota:** $E(X) = \sum_x x\, P(x)$
- **Rozptyl:** $D(X) = E(X^2) - [E(X)]^2 = \sum_x x^2 P(x) - (\sum_x x P(x))^2$

### 2.2.2 Spojitá náhodná veličina

Hustota pravděpodobnosti vyjadřuje rychlost změny distribuční funkce: $f(x) = F'(x)$. Normalizační podmínka: $\int_{-\infty}^{\infty} f(x)\,dx = 1$. Distribuční funkce: $F(x) = \int_{-\infty}^{x} f(t)\,dt$.

- **Pravděpodobnost intervalu:** $P(x_1 < X \leq x_2) = \int_{x_1}^{x_2} f(x)\,dx = F(x_2) - F(x_1)$
- **Střední hodnota:** $E(X) = \int_{-\infty}^{\infty} x f(x)\,dx$
- **Rozptyl:** $D(X) = \int_{-\infty}^{\infty} x^2 f(x)\,dx - \left[\int_{-\infty}^{\infty} x f(x)\,dx\right]^2$

Směrodatná odchylka je i zde odmocnina z rozptylu: $\sigma = \sqrt{D(X)}$.

# 3 Kombinatorika a Metriky

## 3.1 Kombinatorika

Mějme množinu $n$ prvků, ze které vybíráme $k$ prvků.

- **Permutace (Pořadí všech $n$ prvků):** Bez opakování: $P(n) = n!$
  S opakováním: $P'_{k_1,\ldots,k_m}(n) = \frac{n!}{k_1!\cdot\ldots\cdot k_m!}$
- **Variace (Výběr $k$ prvků z $n$, záleží na pořadí):** Bez opakování: $V(k,n) = \frac{n!}{(n-k)!}$
  S opakováním: $V'(k,n) = n^k$
- **Kombinace (Výběr $k$ prvků z $n$, nezáleží na pořadí):** Bez opakování: $K(k,n) = \binom{n}{k} = \frac{n!}{k!(n-k)!}$
  S opakováním: $K'(k,n) = \binom{n+k-1}{k} = \frac{(n+k-1)!}{k!(n-1)!}$

## 3.2 $L^p$ Normy (Vzdálenosti a penalizace)

Obecně: $\|x\|_p = (\sum |x_i|^p)^{1/p}$. Klíčové pro metriky chyb a regularizaci.

- $L^1$ **(Manhattan):** $\|x\|_1 = \sum |x_i|$. Využití: Lasso regrese.
- $L^2$ **(Euklid):** $\|x\|_2 = \sqrt{\sum x_i^2}$. Využití: Ridge regrese (metoda nejmenších čtverců).
- $L^\infty$ **(Max):** $\|x\|_\infty = \max(|x_i|)$. Reprezentuje nejhorší možnou chybu.

# 4 Práce s daty v Pythonu (Cheatsheet)

## 4.1 Užitečné knihovny a základy

| Funkce / Operace | Příklad použití | Vysvětlení |
|---|---|---|
| `import numpy as np` | `np.array([...])` | Matice, vektory a rychlé matematické operace. |
| `import pandas as pd` | `pd.DataFrame(matice)` | Analýza tabulek a práce s CSV. |
| `import matplotlib.pyplot as plt` | `plt.hist(data)` | Tvorba grafů a vizualizace dat. |
| `math.comb(n, k)` | `math.comb(10, 3)` | Kombinační číslo (výběr $k$ z $n$). |
| `List Comprehension` | `[x**2 for x in range(5)]` | Dynamické generování pole pomocí cyklu. |

## 4.2 NumPy: Statistika a Matice

| Funkce / Operace | Příklad použití | Vysvětlení |
|---|---|---|
| `np.random.uniform(a,b,n)` | `np.random.uniform(10,50,100)` | Generuje náhodná desetinná čísla z $[a, b)$. |
| `np.linalg.norm(x, p)` | `np.linalg.norm(x, ord=2)` | Výpočet $L^1, L^2$ nebo $L^\infty$ normy. |
| `np.where(cond, x, y)` | `np.where(df['a']==0, 1, 2)` | Pokud platí `cond`, vlož `x`, jinak `y` (jako IF v Excelu). |

## 4.3 Pandas: Analýza dat

| Funkce / Operace | Příklad použití | Vysvětlení |
|---|---|---|
| `pd.read_csv(file)` | `pd.read_csv('data.csv')` | Načte data z CSV souboru a vytvoří DataFrame. |
| `df.describe()` | `df.describe()` | Souhrnné statistiky (průměr, std, kvartily, atd.). |
| `df.loc` vs `df.iloc` | `df.loc[0, 'Sloupec']` | Výběr dat podle **názvů** (`loc`) vs. **pozice** (`iloc`). |
| `df.value_counts()` | `df['A'].value_counts()` | Tabulka četností pro kategorická data. |
| `df.groupby('A')` | `df.groupby('A').mean()` | Výpočet statistik podle kategorií ve sloupci 'A'. |
| `pd.crosstab()` | `pd.crosstab(df['A'], df['B'])` | Kontingenční tabulka četností dvou kategorií. |
| `pd.pivot_table()` | `df.pivot_table(values='C', ...)` | Univerzální pivotní tabulka. |

## 4.4 Matplotlib a Seaborn: Vizualizace

| Funkce / Operace | Příklad použití | Vysvětlení |
|---|---|---|
| `df.boxplot()` | `df.boxplot(column='Y', by='X')` | **Boxplot (Pandas)**: Rozdělení dat do kvartilů dle skupiny. |
| `plt.hist(x)` | `plt.hist(data, bins=15)` | **Histogram**: Rozdělení četností. `bins` určuje intervaly. |
| `plt.scatter(x, y)` | `plt.scatter(x, y, alpha=0.5)` | **Bodový graf**: Závislost dvou proměnných. |
| `plt.title(s)` | `plt.title("Název", fontsize=16)` | Nastaví hlavní nadpis grafu. |
| `plt.xlabel / ylabel` | `plt.xlabel("Čas [s]")` | Nastaví popisky os $x$ a $y$. |
| `plt.legend()` | `plt.legend(loc='upper right')` | Zobrazí legendu (nutný parametr `label` u dat). |
| `plt.savefig()` | `plt.savefig("graf.pdf")` | Uloží graf na disk. |