Vzorcovník – 4ST204 Statistika pro informatiky

Obsah

1 Popisná Statistika **2**

1.1 Četnosti . . . 2

1.1.1 Absolutní četnost . . . 2

1.1.2 Součet absolutních četností . . . 2

1.1.3 Relativní Četnost . . . 2

1.1.4 Součet relativních četností . . . 2

1.2 Charakteristiky polohy . . . 3

1.2.1 Aritmetický průměr . . . 3

1.2.2 Vážený aritmetický průměr (z četnostní tabulky) . . . 3

1.2.3 Aritmetický průměr pomocí relativních četností . . . 4

1.2.4 Harmonický průměr . . . 5

1.2.5 Geometrický průměr . . . 5

1.2.6 Vztah mezi průměry . . . 6

1.2.7 Medián . . . 6

1.2.8 Kvantily a kvartily . . . 7

1.2.9 Interkvartilové rozpětí (IQR) . . . 8

1.3 Charakteristiky variability . . . 9

1.3.1 Variační rozpětí . . . 9

1.3.2 Rozptyl statistického souboru . . . 10

1.3.3 Výběrový rozptyl . . . 11

1.3.4 Směrodatná odchylka statistického souboru . . . 11

1.3.5 Výběrová směrodatná odchylka . . . 12

1.3.6 Variační koeficient . . . 12

1 Popisná Statistika

1.1 Četnosti

1.1.1 Absolutní četnost

Absolutní četnost i-té hodnoty je počet výskytů dané hodnoty ve výběru.

$$n_i$$

kde

- n_i je počet výskytů i-té hodnoty ve výběru.

1.1.2 Součet absolutních četností

Součet absolutních četností všech hodnot (nebo tříd) ve výběru se rovná celkovému počtu pozorování.

$$\sum_{i=1}^{k} n_i = n$$

kde

- $\sum$ je sumační znak (značí sčítání),
- i je index hodnoty nebo třídy,
- k je počet různých hodnot nebo tříd,
- n_i je absolutní četnost i-té hodnoty (nebo třídy),
- n je celkový počet pozorování.

1.1.3 Relativní Četnost

Relativní četnost i-té hodnoty ve výběru je definována jako podíl absolutní četnosti dané hodnoty a celkového počtu pozorování,

$$p_i = \frac{n_i}{n}$$

kde

- p_i je relativní četnost i-té hodnoty,
- n_i je absolutní četnost i-té hodnoty (kolikrát se hodnota vyskytla),
- n je celkový počet pozorování v souboru.

1.1.4 Součet relativních četností

Součet relativních četností všech hodnot (nebo tříd) ve výběru je roven jedné.

$$\sum_{i=1}^{k} p_i = 1$$

kde

- $\sum$ je sumační znak (značí sčítání),
- i je index hodnoty nebo třídy,
- k je počet různých hodnot nebo tříd,
- p_i je relativní četnost i-té hodnoty (nebo třídy).

1.2 Charakteristiky polohy

1.2.1 Aritmetický průměr

Aritmetický průměr (výběrový průměr) je definován jako součet všech hodnot statistického souboru dělený počtem pozorování.

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

kde

- $\bar{x}$ je aritmetický průměr,
- $\sum$ je sumační znak (součet hodnot),
- x_i je i-tá hodnota statistického souboru,
- i je index hodnoty,
- n je počet pozorování.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`mean(x)`	`x <- c(1,2,3,4,5)` `mean(x)`	Vrací aritmetický průměr hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.mean(x)`	`import numpy as np`
	`x = np.array([1,2,3,4,5])`
	`np.mean(x)`
		Vrací aritmetický průměr pole pomocí knihovny `numpy`.

1.2.2 Vážený aritmetický průměr (z četnostní tabulky)

Pokud jsou data zadána pomocí četnostní tabulky, aritmetický průměr lze vypočítat jako vážený průměr hodnot.

$$\bar{x} = \frac{\sum_{i=1}^{k} x_i n_i}{\sum_{i=1}^{k} n_i}$$

kde

- $\bar{x}$ je aritmetický průměr,
- $\sum$ je sumační znak (součet),
- x_i je i-tá hodnota znaku,
- n_i je absolutní četnost i-té hodnoty,
- k je počet různých hodnot nebo tříd,
- $\sum_{i=1}^{k} n_i$ je celkový počet pozorování.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`weighted.mean(x, w)`	`x <- c(1,2,3)`
	`w <- c(2,3,5)`
	
	`weighted.mean(x, w)`
		Vrací vážený průměr hodnot ve vektoru `x` s váhami `w`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.average(x, weights=w)`	`import numpy as np`
	
	`x = np.array([1,2,3])`
	`w = np.array([2,3,5])`
	
	`np.average(x, weights=w)`
		Vrací vážený průměr hodnot ve vektoru `x` s váhami `w`.

1.2.3 Aritmetický průměr pomocí relativních četností

Pokud jsou data vyjádřena pomocí relativních četností, lze aritmetický průměr vypočítat jako vážený součet hodnot.

$$\bar{x} = \sum_{i=1}^{k} x_i p_i$$

kde

- $\bar{x}$ je aritmetický průměr,
- $\sum$ je sumační znak (součet),
- x_i je i-tá hodnota znaku,
- p_i je relativní četnost i-té hodnoty,
- i je index hodnoty,
- k je počet různých hodnot nebo tříd.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`sum(x * p)`	`x <- c(1,2,3)`
	`p <- c(0.2,0.3,0.5)`
	
	`sum(x * p)`
		Vrací aritmetický průměr vypočtený pomocí relativních četností.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.sum(x * p)`	`import numpy as np`
	
	`x = np.array([1,2,3])`
	`p = np.array([0.2,0.3,0.5])`
	
	`np.sum(x * p)`
		Vrací aritmetický průměr vypočtený pomocí relativních četností pomocí knihovny `numpy`.

1.2.4 Harmonický průměr

Harmonický průměr je definován jako podíl počtu pozorování a součtu převrácených hodnot jednotlivých pozorování.

$$\bar{x}_H = \frac{n}{\sum_{i=1}^{n} \frac{1}{x_i}}$$

kde

- $\bar{x}_H$ je harmonický průměr,
- n je počet pozorování,
- $\sum$ je sumační znak (součet),
- x_i je i-tá hodnota statistického souboru,
- $\frac{1}{x_i}$ je převrácená hodnota i-tého pozorování.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`n / sum(1/x)`	`x <- c(1,2,4,5)`
	`n <- length(x)`
	
	`n / sum(1/x)`
		Vrací harmonický průměr hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`len(x) / np.sum(1/x)`	`import numpy as np`
	
	`x = np.array([1,2,4,5])`
	`len(x) / np.sum(1/x)`
		Vrací harmonický průměr hodnot ve vektoru `x`.

1.2.5 Geometrický průměr

Geometrický průměr je definován jako n-tá odmocnina součinu všech hodnot statistického souboru.

$$\bar{x}_G = \sqrt[n]{\prod_{i=1}^{n} x_i} = \sqrt[n]{x_1 \cdot x_2 \cdots x_n}$$

kde

- $\bar{x}_G$ je geometrický průměr,
- $\prod$ je znak pro součin (násobení všech hodnot),
- x_i je i-tá hodnota statistického souboru,
- i je index hodnoty,
- n je počet pozorování,
- $\sqrt[n]{\cdot}$ značí n-tou odmocninu.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`exp(mean(log(x)))`	`x <- c(1,2,3,4)` `exp(mean(log(x)))`	Vrací geometrický průměr hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.exp(np.mean (np.log(x)))`	`import numpy as np`
	`x = np.array([1,2,3,4])`
	`np.exp(np.mean(np.log(x)))`
		Vrací geometrický průměr hodnot ve vektoru `x`.

1.2.6 Vztah mezi průměry

$$\bar{x}_H \leq \bar{x}_G \leq \bar{x}$$

kde

- $\bar{x}_H$ je harmonický průměr,
- $\bar{x}_G$ je geometrický průměr,
- $\bar{x}$ je aritmetický průměr.

1.2.7 Medián

Medián je hodnota, která rozděluje uspořádaný statistický soubor na dvě stejně početné části. Medián také vyjadřuje 50% kvantil.

$$\tilde{x} = \begin{cases} x_{\left(\frac{n+1}{2}\right)}, & \text{je-li } n \text{ liché,} \\ \frac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2}, & \text{je-li } n \text{ sudé.} \end{cases}$$

kde

- $\tilde{x}$ je medián,
- $x_{(i)}$ je i-tá hodnota v uspořádaném statistickém souboru,
- n je počet pozorování.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`median(x)`	`x <- c(1,3,2,5,4)` `median(x)`	Vrací medián hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.median(x)`	`import numpy as np`
	
	`x = np.array([1,3,2,5,4])`
	`np.median(x)`
		Vrací medián hodnot ve vektoru `x`.

1.2.8 Kvantily a kvartily

Kvantily rozdělují uspořádaný statistický soubor na části se stejným počtem pozorování.

q-kvantil je hodnota x_q, pro kterou platí

$$P(X \leq x_q) = q$$

kde

- x_q je q-kvantil,
- $q \in (0, 1)$ je pořadí kvantilu,
- $P(X \leq x_q)$ je pravděpodobnost, že náhodná veličina nabývá hodnot menších nebo rovných x_q.

Speciálním případem kvantilů jsou kvartily, které rozdělují data na čtyři stejně velké části.

$$Q_1 = x_{0.25}, \qquad Q_2 = x_{0.5}, \qquad Q_3 = x_{0.75}$$

kde

- Q_1 je první kvartil (25% dat je menších),
- Q_2 je druhý kvartil, který odpovídá mediánu,
- Q_3 je třetí kvartil (75% dat je menších).

Implementace v R

Funkce	Příklad použití	Vysvětlení

`quantile(x)`	`x <- c(1,2,3,4,5,6,7,8)`
	
	`quantile(x)`
		Vrací kvantily datového vektoru.

`quantile(x, probs=c(0.25, 0.5, 0.75))`	`x <- c(1,2,3,4,5,6,7,8)`
	
	`quantile(x, probs=c`
	`(0.25,0.5,0.75))`
		Vrací první, druhý a třetí kvartil.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.quantile(x,q)`	`import numpy as np`
	
	`x = np.array`
	`([1,2,3,4,5,6,7,8])`
	
	`np.quantile(x,0.5)`
		Vrací q-kvantil pole.

`np.quantile(x, [0.25,0.5,0.75])`	`import numpy as np`
	
	`x = np.array`
	`([1,2,3,4,5,6,7,8])`
	
	`np.quantile(x`
	`,[0.25,0.5,0.75])`
		Vrací první, druhý a třetí kvartil.

1.2.9 Interkvartilové rozpětí (IQR)

Interkvartilové rozpětí (IQR) je rozdíl mezi třetím a prvním kvartilem. Vyjadřuje rozptyl prostředních 50 % dat.

$$IQR = Q_3 - Q_1$$

kde

- IQR je interkvartilové rozpětí,
- Q_1 je první kvartil,
- Q_3 je třetí kvartil.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`IQR(x)`	`x <- c(1,2,3,4,5,6,7,8)`
	
	`IQR(x)`
		Vrací interkvartilové rozpětí datového vektoru.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.quantile(x,0.75)`
`-`
`np.quantile(x,0.25)`
	`import numpy as np`
	
	`x = np.array`
	`([1,2,3,4,5,6,7,8])`
	
	`np.quantile(x,0.75) - np.`
	`quantile(x,0.25)`
		Vrací interkvartilové rozpětí pole.

1.3 Charakteristiky variability

1.3.1 Variační rozpětí

Variační rozpětí je rozdíl mezi maximální a minimální hodnotou statistického souboru.

$$R = x_{\max} - x_{\min}$$

kde

- R je variační rozpětí,
- $x_{\max}$ je maximální hodnota v souboru,
- $x_{\min}$ je minimální hodnota v souboru.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`max(x) - min(x)`	`x <- c(3,7,2,9,5)`
	
	`max(x) - min(x)`
		Vrací variační rozpětí hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.max(x) - np.min(x)`	`import numpy as np`
	
	`x = np.array([3,7,2,9,5])`
	
	`np.max(x) - np.min(x)`
		Vrací variační rozpětí hodnot ve vektoru `x`.

1.3.2 Rozptyl statistického souboru

Rozptyl vyjadřuje průměrnou kvadratickou odchylku hodnot od aritmetického průměru.

$$s_x^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n}$$

kde

- s_x^2 je rozptyl statistického souboru,
- $\sum$ je sumační znak (součet),
- x_i je i-tá hodnota statistického souboru,
- $\bar{x}$ je aritmetický průměr,
- $x_i - \bar{x}$ je odchylka hodnoty od průměru,
- $(x_i - \bar{x})^2$ je čtverec odchylky,
- n je počet pozorování.

Výpočetní tvar rozptylu:

$$s_x^2 = \frac{\sum_{i=1}^{n} x_i^2}{n} - \left(\frac{\sum_{i=1}^{n} x_i}{n}\right)^2$$

Implementace v R

Funkce	Příklad použití	Vysvětlení

`mean((x - mean(x))^2)`	`x <- c(2,4,6,8)`
	
	`mean((x-mean(x))^2)`
		Vrací nevýběrový (populační) rozptyl hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.var(x)`	`import numpy as np`
	
	`x = np.array([2,4,6,8])`
	
	`np.var(x)`
		Vrací nevýběrový (populační) rozptyl pomocí knihovny `numpy`.

1.3.3 Výběrový rozptyl

Výběrový rozptyl je nezkreslený odhad rozptylu populace a vznikne úpravou rozptylu statistického souboru pomocí Besselovy korekce.

$$S^2 = \frac{n}{n-1} s_x^2$$

kde

- S^2 je výběrový rozptyl,
- s_x^2 je rozptyl statistického souboru,
- n je počet pozorování,
- $n - 1$ je korekce při odhadu rozptylu (Besselova korekce).

Implementace v R

Funkce	Příklad použití	Vysvětlení
`var(x)`	`x <- c(2,4,6,8)` `var(x)`	Vrací výběrový rozptyl hodnot ve vektoru `x` (dělí se $n - 1$).

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.var(x, ddof=1)`	`import numpy as np`
	`x = np.array([2,4,6,8])`
	`np.var(x, ddof=1)`
		Vrací výběrový rozptyl pomocí knihovny `numpy` (Besselova korekce).

1.3.4 Směrodatná odchylka statistického souboru

Směrodatná odchylka je druhá odmocnina rozptylu statistického souboru.

$$s_x = \sqrt{s_x^2}$$

kde

- s_x je směrodatná odchylka,
- s_x^2 je rozptyl statistického souboru,
- $\sqrt{\cdot}$ značí druhou odmocninu.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`sqrt(mean((x-mean(x))^2))`	`x <- c(2,4,6,8)` `sqrt(mean((x-mean(x))^2))`	Vrací směrodatnou odchylku statistického souboru.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.std(x)`	`import numpy as np`
	
	`x = np.array([2,4,6,8])`
	
	`np.std(x)`
		Vrací směrodatnou odchylku pole (nevýběrovou).

1.3.5 Výběrová směrodatná odchylka

Výběrová směrodatná odchylka je odmocnina z výběrového rozptylu.

$$S = \sqrt{S^2}$$

kde

- S je výběrová směrodatná odchylka,
- S^2 je výběrový rozptyl,
- $\sqrt{\cdot}$ značí druhou odmocninu.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`sd(x)`	`x <- c(2,4,6,8)`
	
	`sd(x)`
		Vrací výběrovou směrodatnou odchylku (dělí se $n-1$).

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.std(x, ddof=1)`	`import numpy as np`
	
	`x = np.array([2,4,6,8])`
	
	`np.std(x, ddof=1)`
		Vrací výběrovou směrodatnou odchylku (Besselova korekce).

1.3.6 Variační koeficient

Variační koeficient vyjadřuje relativní variabilitu dat a udává poměr směrodatné odchylky k aritmetickému průměru.

$$v_x = \frac{s_x}{\bar{x}}$$

kde

- v_x je variační koeficient,

- s_x je směrodatná odchylka,
- $\bar{x}$ je aritmetický průměr.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`sd(x) / mean(x)`	`x <- c(2,4,6,8)`
	
	`sd(x) / mean(x)`
		Vrací variační koeficient hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.std(x) / np.mean(x)`	`import numpy as np`
	
	`x = np.array([2,4,6,8])`
	
	`np.std(x) / np.mean(x)`
		Vrací variační koeficient hodnot ve vektoru `x`.