VYSOKÁ ŠKOLA EKONOMICKÁ V PRAZE
FAKULTA INFORMATIKY A STATISTIKY

STATISTIKA PRO INFORMATIKY

VZORCE PRO 4ST204

Obsah

1 Popisná Statistika

1.1 Četnosti

1.1.1 Absolutní četnost

Absolutní četnost i-té hodnoty je počet výskytů dané hodnoty ve výběru.

$$n_i$$

kde

- n_i je počet výskytů i-té hodnoty ve výběru.

1.1.2 Součet absolutních četností

Součet absolutních četností všech hodnot (nebo tříd) ve výběru se rovná celkovému počtu pozorování.

$$\sum_{i=1}^{k} n_i = n$$

kde

- $\sum$ je sumační znak (značí sčítání),
- i je index hodnoty nebo třídy,
- k je počet různých hodnot nebo tříd,
- n_i je absolutní četnost i-té hodnoty (nebo třídy),
- n je celkový počet pozorování.

1.1.3 Relativní Četnost

Relativní četnost i-té hodnoty ve výběru je definována jako podíl absolutní četnosti dané hodnoty a celkového počtu pozorování,

$$p_i = \frac{n_i}{n}$$

kde

- p_i je relativní četnost i-té hodnoty,
- n_i je absolutní četnost i-té hodnoty (kolikrát se hodnota vyskytla),
- n je celkový počet pozorování v souboru.

1.1.4 Součet relativních četností

Součet relativních četností všech hodnot (nebo tříd) ve výběru je roven jedné.

$$\sum_{i=1}^{k} p_i = 1$$

kde

- $\sum$ je sumační znak (značí sčítání),
- i je index hodnoty nebo třídy,
- k je počet různých hodnot nebo tříd,
- p_i je relativní četnost i-té hodnoty (nebo třídy).

1.2 Charakteristiky polohy

1.2.1 Aritmetický průměr

Aritmetický průměr (výběrový průměr) je definován jako součet všech hodnot statistického souboru dělený počtem pozorování.

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

kde

- $\bar{x}$ je aritmetický průměr,
- $\sum$ je sumační znak (součet hodnot),
- x_i je i-tá hodnota statistického souboru,
- i je index hodnoty,
- n je počet pozorování.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`mean(x)`	`x <- c(1,2,3,4,5)` `mean(x)`	Vrací aritmetický průměr hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.mean(x)`	`import numpy as np`
	`x = np.array([1,2,3,4,5])`
	`np.mean(x)`
		Vrací aritmetický průměr pole pomocí knihovny `numpy`.

1.2.2 Vážený aritmetický průměr (z četnostní tabulky)

Pokud jsou data zadána pomocí četnostní tabulky, aritmetický průměr lze vypočítat jako vážený průměr hodnot.

$$\bar{x} = \frac{\sum_{i=1}^{k} x_i n_i}{\sum_{i=1}^{k} n_i}$$

kde

- $\bar{x}$ je aritmetický průměr,
- $\sum$ je sumační znak (součet),
- x_i je i-tá hodnota znaku,
- n_i je absolutní četnost i-té hodnoty,
- k je počet různých hodnot nebo tříd,
- $\sum_{i=1}^{k} n_i$ je celkový počet pozorování.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`weighted.mean(x, w)`	`x <- c(1,2,3)`
	`w <- c(2,3,5)`
	
	`weighted.mean(x, w)`
		Vrací vážený průměr hodnot ve vektoru `x` s váhami `w`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.average(x, weights=w)`	`import numpy as np`
	
	`x = np.array([1,2,3])`
	`w = np.array([2,3,5])`
	
	`np.average(x, weights=w)`
		Vrací vážený průměr hodnot ve vektoru `x` s váhami `w`.

1.2.3 Aritmetický průměr pomocí relativních četností

Pokud jsou data vyjádřena pomocí relativních četností, lze aritmetický průměr vypočítat jako vážený součet hodnot.

$$\bar{x} = \sum_{i=1}^{k} x_i p_i$$

kde

- $\bar{x}$ je aritmetický průměr,
- $\sum$ je sumační znak (součet),
- x_i je i-tá hodnota znaku,
- p_i je relativní četnost i-té hodnoty,
- i je index hodnoty,
- k je počet různých hodnot nebo tříd.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`sum(x * p)`	`x <- c(1,2,3)`
	`p <- c(0.2,0.3,0.5)`
	
	`sum(x * p)`
		Vrací aritmetický průměr vypočtený pomocí relativních četností.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.sum(x * p)`	`import numpy as np`
	
	`x = np.array([1,2,3])`
	`p = np.array([0.2,0.3,0.5])`
	
	`np.sum(x * p)`
		Vrací aritmetický průměr vypočtený pomocí relativních četností pomocí knihovny `numpy`.

1.2.4 Harmonický průměr

Harmonický průměr je definován jako podíl počtu pozorování a součtu převrácených hodnot jednotlivých pozorování.

$$\bar{x}_H = \frac{n}{\sum_{i=1}^{n} \frac{1}{x_i}}$$

kde

- $\bar{x}_H$ je harmonický průměr,
- n je počet pozorování,
- $\sum$ je sumační znak (součet),
- x_i je i-tá hodnota statistického souboru,
- $\frac{1}{x_i}$ je převrácená hodnota i-tého pozorování.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`n / sum(1/x)`	`x <- c(1,2,4,5)`
	`n <- length(x)`
	
	`n / sum(1/x)`
		Vrací harmonický průměr hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`scipy.stats.`
`hmean(x)`
	`from scipy.stats import`
	`  hmean`
	
	`x = [1,2,4,5]`
	
	`hmean(x)`
		Vrací harmonický průměr pomocí funkce `hmean` z knihovny `scipy.stats`.

1.2.5 Geometrický průměr

Geometrický průměr je definován jako n-tá odmocnina součinu všech hodnot statistického souboru.

$$\bar{x}_G = \sqrt[n]{\prod_{i=1}^{n} x_i} = \sqrt[n]{x_1 \cdot x_2 \cdots x_n}$$

kde

- $\bar{x}_G$ je geometrický průměr,
- $\prod$ je znak pro součin (násobení všech hodnot),
- x_i je i-tá hodnota statistického souboru,
- i je index hodnoty,
- n je počet pozorování,
- $\sqrt[n]{\cdot}$ značí n-tou odmocninu.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`exp(mean(log(x)))`	`x <- c(1,2,3,4)`
	
	`exp(mean(log(x)))`
		Vrací geometrický průměr hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`scipy.stats.gmean(x)`	`from scipy.stats import gmean`
	
	`x = [1,2,3,4]`
	
	`gmean(x)`
		Vrací geometrický průměr pomocí funkce `gmean` z knihovny `scipy.stats`.

1.2.6 Vztah mezi průměry

$$\bar{x}_H \leq \bar{x}_G \leq \bar{x}$$

kde

- $\bar{x}_H$ je harmonický průměr,
- $\bar{x}_G$ je geometrický průměr,
- $\bar{x}$ je aritmetický průměr.

1.2.7 Medián

Medián je hodnota, která rozděluje uspořádaný statistický soubor na dvě stejně početné části. Medián také vyjadřuje 50% kvantil.

$$\tilde{x} = \begin{cases} x_{\left(\frac{n+1}{2}\right)}, & \text{je-li } n \text{ liché,} \\ \frac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2}, & \text{je-li } n \text{ sudé.} \end{cases}$$

kde

- $\tilde{x}$ je medián,
- $x_{(i)}$ je i-tá hodnota v uspořádaném statistickém souboru,
- n je počet pozorování.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`median(x)`	`x <- c(1,3,2,5,4)` `median(x)`	Vrací medián hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.median(x)`	`import numpy as np`
	
	`x = np.array([1,3,2,5,4])`
	`np.median(x)`
		Vrací medián hodnot ve vektoru `x`.

1.2.8 Kvantily a kvartily

Kvantily rozdělují uspořádaný statistický soubor na části se stejným počtem pozorování.

q-kvantil je hodnota x_q, pro kterou platí

$$P(X \leq x_q) = q$$

kde

- x_q je q-kvantil,
- $q \in (0, 1)$ je pořadí kvantilu,
- $P(X \leq x_q)$ je pravděpodobnost, že náhodná veličina nabývá hodnot menších nebo rovných x_q.

Speciálním případem kvantilů jsou kvartily, které rozdělují data na čtyři stejně velké části.

$$Q_1 = x_{0.25}, \qquad Q_2 = x_{0.5}, \qquad Q_3 = x_{0.75}$$

kde

- Q_1 je první kvartil (25% dat je menších),
- Q_2 je druhý kvartil, který odpovídá mediánu,
- Q_3 je třetí kvartil (75% dat je menších).

Implementace v R

Funkce	Příklad použití	Vysvětlení

`quantile(x)`	`x <- c(1,2,3,4,5,6,7,8)`
	
	`quantile(x)`
		Vrací kvantily datového vektoru.

`quantile(x, probs=c(0.25, 0.5, 0.75))`	`x <- c(1,2,3,4,5,6,7,8)`
	
	`quantile(x, probs=c`
	`(0.25,0.5,0.75))`
		Vrací první, druhý a třetí kvartil.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.quantile(x,q)`	`import numpy as np`
	
	`x = np.array`
	`([1,2,3,4,5,6,7,8])`
	
	`np.quantile(x,0.5)`
		Vrací q-kvantil pole.

`np.quantile(x, [0.25,0.5,0.75])`	`import numpy as np`
	
	`x = np.array`
	`([1,2,3,4,5,6,7,8])`
	
	`np.quantile(x`
	`,[0.25,0.5,0.75])`
		Vrací první, druhý a třetí kvartil.

1.2.9 Interkvartilové rozpětí (IQR)

Interkvartilové rozpětí (IQR) je rozdíl mezi třetím a prvním kvartilem. Vyjadřuje rozptyl prostředních 50 % dat.

$$IQR = Q_3 - Q_1$$

kde

- IQR je interkvartilové rozpětí,
- Q_1 je první kvartil,
- Q_3 je třetí kvartil.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`IQR(x)`	`x <- c(1,2,3,4,5,6,7,8)`
	
	`IQR(x)`
		Vrací interkvartilové rozpětí datového vektoru.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.quantile(x,0.75)`
`-`
`np.quantile(x,0.25)`
	`import numpy as np`
	
	`x = np.array`
	`([1,2,3,4,5,6,7,8])`
	
	`np.quantile(x,0.75) - np.`
	`quantile(x,0.25)`
		Vrací interkvartilové rozpětí pole.

1.3 Charakteristiky variability

1.3.1 Variační rozpětí

Variační rozpětí je rozdíl mezi maximální a minimální hodnotou statistického souboru.

$$R = x_{\max} - x_{\min}$$

kde

- R je variační rozpětí,
- $x_{\max}$ je maximální hodnota v souboru,
- $x_{\min}$ je minimální hodnota v souboru.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`max(x) - min(x)`	`x <- c(3,7,2,9,5)`
	
	`max(x) - min(x)`
		Vrací variační rozpětí hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.max(x) - np.min(x)`	`import numpy as np`
	
	`x = np.array([3,7,2,9,5])`
	
	`np.max(x) - np.min(x)`
		Vrací variační rozpětí hodnot ve vektoru `x`.

1.3.2 Rozptyl statistického souboru

Rozptyl vyjadřuje průměrnou kvadratickou odchylku hodnot od aritmetického průměru.

$$s_x^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n}$$

kde

- s_x^2 je rozptyl statistického souboru,
- $\sum$ je sumační znak (součet),
- x_i je i-tá hodnota statistického souboru,
- $\bar{x}$ je aritmetický průměr,
- $x_i - \bar{x}$ je odchylka hodnoty od průměru,
- $(x_i - \bar{x})^2$ je čtverec odchylky,
- n je počet pozorování.

Výpočetní tvar rozptylu:

$$s_x^2 = \frac{\sum_{i=1}^{n} x_i^2}{n} - \left(\frac{\sum_{i=1}^{n} x_i}{n}\right)^2$$

Implementace v R

Funkce	Příklad použití	Vysvětlení

`mean((x - mean(x))^2)`	`x <- c(2,4,6,8)`
	
	`mean((x-mean(x))^2)`
		Vrací nevýběrový (populační) rozptyl hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.var(x)`	`import numpy as np`
	
	`x = np.array([2,4,6,8])`
	
	`np.var(x)`
		Vrací nevýběrový (populační) rozptyl pomocí knihovny `numpy`.

1.3.3 Výběrový rozptyl

Výběrový rozptyl je nezkreslený odhad rozptylu populace a vznikne úpravou rozptylu statistického souboru pomocí Besselovy korekce.

$$S^2 = \frac{n}{n-1} s_x^2$$

kde

- S^2 je výběrový rozptyl,
- s_x^2 je rozptyl statistického souboru,
- n je počet pozorování,
- $n - 1$ je korekce při odhadu rozptylu (Besselova korekce).

Implementace v R

Funkce	Příklad použití	Vysvětlení
`var(x)`	`x <- c(2,4,6,8)` `var(x)`	Vrací výběrový rozptyl hodnot ve vektoru `x` (dělí se $n - 1$).

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.var(x, ddof=1)`	`import numpy as np`
	`x = np.array([2,4,6,8])`
	`np.var(x, ddof=1)`
		Vrací výběrový rozptyl pomocí knihovny `numpy` (Besselova korekce).

1.3.4 Vážený rozptyl

Vážený rozptyl vyjadřuje variabilitu hodnot znaku, když mají jednotlivé hodnoty různé váhy nebo relativní četnosti.

$$s^2 = \sum_{i=1}^{k} p_i (x_i - \bar{x})^2$$

kde

- s^2 je vážený rozptyl,
- x_i je i-tá hodnota znaku,
- $\bar{x}$ je vážený aritmetický průměr,
- p_i je váha nebo relativní četnost i-té hodnoty,
- k je počet různých hodnot nebo tříd.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`weighted.mean( (x-mean(x))^2, w)`	`x <- c(1,2,3,4)`
	`w <- c(0.1,0.2,0.3,0.4)`
	
	`weighted.mean((x-weighted. mean(x,w))^2, w)`
		Vrací vážený rozptyl hodnot s váhami `w`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.average( (x-xbar)**2, weights=w)`	`import numpy as np`
	
	`x = np.array([1,2,3,4])`
	`w = np.array ([0.1,0.2,0.3,0.4])`
	
	`xbar = np.average(x, weights=w)`
	`np.average((x-xbar)**2, weights=w)`
		Vrací vážený rozptyl hodnot s váhami `w` pomocí knihovny `numpy`.

1.3.5 Směrodatná odchylka statistického souboru

Směrodatná odchylka je druhá odmocnina rozptylu statistického souboru.

$$s_x = \sqrt{s_x^2}$$

kde

- s_x je směrodatná odchylka,
- s_x^2 je rozptyl statistického souboru,
- $\sqrt{\cdot}$ značí druhou odmocninu.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`sqrt(mean((x-mean(x))`^{2}`))`	`x <- c(2,4,6,8)`
	
	`sqrt(mean((x-mean(x))^2))`
		Vrací směrodatnou odchylku statistického souboru.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.std(x)`	`import numpy as np`
	`x = np.array([2,4,6,8])`
	`np.std(x)`
		Vrací směrodatnou odchylku pole (nevýběrovou).

1.3.6 Výběrová směrodatná odchylka

Výběrová směrodatná odchylka je odmocnina z výběrového rozptylu.

$$S = \sqrt{S^2}$$

kde

- S je výběrová směrodatná odchylka,
- S^2 je výběrový rozptyl,
- $\sqrt{\cdot}$ značí druhou odmocninu.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`sd(x)`	`x <- c(2,4,6,8)` `sd(x)`	Vrací výběrovou směrodatnou odchylku (dělí se $n-1$).

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.std(x, ddof=1)`	`import numpy as np`
	`x = np.array([2,4,6,8])`
	`np.std(x, ddof=1)`
		Vrací výběrovou směrodatnou odchylku (Besselova korekce).

1.3.7 Variační koeficient

Variační koeficient vyjadřuje relativní variabilitu dat a udává poměr směrodatné odchylky k aritmetickému průměru.

$$v_x = \frac{s_x}{\bar{x}}$$

kde

- v_x je variační koeficient,
- s_x je směrodatná odchylka,
- $\bar{x}$ je aritmetický průměr.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`sd(x) / mean(x)`	`x <- c(2,4,6,8)`
	
	`sd(x) / mean(x)`
		Vrací variační koeficient hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.std(x) / np.mean(x)`	`import numpy as np`
	
	`x = np.array([2,4,6,8])`
	
	`np.std(x) / np.mean(x)`
		Vrací variační koeficient hodnot ve vektoru `x`.

2 Teorie pravděpodobnosti

2.1 Počet pravděpodobnosti

2.1.1 Klasická definice pravděpodobnosti

Pravděpodobnost jevu A při klasické definici pravděpodobnosti je podíl počtu příznivých výsledků a celkového počtu stejně pravděpodobných výsledků.

$$P(A) = \frac{m}{n}$$

kde

- $P(A)$ je pravděpodobnost jevu A,
- m je počet příznivých výsledků,
- n je počet všech možných výsledků.

2.1.2 Pravděpodobnost komplementárního jevu

Pravděpodobnost opačného (komplementárního, doplňkového) jevu k jevu A je rovna jedné minus pravděpodobnost jevu A.

$$P(\overline{A}) = 1 - P(A)$$

kde

- $P(\overline{A})$ je pravděpodobnost opačného jevu k A,
- $P(A)$ je pravděpodobnost jevu A.

2.1.3 Horní odhad pravděpodobnosti průniku

Pravděpodobnost současného nastání dvou jevů nemůže být větší než pravděpodobnost kteréhokoli z nich.

$$P(A \cap B) \leq \min(P(A), P(B))$$

kde

- $P(A \cap B)$ je pravděpodobnost, že nastanou oba jevy současně,
- $P(A)$ je pravděpodobnost jevu A,
- $P(B)$ je pravděpodobnost jevu B,
- $\min(\cdot)$ označuje minimum z daných hodnot.

2.1.4 Průnik nezávislých jevů

Jsou-li jevy A a B nezávislé, pak pravděpodobnost jejich současného nastání je rovna součinu jejich pravděpodobností.

$$P(A \cap B) = P(A)P(B)$$

kde

- $P(A \cap B)$ je pravděpodobnost současného nastání jevů A a B,
- $P(A)$ je pravděpodobnost jevu A,
- $P(B)$ je pravděpodobnost jevu B.

2.1.5 Sjednocení dvou jevů

Pravděpodobnost, že nastane alespoň jeden z jevů A nebo B, je rovna součtu jejich pravděpodobností minus pravděpodobnost jejich současného nastání.

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

kde

- $P(A \cup B)$ je pravděpodobnost, že nastane alespoň jeden z jevů,
- $P(A)$ je pravděpodobnost jevu A,
- $P(B)$ je pravděpodobnost jevu B,
- $P(A \cap B)$ je pravděpodobnost současného nastání jevů A a B.

2.1.6 Sjednocení neslučitelných jevů

Pokud jsou jevy A a B neslučitelné (nemohou nastat současně), pak pravděpodobnost jejich sjednocení je rovna součtu pravděpodobností těchto jevů.

$$P(A \cup B) = P(A) + P(B)$$

kde

- $P(A \cup B)$ je pravděpodobnost, že nastane jev A nebo B,
- $P(A)$ je pravděpodobnost jevu A,
- $P(B)$ je pravděpodobnost jevu B.

2.2 Náhodné veličiny

2.2.1 Pravděpodobnostní funkce diskrétní náhodné veličiny

Pravděpodobnost, že diskrétní náhodná veličina X nabývá konkrétní hodnoty x.

$$P(x) = P(X = x)$$

kde

- $P(x)$ je pravděpodobnost hodnoty x,
- $P(X = x)$ je pravděpodobnost, že náhodná veličina X má hodnotu x,
- X je náhodná veličina,
- x je konkrétní hodnota náhodné veličiny.

2.2.2 Distribuční funkce diskrétní náhodné veličiny

Distribuční funkce (kumulativní pravděpodobnost) udává pravděpodobnost, že náhodná veličina X bude menší nebo rovna hodnotě x.

$$F(x) = P(X \leq x) = \sum_{x_j \leq x} P(x_j)$$

kde

- $F(x)$ je distribuční funkce,
- $P(X \leq x)$ je pravděpodobnost, že X je menší nebo rovno x,
- $\sum$ je součet pravděpodobností,
- x_j jsou jednotlivé možné hodnoty náhodné veličiny,
- $P(x_j)$ je pravděpodobnost, že $X = x_j$.

2.2.3 Pravděpodobnost intervalu

Pravděpodobnost, že náhodná veličina X nabývá hodnot v intervalu $(x_1, x_2]$.

$$P(x_1 < X \leq x_2) = \sum_{x_1 < x \leq x_2} P(x) = F(x_2) - F(x_1)$$

kde

- $P(x_1 < X \leq x_2)$ je pravděpodobnost, že X leží mezi x_1 a x_2,
- X je náhodná veličina,
- x_1, x_2 jsou hranice intervalu,
- $\sum$ je součet pravděpodobností všech hodnot v intervalu,
- $P(x)$ je pravděpodobnost, že $X = x$,
- $F(x)$ je distribuční funkce.

2.2.4 Střední hodnota diskrétní náhodné veličiny

Střední hodnota (očekávaná hodnota) diskrétní náhodné veličiny je vážený průměr všech možných hodnot, kde váhami jsou jejich pravděpodobnosti.

$$E(X) = \sum_{x} x\, P(x)$$

kde

- $E(X)$ je očekávaná hodnota náhodné veličiny X,
- $\sum$ je součet přes všechny možné hodnoty,
- x jsou jednotlivé možné hodnoty náhodné veličiny,
- $P(x) = P(X = x)$ je pravděpodobnost, že X nabude hodnoty x.

2.2.5 Rozptyl diskrétní náhodné veličiny

Rozptyl náhodné veličiny vyjadřuje míru variability hodnot náhodné veličiny kolem její střední hodnoty.

$$D(X) = E(X^2) - [E(X)]^2 = \sum_x x^2 P(x) - \left(\sum_x xP(x)\right)^2$$

kde

- $D(X)$ je rozptyl náhodné veličiny X,
- $E(X)$ je očekávaná hodnota náhodné veličiny,
- $E(X^2)$ je očekávaná hodnota druhé mocniny náhodné veličiny,
- $\sum$ je součet přes všechny možné hodnoty,
- x jsou jednotlivé možné hodnoty náhodné veličiny,
- $P(x) = P(X = x)$ je pravděpodobnost, že X nabude hodnoty x.

2.2.6 Hustota pravděpodobnosti spojité náhodné veličiny

Hustota pravděpodobnosti vyjadřuje rychlost změny distribuční funkce spojité náhodné veličiny.

$$f(x) = F'(x)$$

kde

- $f(x)$ je hustota pravděpodobnosti,
- $F(x)$ je distribuční funkce,
- $F'(x)$ je derivace distribuční funkce podle x,
- x je hodnota náhodné veličiny.

2.2.7 Normalizační podmínka hustoty pravděpodobnosti

Celková pravděpodobnost spojité náhodné veličiny přes všechny možné hodnoty je rovna jedné.

$$\int_{-\infty}^{\infty} f(x)\, dx = 1$$

kde

- $\int$ označuje integrál (součet přes všechny hodnoty),
- $f(x)$ je hustota pravděpodobnosti,
- dx je integrační proměnná,
- $-\infty, \infty$ vyjadřují integraci přes všechny možné hodnoty náhodné veličiny.

2.2.8 Distribuční funkce spojité náhodné veličiny

Distribuční funkce spojité náhodné veličiny udává pravděpodobnost, že náhodná veličina X bude menší nebo rovna hodnotě x.

$$F(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)\, dt$$

kde

- $F(x)$ je distribuční funkce,
- $P(X \leq x)$ je pravděpodobnost, že náhodná veličina X je menší nebo rovna x,
- $\int$ označuje integrál,
- $f(t)$ je hustota pravděpodobnosti,
- t je integrační proměnná,
- $-\infty$ je dolní mez integrace,
- x je horní mez integrace.

2.2.9 Pravděpodobnost intervalu spojité náhodné veličiny

Pravděpodobnost, že spojitá náhodná veličina X nabývá hodnot v intervalu $(x_1, x_2]$.

$$P(x_1 < X \leq x_2) = \int_{x_1}^{x_2} f(x)\,dx = F(x_2) - F(x_1)$$

kde

- $P(x_1 < X \leq x_2)$ je pravděpodobnost, že X leží mezi x_1 a x_2,
- X je náhodná veličina,
- x_1, x_2 jsou hranice intervalu,
- $\int$ označuje integrál,
- $f(x)$ je hustota pravděpodobnosti,
- dx je integrační proměnná,
- $F(x)$ je distribuční funkce.

2.2.10 Střední hodnota spojité náhodné veličiny

Střední hodnota (očekávaná hodnota) spojité náhodné veličiny je vážený průměr všech možných hodnot, kde váhami jsou hodnoty hustoty pravděpodobnosti.

$$E(X) = \int_{-\infty}^{\infty} x f(x)\,dx$$

kde

- $E(X)$ je očekávaná hodnota náhodné veličiny X,
- $\int$ označuje integrál,
- x je hodnota náhodné veličiny,
- $f(x)$ je hustota pravděpodobnosti,
- dx je integrační proměnná,
- $-\infty, \infty$ vyjadřují integraci přes všechny možné hodnoty náhodné veličiny.

2.2.11 Rozptyl spojité náhodné veličiny

Rozptyl spojité náhodné veličiny vyjadřuje variabilitu hodnot náhodné veličiny kolem její střední hodnoty.

$$D(X) = \int_{-\infty}^{\infty} x^2 f(x)\,dx - \left[\int_{-\infty}^{\infty} x f(x)\,dx\right]^2$$

kde

- $D(X)$ je rozptyl náhodné veličiny X,
- $\int$ označuje integrál,
- x je hodnota náhodné veličiny,
- $f(x)$ je hustota pravděpodobnosti,

- dx je integrační proměnná,
- $\int xf(x)\,dx$ je očekávaná hodnota $E(X)$,
- $\int x^2 f(x)\,dx$ je očekávaná hodnota $E(X^2)$.

2.2.12 Směrodatná odchylka náhodné veličiny

Směrodatná odchylka vyjadřuje míru variability hodnot náhodné veličiny kolem její střední hodnoty.

$$\sigma = \sqrt{D(X)}$$

kde

- σ je směrodatná odchylka,
- $D(X)$ je rozptyl náhodné veličiny X,
- $\sqrt{\ }$ označuje druhou odmocninu.

3 Kombinatorika a Metriky

3.1 Kombinatorika

Mějme množinu n prvků, ze které vybíráme k prvků.

- **Permutace (Pořadí všech n prvků):** Bez opakování: $P(n) = n!$
  S opakováním: $P'_{k_1,\ldots,k_m}(n) = \frac{n!}{k_1!\cdot\ldots\cdot k_m!}$
- **Variace (Výběr k prvků z n, záleží na pořadí):** Bez opakování: $V(k,n) = \frac{n!}{(n-k)!}$
  S opakováním: $V'(k,n) = n^k$
- **Kombinace (Výběr k prvků z n, nezáleží na pořadí):** Bez opakování: $K(k,n) = \binom{n}{k} = \frac{n!}{k!(n-k)!}$
  S opakováním: $K'(k,n) = \binom{n+k-1}{k} = \frac{(n+k-1)!}{k!(n-1)!}$

3.2 L^p Normy (Vzdálenosti a penalizace)

Obecně: $\|x\|_p = (\sum |x_i|^p)^{1/p}$. Klíčové pro metriky chyb a regularizaci.

- L^1 **(Manhattan):** $\|x\|_1 = \sum |x_i|$. Využití: Lasso regrese.
- L^2 **(Euklid):** $\|x\|_2 = \sqrt{\sum x_i^2}$. Využití: Ridge regrese (metoda nejmenších čtverců).
- L^∞ **(Max):** $\|x\|_\infty = \max(|x_i|)$. Reprezentuje nejhorší možnou chybu.

4 Práce s daty v Pythonu (Cheatsheet)

4.1 Užitečné knihovny a základy

Funkce	Příklad použití	Vysvětlení
`import numpy as np`	`np.array([...])`	Matice, vektory a rychlé matematické operace.
`import pandas as pd`	`pd.DataFrame(matice)`	Analýza tabulek a práce s CSV.
`import matplotlib.pyplot as plt`	`plt.hist(data)`	Tvorba grafů a vizualizace dat.
`math.comb(n, k)`	`math.comb(10, 3)`	Kombinační číslo (výběr k z n).
`List Comprehension`	`[x**2 for x in range(5)]`	Dynamické generování pole pomocí cyklu.

4.2 Práce s poli (Standardní Python)

Funkce	Příklad použití	Vysvětlení
List Comprehension	`[x**2 for x in range(5)]`	Dynamické generování pole pomocí cyklu.
`x[start:stop:krok]`	`pole[1:10:2]`	Výřez (stop je exkluzivní). `[::-1]` pro otočení.
`x.copy()` vs `deepcopy`	`a = b.copy()`	`copy` je plytká, `deepcopy` kopíruje i vnořená pole.
`x.append(v)`	`data.append(10)`	Přidání jednoho prvku na konec pole.
`x.extend(a)`	`data.extend([1,2,3])`	Přidání více prvků na konec pole.

4.3 Základní Python (Built-in & Math)

Funkce	Příklad použití	Vysvětlení
`help(funkce)`	`help(print)`	Dokumentace pro zadanou funkci.
`range(start, stop)`	`list(range(0, 5))`	Vygeneruje sekvenci `[0, 1, 2, 3, 4]`.
`math.log(x, b)`	`math.log(8, 2)`	Logaritmus čísla x o základu b.
`math.sqrt(x)`	`math.sqrt(16)`	Druhá odmocnina čísla.
`math.ceil / floor`	`math.ceil(2.1)`	Zaokrouhlení nahoru (3) / dolů (2).
`math.trunc(x)`	`math.trunc(2.9)`	Odříznutí desetinné části (2).
`math.comb(n, k)`	`math.comb(10, 3)`	Kombinační číslo (počet kombinací k prvků z n).
`def function(...):`	`def funkce(x, y, z):`	Definice vlastní funkce s parametry.

4.4 Statistika a Matice (Knihovna NumPy a jiné)

Funkce	Příklad použití	Vysvětlení
`np.sum(x)`	`np.sum(data, axis=0)`	Součet všech prvků v poli (nebo podél zvolené osy).
`np.mean(x)`	`np.mean(data)`	Průměr všech prvků v poli.
`np.prod(x)`	`np.prod(data)`	Součin všech prvků v poli.
`np.sqrt(x)`	`np.sqrt(data)`	Druhá odmocnina z každého prvku v poli.
`np.random.rand(n)`	`np.random.rand(100)`	Generování pole n náhodných čísel z rovnoměrného rozdělení na $[0, 1)$.
`np.random.uniform(a, b, n)`	`np.random.uniform(10, 50, 100)`	Generuje n náhodných **desetinných** čísel v rozsahu $[a, b)$.
`np.quantile(x, q)`	`np.quantile(x, 0.75, method='midpoint')`	Výpočet kvantilu ($q \in [0, 1]$).
`Modus`	`statistics.multimode(data)`	`Vrací modus z pole (i více prvků)`
`np.log10(x)`	`np.log10(data)`	Dekadický logaritmus (základ 10). Často se používá pro normalizaci dat.
`np.linalg.norm(x, p)`	`np.linalg.norm(x, ord=2)`	Výpočet L^1, L^2 nebo L^∞ (`np.inf`) normy.
`np.insert / np.delete`	`np.insert(A, 1, [..], axis=0)`	Vloží/Smaže řádek (`axis=0`) nebo sloupec (`axis=1`).
`stats.gmean(x)`	`stats.gmean(x)`	Geometrický průměr (knihovna Scipy).
`stats.hmean(x)`	`stats.hmean(x, weights=[...])`	Harmonický průměr (knihovna Scipy).
`np.var(x, ddof=0)`	`np.var(data, ddof=0)`	**Klasický rozptyl** s_x^2 (děleno n).
`np.var(x, ddof=1)`	`np.var(data, ddof=1)`	**Výběrový rozptyl** S^2 (děleno $n-1$).
`np.std(x, ddof=0)`	`np.std(data, ddof=0)`	Klasická směrodatná odchylka s_x.
`np.std(x, ddof=1)`	`np.std(data, ddof=1)`	Výběrová směrodatná odchylka S.
`np.ptp(x)`	`np.ptp(data)`	**Variační rozpětí** $R = x_{max} - x_{min}$.
`v_x = std / mean`	`np.std(x) / np.mean(x)`	**Variační koeficient** v_x (relativní variabilita).
`np.where(cond, x, y)`	`np.where(df['am'] == 0, 'aut', 'man')`	**Podmíněný sloupec**: Pokud platí `cond`, vlož `x`, jinak `y` (jako IF v Excelu).

4.5 Pandas: Analýza dat

Funkce	Příklad použití	Vysvětlení
`pd.read_csv(file)`	`pd.read_csv('data.csv')`	Načte data z CSV souboru a vytvoří DataFrame.
`df.describe()`	`df.describe()`	Souhrnné statistiky (průměr, std, kvartily, atd.).
`df[columns]`	`df[["A", "B", "C"]]`	Výběr určitých sloupců.
`Filtrování`	`df[df['Věk'] >= 18]`	Vybere pouze řádky splňující danou podmínku.
`df['A'].isin([list])`	`df[df['mesto'].isin(['Praha', 'Brno'])]`	Vybere řádky, kde hodnota sloupce odpovídá prvkům v seznamu.
`df.loc` vs `df.iloc`	`df.loc[0, 'Sloupec']`	Výběr dat podle **názvů** (`loc`) vs. **pozice** (`iloc`).
`df.isna().sum()`	`df.isna().sum()`	Počet chybějících (null) hodnot v tabulce.
`df.value_counts()`	`df['A'].value_counts()`	Tabulka četností pro kategorická data.
`df.groupby('A')`	`df.groupby('A').mean()`	Výpočet statistik podle kategorií ve sloupci 'A'.
`df.cumsum()`	`df['cetnost'].cumsum()`	**Kumulativní součet**: Pro výpočet kumulativních absolutních/relativních četností.
`pd.crosstab()`	`pd.crosstab(df['A'], df['B'])`	Kontingenční tabulka četností dvou kategorií.
`pd.pivot_table()`	`df.pivot_table(values='C', ...)`	Univerzální pivotní tabulka.
`df['A'].between(a, b)`	`df[df['mzda'].between(30000, 50000)]`	Filtrování hodnot v uzavřeném intervalu [a, b].

4.6 Matplotlib a Seaborn: Vizualizace

Funkce	Příklad použití	Vysvětlení
`df.boxplot()`	`df.boxplot(column='Y', by='X')`	**Boxplot (Pandas)**: Rozdělení dat do kvartilů dle skupiny.
`plt.hist(x)`	`plt.hist(data, bins=15)`	**Histogram**: Rozdělení četností. `bins` určuje intervaly.
`plt.scatter(x, y)`	`plt.scatter(x, y, alpha=0.5)`	**Bodový graf**: Závislost dvou proměnných.
`plt.title(s)`	`plt.title("Název", fontsize=16)`	Nastaví hlavní nadpis grafu.
`plt.xlabel / ylabel`	`plt.xlabel("Čas [s]")`	Nastaví popisky os x a y.
`plt.legend()`	`plt.legend(loc='upper right')`	Zobrazí legendu (nutný parametr `label` u dat).
`plt.savefig()`	`plt.savefig("graf.pdf")`	Uloží graf na disk.

4.7 Náhodné veličiny a rozdělení

`Importy:`

```
from scipy.stats import norm, binom, poisson, hypergeom, t
```

Normální rozdělení (`norm`)

Spojité rozdělení pro modelování např. času, délky či chyby měření.
Parametry: `x` = zkoumaná hodnota (hranice), `mu` (`loc`) = střední hodnota, `sigma` (`scale`) = směrodatná odchylka, `q` = zadaná pravděpodobnost (pro hledání kvantilu).

Funkce	Příklad použití	Vysvětlení
`norm.cdf(x, mu, sigma)`	`norm.cdf(16, loc=20, scale=4)`	`MÉNĚ NEŽ`: Šance, že hodnota bude maximálně x.
`norm.sf(x, mu, sigma)`	`norm.sf(20, loc=20, scale=4)`	`VÍCE NEŽ`: Ekvivalent `1 - cdf`. Šance, že hodnota překročí x.
`norm.cdf(b) - norm.cdf(a)`	`norm.cdf(28, 20, 4) - norm.cdf(12, 20, 4)`	`MEZI`: Šance, že se hodnota trefí do intervalu (a, b).
`norm.ppf(q, mu, sigma)`	`norm.ppf(0.4, loc=20, scale=4)`	`Hledání kvantilu`: Najde hodnotu x, pro kterou platí $P(X < x) = q$.

Binomické rozdělení (`binom`)

Diskrétní rozdělení. Počet úspěchů v pevně daném počtu nezávislých pokusů.
Aproximace: Pokud je počet pokusů $n \geq 30$ a pravděpodobnost úspěchu $p \leq 0.05$, blíží se Poissonovu rozdělení.
Parametry: `k` = zkoumaný počet úspěchů, `n` = celkový počet pokusů, `p` = pravděpodobnost úspěchu.

Funkce	Příklad použití	Vysvětlení
`binom.pmf(k, n, p)`	`binom.pmf(4, n=10, p=1/6)`	`Pravděpodobnost PŘESNĚ`: Šance, že úspěch nastane přesně k-krát.
`binom.cdf(k, n, p)`	`binom.cdf(2, n=10, p=1/6)`	`Pravděpodobnost NEJVÝŠE`: Šance, že úspěchů bude 0 až k (včetně).
`1 - binom.cdf(k, n, p)`	`1 - binom.cdf(2, n=10, p=1/6)`	`Pravděpodobnost VÍCE NEŽ`: Šance, že úspěchů bude striktně více než k.

Poissonovo rozdělení (`poisson`)

Diskrétní rozdělení. Počet výskytů události za jednotku času nebo prostoru, když známe průměr.
Parametry: `k` = zkoumaný počet událostí, `mu` = průměrný počet událostí (λ).

Funkce	Příklad použití	Vysvětlení
`poisson.pmf(k, mu)`	`poisson.pmf(2, mu=0.4)`	`Pravděpodobnost PŘESNĚ`: Šance, že nastanou přesně k události při průměru μ.
`poisson.cdf(k, mu)`	`poisson.cdf(2, mu=0.4)`	`Pravděpodobnost NEJVÝŠE`: Šance, že událostí bude 0 až k (včetně).
`1 - poisson.cdf(k, mu)`	`1 - poisson.cdf(2, mu=0.4)`	`Pravděpodobnost VÍCE NEŽ`: Šance na více než k událostí.

Hypergeometrické rozdělení (`hypergeom`)

Diskrétní rozdělení. Výběr **bez vracení** z konečné populace (např. zmetky v zásilce).
Aproximace: Pokud $N/M \leq 0.05$, výběr bez vracení se chová téměř jako výběr s vracením (Binomické).
Parametry: `k` = hledané prvky ve výběru, `M` = populace, `n` = hledané prvky v populaci, `N` = velikost výběru.

Funkce	Příklad použití	Vysvětlení
`hypergeom.pmf(k, M, n, N)`	`hypergeom.pmf(0, 200, 10, 5)`	`Pravděpodobnost PŘESNĚ`: Šance na k zmetků ve výběru N z M, kde je celkem n zmetků.

Studentovo t-rozdělení (`t`)

Spojité rozdělení. Používá se pro konstrukci intervalů spolehlivosti a testování (neznáme-li rozptyl populace).
Parametry: `df` = stupně volnosti, `q` = hladina (pravděpodobnost).

Funkce	Příklad použití	Vysvětlení
`t.pdf(x, df)`	`t.pdf(x, df=15)`	`Hustota pravděpodobnosti`: Hodnota křivky pro bod x.
`t.ppf(q, df)`	`t.ppf(1 - 0.05/2, df=19)`	`Kritická hodnota`: Kvantil pro t-rozdělení (pro meze intervalu spolehlivosti).

4.8 Intervaly spolehlivosti a velikost výběru

Interval pro průměr (μ)

Kdy použít: Pro odhad průměrné hodnoty měřitelného znaku (váha, čas, délka).

- **Normální rozdělení (`norm`):** Pokud známe rozptyl populace σ^2 nebo je výběr velký ($n \geq 30$).
- **Studentovo t-rozdělení (`t`):** Pokud rozptyl populace neznáme a výběr je malý ($n < 30$).
- **Typy kvantilů:** Pro **oboustranný** interval používáme $1 - \alpha/2$, pro **jednostranný** (jen horní nebo dolní mez) používáme $1 - \alpha$.

Parametry: `x_bar` (výběrový průměr), `s` (výběrová směr. odchylka), `n` (rozsah výběru), `alpha` (α, hladina významnosti).

Funkce	Příklad použití	Vysvětlení
`Kritická hodnota`	`crit = t.ppf(1 - alpha/2, df=n-1)`	Kvantil pro t-interval (neznámé σ). Pro velké n lze nahradit `norm.ppf`.
`Mezní chyba (Mean)`	`err = crit * (s / np.sqrt(n))`	Výpočet odchylky pro průměr. `s` je výběrová směrodatná odchylka.
`Meze intervalu`	`lower, upper = p - err, p + err`	Skutečný parametr leží v intervalu s pravděpodobností $1 - \alpha$.

Interval pro podíl (π)

Kdy použít: Pro odhad procentuálního zastoupení (např. podíl zmetků, preference voličů).

- Vždy využíváme **normální rozdělení** (Z-kvantil).
- **Typy kvantilů:** Obdobně jako u průměru platí $1 - \alpha/2$ pro oboustranný a $1 - \alpha$ pro jednostranný odhad.

Parametry: `p` (výběrová relativní četnost), `n` (celkový počet testovaných jednotek).

Funkce	Příklad použití	Vysvětlení
`Kritická hodnota`	`z_crit = norm.ppf(1 - alpha / 2)`	Pro podíl se vždy používá normální rozdělení (Z-kvantil).
`Mezní chyba (Prop)`	`err = z_crit * np.sqrt(p * (1-p) / n)`	Výpočet odchylky pro proporci p.
`Meze intervalu`	`lower, upper = p - err, p + err`	Skutečný parametr leží v intervalu s pravděpodobností $1 - \alpha$.

Potřebná velikost výběru (n)

Kdy použít: Hledáme, kolik jednotek musíme vybrat (n), aby se náš odhad nemýlil o více než stanovenou chybu Δ (`delta`).

- **Zaokrouhlování:** Protože n musí být celé číslo, výsledek se **vždy zaokrouhluje nahoru** (funkce `math.ceil`), jinak by chyba byla větší než povolená.

Parametry: `delta` (Δ, požadovaná přesnost), `sigma` (předpokládaná směr. odchylka).

Funkce	Příklad použití	Vysvětlení
`Minimální n (Mean)`	`n = math.ceil((z_crit * sigma / delta)**2)`	Pro průměr. Δ je cílová přesnost. Výsledek **vždy** zaokrouhli nahoru.
`Minimální n (Prop)`	`n = math.ceil(p*(1-p) * (z_crit/delta)**2)`	Pro podíl. Používá se pro plánování reprezentativního výzkumu.

4.9 Testování hypotéz o průměru (μ)

Volba rozdělení: Pro $n \geq 30$ využíváme `norm`, pro $n < 30$ využíváme `t` s `df = n-1`.
Parametry: `mu0` (testovaná hodnota), `x_bar` (naměřený průměr), `s` (odchylka), `n` (rozsah).

1. Výpočet testového kritéria

```
u = (x_bar - mu0) / (s / np.sqrt(n))
```

2. Vyhodnocení testu (p-hodnota nebo kritická hodnota)

Typ testu	Alternativa H_1	Vzorec pro p-hodnotu (Python)
Levostranný	$E(X) < \mu_0$	`p = norm.cdf(u)`
Pravostranný	$E(X) > \mu_0$	`p = 1 - norm.cdf(u)`
Oboustranný	$E(X) \neq \mu_0$	`p = 2 * (1 - norm.cdf(abs(u)))`

Rozhodnutí pomocí p-hodnoty:

Podmínka	Výsledek testu
$p < \alpha$	**ZAMÍTÁME** H_0 (rozdíl je statisticky významný)
$p \geq \alpha$	**NEZAMÍTÁME** H_0 (rozdíl je pravděpodobně náhodný)

Rozhodnutí pomocí kritické hodnoty (u_{krit}):

`u_krit = norm.ppf(1 - alpha)` (u oboustranného testu `1 - alpha/2`)

Typ testu	Alternativa H_1	Zamítáme H_0, pokud platí:
Levostranný	$E(X) < \mu_0$	$u < -u_{\text{krit}}$
Pravostranný	$E(X) > \mu_0$	$u > u_{\text{krit}}$
Oboustranný	$E(X) \neq \mu_0$	$\lvert u \rvert \geq u_{\text{krit}}$

Poznámka: U malého vzorku zaměňujeme `norm` za `t` s parametrem `df=n-1`.

3. Automatické statistické testy (z pole dat)

Využíváme funkce z knihovny `scipy.stats`, které provádějí kompletní výpočet přímo z naměřených hodnot.

Vstupní parametry:

- `data, A, B, C`: Nezávislé vzorky měření (např. různé skupiny studentů nebo odrůd).
- `pred, po`: Závislá (párová) měření na stejných objektech (typicky testování „před a po“).
- `O, E`: Pozorované (`O`) a očekávané (`E`) četnosti výskytů.
- `table`: Kontingenční tabulka četností zadaná jako 2D pole (matice).
- `x, y`: Dvě sady proměnných pro zjištění síly jejich vzájemné závislosti.

Funkce	**Příklad použití**	**Vysvětlení**
`Jednovýběrový t-test`	`stats.ttest_1samp(data, popmean=mu0)`	Porovnání průměru vzorku s pevnou hodnotou μ_0.
`Dvouvýběrový t-test`	`stats.ttest_ind(A, B, equal_var=False)`	Porovnání průměrů dvou nezávislých skupin (Welchův test).
`Párový t-test`	`stats.ttest_rel(po, pred)`	Porovnání stejné skupiny ve dvou různých situacích.
`ANOVA (Analýza rozptylu)`	`stats.f_oneway(A, B, C)`	Testování shody průměrů u tří a více skupin.
`Chí-kvadrát shoda`	`stats.chisquare(O, f_exp=E)`	Test dobré shody (např. spravedlivost kostky nebo náhodnost).
`Chí-kvadrát nezávislost`	`stats.chi2_contingency(table)`	Test závislosti kategoriálních znaků z kontingenční tabulky.
`Pearsonova korelace`	`stats.pearsonr(x, y)`	Měření síly lineární závislosti dvou spojitých proměnných.
`Spearmanova korelace`	`stats.spearmanr(x, y)`	Měření síly monotónní závislosti (i pro nelineární vztahy).

Návratové hodnoty a rozhodnutí:

- `res.pvalue`: Klíčová hodnota pro rozhodnutí. Pokud $p < \alpha$, nulovou hypotézu H_0 **zamítáme**.
- `res.statistic`: Hodnota testového kritéria (čím je vyšší, tím více se data liší od hypotézy).
- *Výjimka:* `chi2_contingency` vrací výsledky jako n-tici `(statistika, p-hodnota, df, expected_table)`.

5 Práce s daty v R (Cheatsheet)

5.1 Náhodné veličiny a rozdělení

`dxxx` = hustota pravděpodobnosti, `pxxx` = distribuční funkce $F(x)$, `qxxx` = kvantil, `rxxx` = náhodné číslo.

Normální rozdělení (`norm`)

Spojité rozdělení pro modelování např. výšky, chyby měření či doby čekání.
Parametry: `mean` (μ) = střední hodnota, `sd` (σ) = směrodatná odchylka.

Funkce	Příklad použití	Vysvětlení
`pnorm(x, mean, sd)`	`pnorm(16, mean=20, sd=4)`	`MÉNĚ NEŽ`: $P(X \leq x)$.
`1 - pnorm(x, mean, sd)`	`1 - pnorm(20, mean=20, sd=4)`	`VÍCE NEŽ`: $P(X > x)$.
`pnorm(b,m,s) - pnorm(a,m,s)`	`pnorm(28,20,4) - pnorm(12,20,4)`	`MEZI`: $P(a < X \leq b)$.
`qnorm(q, mean, sd)`	`qnorm(0.975, mean=0, sd=1)`	Kvantil: najde x pro $P(X \leq x) = q$.

Binomické rozdělení (`binom`)

Diskrétní rozdělení. Počet úspěchů v pevně daném počtu nezávislých pokusů.
Aproximace: Pokud je počet pokusů $n \geq 30$ a pravděpodobnost úspěchu $p \leq 0{,}05$, blíží se Poissonovu rozdělení ($\lambda = np$).
Parametry: `size` (n) = celkový počet pokusů, `prob` (p) = pravděpodobnost úspěchu.

Funkce	Příklad použití	Vysvětlení
`dbinom(k, size, prob)`	`dbinom(4, size=10, prob=1/6)`	`PŘESNĚ`: $P(X = k)$.
`pbinom(k, size, prob)`	`pbinom(2, size=10, prob=1/6)`	`NEJVÝŠE`: $P(X \leq k)$.
`1 - pbinom(k, size, prob)`	`1 - pbinom(2, size=10, prob=1/6)`	`VÍCE NEŽ`: $P(X > k)$.

Poissonovo rozdělení (`pois`)

Diskrétní rozdělení. Počet výskytů události za jednotku času nebo prostoru, když známe průměr.
Parametry: `lambda` (λ) = průměrný počet událostí za interval.

Funkce	Příklad použití	Vysvětlení
`dpois(k, lambda)`	`dpois(2, lambda=0.4)`	`PŘESNĚ`: $P(X = k)$.
`ppois(k, lambda)`	`ppois(2, lambda=0.4)`	`NEJVÝŠE`: $P(X \leq k)$.
`1 - ppois(k, lambda)`	`1 - ppois(2, lambda=0.4)`	`VÍCE NEŽ`: $P(X > k)$.

Hypergeometrické rozdělení (`hyper`)

Diskrétní rozdělení. Výběr **bez vracení** z konečné populace (např. zmetky v zásilce).
Aproximace: Pokud $\frac{k}{m+n} \leq 0{,}05$, výběr bez vracení se chová téměř jako výběr s vracením (Binomické).
Parametry: `m` = počet hledaných prvků v populaci, `n` = počet ostatních prvků v populaci, `k` = velikost výběru.

Funkce	Příklad použití	Vysvětlení
`dhyper(x, m, n, k)`	`dhyper(0, m=10, n=190, k=5)`	`PŘESNĚ`: $P(X = x)$, zde: 0 zmetků z populace 200 (10 zmetků), výběr 5.
`phyper(x, m, n, k)`	`phyper(2, m=10, n=190, k=5)`	`NEJVÝŠE`: $P(X \leq x)$.

Studentovo t-rozdělení (`t`)

Spojité rozdělení. Používá se pro intervaly spolehlivosti a testování, pokud neznáme rozptyl populace.
Parametry: `df` = stupně volnosti ($n - 1$ pro jednovýběrový t-test).

Funkce	Příklad použití	Vysvětlení
`pt(x, df)`	`pt(-1.96, df=19)`	Distribuční funkce $F(x) = P(T \leq x)$.
`qt(q, df)`	`qt(0.975, df=19)`	Kvantil: kritická hodnota pro t-test nebo IS.

Chí-kvadrát rozdělení (`chisq`) a F-rozdělení (`f`)

Funkce	Příklad použití	Vysvětlení
`pchisq(x, df)`	`pchisq(7.81, df=3)`	$P(\chi^2 \leq x)$ – distribuční funkce.
`qchisq(q, df)`	`qchisq(0.99, df=3)`	Kritická hodnota pro χ^2 test.
`pf(x, df1, df2)`	`pf(3.86, df1=2, df2=9)`	$P(F \leq x)$ – distribuční funkce pro ANOVA.
`qf(q, df1, df2)`	`qf(0.95, df1=2, df2=9)`	Kritická hodnota pro F-test (ANOVA).

5.2 Intervaly spolehlivosti a velikost výběru

Interval pro průměr (μ)

Kdy použít: Pro odhad průměrné hodnoty měřitelného znaku (váha, čas, délka).

- **Normální rozdělení:** Pokud známe σ^2 nebo je výběr velký ($n \geq 30$): použijeme `qnorm`.
- **t-rozdělení:** Neznámý σ^2 nebo malý výběr ($n < 30$): použijeme `qt` s `df = n-1`.

- **Jednostranný IS:** Kvantil $1 - \alpha$ místo $1 - \alpha/2$.

Parametry: `x` (vektor dat), `xbar` (průměr), `s` (výběrová směr. odchylka), `n` (rozsah), `alpha` (α).

Funkce	Příklad použití	Vysvětlení
`t.test(x)$conf.int`	`x <- c (163,175,177,165,171,174)` `t.test(x, conf.level = 0.95)$conf.int`	Vrací 95 % IS pro μ (neznámý σ^2).

Ručně (t-rozdělení)	`xbar <- mean(x); s <- sd(x)`
	`n <- length(x); alpha <- 0.05`
	`t_kr <- qt(1 - alpha/2, df = n - 1)`
	`c(xbar - t_kr*s/sqrt(n), xbar + t_kr*s/sqrt(n))`
		Ruční výpočet IS s t-rozdělením.

Ručně (Z, známý σ)	`sigma <- 7`
	`z_kr <- qnorm(1 - alpha/2)`
	`c(xbar - z_kr*sigma/sqrt(n), xbar + z_kr*sigma/sqrt(n))`
		Ruční výpočet IS s normálním rozdělením (Z-kvantil).

Interval pro podíl (π)

Kdy použít: Pro odhad procentuálního zastoupení (např. podíl zmetků, preference voličů).

- Vždy využíváme **normální rozdělení** (Z-kvantil).
- **Typy kvantilů:** Oboustranný: $1 - \alpha/2$, jednostranný: $1 - \alpha$.

Parametry: `x` (počet úspěchů), `n` (celkový počet), `p` = `x/n`.

Funkce	Příklad použití	Vysvětlení
`prop.test(x, n)$conf.int`	`prop.test(x=110, n=200, conf.level=0.95)$conf.int`	Wilsonův IS pro proporci (vestavěná funkce).

Ručně (Waldův IS)	`x_vol <- 110; n_vol <- 200`
	`p <- x_vol / n_vol`
	`z_kr <- qnorm(0.975)`
	`se <- sqrt(p*(1-p)/n_vol)`
	`c(p - z_kr*se, p + z_kr*se)`
		Waldův IS – jednoduchá normální aproximace.

Potřebná velikost výběru (n)

Kdy použít: Hledáme, kolik jednotek musíme vybrat (n), aby se náš odhad nemýlil o více než stanovenou chybu Δ.

- Výsledek **vždy zaokrouhlit nahoru** (funkce `ceiling()`), jinak by chyba byla větší než povolená.

Parametry: `delta` (Δ, požadovaná přesnost), `sigma` (předpokládaná směr. odchylka).

Funkce	Příklad použití	Vysvětlení

`Minimální n (průměr)`	`alpha <- 0.05; sigma <- 10`
	`delta <- 2  # pozadovana presnost`
	`z_kr <- qnorm(1 - alpha/2)`
	`ceiling((z_kr * sigma / delta)^2)`
		Pro průměr. Δ je cílová přesnost. Výsledek **vždy** zaokrouhli nahoru.

`Minimální n (podíl)`	`p <- 0.5; delta <- 0.05  # +-5 p.b.` `ceiling(p*(1-p)*(z_kr/delta)^2)  # 385`	Pro podíl. Používá se pro plánování reprezentativního výzkumu.

5.3 Testování hypotéz

Volba rozdělení: Pro $n \geq 30$ lze použít `qnorm`/`pnorm`, pro $n < 30$ použijeme `qt`/`pt` s `df = n-1`.
Parametry: `mu0` (testovaná hodnota), `xbar` (výběrový průměr), `s` (výběrová směr. odchylka), `n` (rozsah), `alpha` (α).

1. Jednovýběrový t-test (střední hodnota)

`T = (xbar - mu0) / (s / sqrt(n))` $\sim t(n-1)$

Typ testu	Alternativa H_1	p-hodnota v R
Levostranný	$\mu < \mu_0$	`pt(T, df=n-1)`
Pravostranný	$\mu > \mu_0$	`1 - pt(T, df=n-1)`
Oboustranný	$\mu \neq \mu_0$	`2*(1 - pt(abs(T), df=n-1))`

Funkce	Příklad použití	Vysvětlení
`t.test(x, mu=mu0, alternative=...)`	`t.test(x, mu = 25000, alternative = "less")` `# "greater" / "two.sided"`	Automatický t-test z vektoru dat.

Ručně	`n <- 49; xbar <- 23500; alpha <- 0.05`
	`mu0 <- 25000; s <- 5500`
	`T <- (xbar - mu0)/(s/sqrt(n))`
	`p_val <- pt(T, df = n - 1)`
	`t_kr <- qt(alpha, df = n - 1)`
		Ruční výpočet (jednostranný levostranný).

2. Párový t-test

Funkce	Příklad použití	Vysvětlení
`t.test(pred, po, paired=TRUE)`	`t.test(pred, po, paired = TRUE, alternative = "two.sided")`	Porovnání stejné skupiny ve dvou různých situacích (např. před a po zásahu).

3. Test proporce

$$Z = \frac{\hat{p} - \pi_0}{\sqrt{\pi_0(1-\pi_0)/n}} \sim N(0,1)$$

Funkce	Příklad použití	Vysvětlení
`prop.test(x, n, p=p0, ...)`	`prop.test(x=90, n=150, p=0.5, alternative="two.sided", correct=FALSE)`	Bez Yatesovy korekce odpovídá ručnímu Z-testu.

Ručně	`p0 <- 0.5; n <- 150; orel <- 90`
	`phat <- orel/n`
	`Z <- (phat-p0)/sqrt(p0*(1-p0)/n)`
	`z_kr <- qnorm(1 - 0.01/2)`
	`p_val <- 2*(1 - pnorm(abs(Z)))`
		Oboustranný Z-test symetrie mince ($\alpha = 0{,}01$).

4. Dvouvýběrový t-test (Welchův)

$$T = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$$

Funkce	Příklad použití	Vysvětlení
`t.test(x1, x2, var.equal=FALSE)`	`t.test(x1, x2, var.equal = FALSE, alternative = "two.sided")`	Welchův test (různé rozptyly).

Ručně (ze souhrnných statistik)	`n1<-38; x1<-5.3875; s1_2<-0.2698`
	`n2<-35; x2<-4.7; s2_2<-0.24`
	`T <- (x1-x2)/sqrt(s1_2/n1+s2_2/n2)`
	`df_w <- (s1_2/n1+s2_2/n2)^2 / ((s1_2/n1)^2/(n1-1)+(s2_2/n2)^2/(n2-1))`
	`p_val <- 2*(1-pt(abs(T), df=df_w))`
		Welch-Satterthwaiteovy stupně volnosti (s_1^2, s_2^2 jsou rozptyly).

5. Korelace

Funkce	Příklad použití	Vysvětlení
`cor.test(x, y)`	`cor.test(x, y, method = "pearson")`	Pearsonova korelace – měří sílu lineární závislosti dvou spojitých proměnných.
`cor.test(x, y, method=...)`	`cor.test(x, y, method = "spearman")`	Spearmanova korelace – měří sílu monotónní závislosti (i pro nelineární vztahy).

5.4 ANOVA (Jednocestná analýza rozptylu)

H$_0$: $\mu_1 = \mu_2 = \cdots = \mu_k$, **H$_1$:** alespoň dva průměry se liší.
Test je vždy **pravostranný**: zamítáme H_0, pokud $F \geq F_{1-\alpha}(k-1, n-k)$.

$$F = \frac{S_m/(k-1)}{S_v/(n-k)} \sim F(k-1, n-k)$$

Funkce	Příklad použití	Vysvětlení

`aov(y ~ skupina)`	`y <- c(91,81,74,57,`
	`  83,72,63,47,`
	`  71,69,58,40)`
	`skupina <- factor(rep(c("A`
	`  ","B","C"),`
	`  each`
	`  =4)`
	`  )`
	`m <- aov(y ~ skupina)`
	`summary(m)`
		Automatická ANOVA s tabulkou výsledků.

`Skupinové průměry`	`tapply(y, skupina, mean)`	Průměry v každé skupině.

`Kritická hodnota F`	`k <- nlevels(skupina); n <-`
	`  length(y)`
	`qf(0.95, df1 = k-1, df2 = n`
	`  -k)`
		Kvantil F-rozdělení pro $\alpha = 0{,}05$.

`Ručně (SS)`	`k <- nlevels(skupina); n <-`
	`  length(y)`
	`grand <- mean(y)`
	`SS_m <- sum(tapply(y,`
	`  skupina,`
	`  function(g) length(g)*(`
	`  mean(g)-grand)^2))`
	`SS_v <- sum(tapply(y,`
	`  skupina,`
	`  function(g) sum((g-mean(g`
	`  ))^2)))`
	`F_stat <- (SS_m/(k-1))/(`
	`  SS_v/(n-k))`
		Ruční výpočet součtů čtverců mezi skupinami a uvnitř skupin.

5.5 Chí-kvadrát testy

Test dobré shody

H_0: výběr odpovídá předpokládanému rozdělení.
$G = \sum_j \frac{(n_j - e_j)^2}{e_j} \sim \chi^2(k-1)$, kde $e_j = n \cdot \pi_{0,j}$.

Funkce	Příklad použití	Vysvětlení

`chisq.test(emp, p=p_teor)`	`emp <- c(A=82, B=38, AB=26, O=69)`
	`p0 <- c(A=0.41,B=0.14,AB=0.07,O=0.38)`
	`chisq.test(emp, p = p0)`
		Automatický test dobré shody. Vektor `p0` musí mít součet 1.

`Ručně`	`teor <- sum(emp) * p0`
	`G <- sum((emp - teor)^2 / teor)`
	`p_val <- 1 - pchisq(G, df= length(emp)-1)`
	`chi_kr <- qchisq(0.99, df= length(emp)-1)`
		Ruční výpočet testové statistiky a p-hodnoty.

Test nezávislosti (kontingenční tabulka)

H_0: řádkový a sloupcový znak jsou nezávislé.
$e_{ij} = \dfrac{n_{i\bullet}\, n_{\bullet j}}{n}, \quad G \sim \chi^2\big((r-1)(s-1)\big).$

Funkce	Příklad použití	Vysvětlení

`chisq.test(tabulka)`	`kt <- matrix(c(1768,807,189,47, 946,1387,746,53, 115,438,288,16), nrow=3, byrow= TRUE)`
	`res <- chisq.test(kt)`
	`res$p.value # p-hodnota`
	`res$expected # teoreticke cetnosti`
		Test nezávislosti z kontingenční tabulky.

`Cramérovo V`	`G <- as.numeric(res$statistic)`
	`n_celk <- sum(kt)`
	`r <- nrow(kt); s_kt <- ncol(kt)`
	`V <- sqrt(G / (n_celk*(min(r,s_kt)-1)))`
	`C <- sqrt(G / (G + n_celk))`
		Síla závislosti: $V \in [0,1]$. Pearsonův C závisí na rozměrech tabulky.

Interpretace Cramérova V (orientační, $df^* = \min(r,s) - 1$): $<$ 0,1 zanedbatelná · 0,1–0,3 slabá · 0,3–0,5 středně silná · $>$ 0,5 silná závislost.

Rozhodnutí pomocí p-hodnoty:

Podmínka	Výsledek testu
$p < \alpha$	**ZAMÍTÁME** H_0 (rozdíl je statisticky významný)
$p \geq \alpha$	**NEZAMÍTÁME** H_0 (rozdíl je pravděpodobně náhodný)

5.6 Korelační analýza

Pearsonův a Spearmanův korelační koeficient

H$_0$: $\rho = 0$ (žádná lineární/monotónní závislost). Testové kritérium $T = r\sqrt{(n-2)/(1-r^2)} \sim t(n-2)$.

Funkce	Příklad použití	Vysvětlení

`cor(x, y)`	`x <- c(1,2,0,5,3,4,2,6,1,3)`
	`y <- c(0,1,0,4,2,3,1,5,0,2)`
	`cor(x, y, method="pearson")`
	`# linearni`
	`cor(x, y, method="spearman")  # poradovy`
		Pearsonův koef. $r \in [-1, 1]$ měří lineární závislost; Spearmanův r_s měří monotónní závislost (neparametrický, odolný vůči odlehlým hodnotám).

`cor.test(x, y)`	`cor.test(x, y, method="pearson")` `cor.test(x, y, method="spearman")`	Test H_0: $\rho = 0$; výstup obsahuje p-hodnotu, testovou statistiku T a (pro Pearson) IS pro ρ.

Interpretace $|r|$: $< 0{,}3$ slabá · 0,3–0,7 střední · $> 0{,}7$ silná závislost. Znaménko udává směr.

5.7 Regresní analýza (jednoduchá lineární)

Koeficienty MNČ

$$b_1 = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}, \quad b_0 = \bar{y} - b_1\bar{x}, \quad \text{model: } \hat{y} = b_0 + b_1 x$$

Funkce	Příklad použití	Vysvětlení

`lm(y ~ x)`	`m <- lm(cena ~ naklady)`
	`summary(m)  # koef., R^2, testy`
	`coef(m)  # b0 a b1`
	`fitted(m)  # vyrovnane hodnoty`
	`residuals(m)  # rezidua e_i`
		Fituje lineární model; `summary` vrací koeficienty, R^2, t-testy i F-test automaticky.

`Koeficienty ručně`	`x_b <- mean(x); y_b <- mean(y)`
	`b1 <- sum((x-x_b)*(y-y_b)) / sum((x-x_b)^2)`
	`b0 <- y_b - b1 * x_b`
		Ruční výpočet metodou nejmenších čtverců (minimalizace $Q = \sum e_i^2$).

`Součty čtverců a` R^2	`SS_tot <- sum((y - mean(y))^2)  # S_Y`
	`SS_reg <- sum((fitted(m)-mean(y))^2)  # S_T`
	`SS_res <- sum(residuals(m)^2)  # S_R`
	`R2 <- SS_reg / SS_tot`
	`summary(m)$r.squared  # zkratka`
		$S_Y = S_T + S_R$; $R^2 = S_T/S_Y \in [0,1]$ – podíl rozptylu Y vysvětlený modelem.

`t-test pro` b_1	`n <- length(x)`
	`se_b1 <- sqrt(SS_res/(n-2) / sum((x-mean(x))^2))`
	`t_stat <- b1 / se_b1`
	`qt(0.975, df=n-2)  # krit. hodnota`
	`2*(1-pt(abs(t_stat), df=n-2))  # p-val`
		$H_0\colon \beta_1 = 0$; $T = b_1/s_{b_1} \sim t(n-2)$; zamítáme při $\lvert T\rvert \geq t_{1-\alpha/2}(n-2)$.

`F-test modelu`	`F_stat <- (SS_reg/1)/(SS_res/(n-2))` `qf(0.95, df1=1, df2=n-2)`	$H_0\colon \beta_1 = 0$; $F = S_T/\big(S_R/(n-2)\big) \sim F(1; n-2)$; pro jednoduchou regresi ekvivalentní t-testu.
`Predikce`	`predict(m, newdata=data.frame(naklady=80))` `predict(m, newdata=data.frame(naklady=80), interval="confidence")`	Bodová predikce i IS pro střední hodnotu Y při nové hodnotě X.

5.8 Časové řady

Charakteristiky: diference a tempa růstu

1. diference: $\Delta y_t = y_t - y_{t-1}$ Tempo růstu: $k_t = y_t/y_{t-1}$ Průměrné tempo: $\bar{k} = \sqrt[n-1]{y_n/y_1}$

Funkce	Příklad použití	Vysvětlení

`diff(y)`	`y <- c (5274,5288,5297,5318,5338,5356)`
	`diff(y) # 1. diference`
	`diff(diff(y)) # 2. diference`
		Absolutní přírůstky první a druhé řádu.

`Tempo růstu`	`n <- length(y)`
	`tempo <- y[-1] / y[-n]`
	`prum_tempo <- (y[n]/y[1]) ^(1/(n-1))`
		Mezičasové indexy k_t a průměrné tempo růstu (geometrický průměr).

`Chronologický průměr`	`# Pro okamzikovou CR (stejne intervaly)`
	`n <- length(y)`
	`(y[1]/2 + sum(y[2:(n-1)]) + y[n]/2) / (n-1)`
		Průměr okamžikové časové řady; krajní hodnoty mají váhu $\frac{1}{2}$.

Klouzavé průměry

Prostý KP (liché $m = 2p + 1$): symetrické okno $\pm p$. Centrovaný KP (sudé m): průměr dvou po sobě jdoucích prostých KP délky m.

Funkce	Příklad použití	Vysvětlení
`filter(y, rep(1/m, m))`	`m <- 5 # liche m -- prosty KP` `kp <- filter(y, rep(1/m,m), sides=2)`	Prostý klouzavý průměr; `sides=2` = symetrické okno. Odstraňuje sezónnost liché délky m.

`Centrovaný KP (sudé m)`	`m <- 4 # sude m -- centrovany KP`
	`kp_l <- filter(y, rep(1/m,m), sides=1)`
	`kp_c <- (kp_l + c(NA, kp_l[-length(kp_l)])) / 2`
		`sides=1`: průměr posledních m hodnot. Centrovaný KP = průměr dvou sousedních prostých KP.

Trend a sezónnost – regresní přístup

Model: $y_t = \beta_0 + \beta_1 t + \gamma_1 D_1 + \gamma_2 D_2 + \gamma_3 D_3 + \varepsilon_t$ (pro sezónnost délky 4; D_j jsou dummy proměnné; 4. čtvrtletí je referenční kategorie).

Funkce	Příklad použití	Vysvětlení

`Dummy proměnné`	`t <- 1:length(y)`
	`Q2 <- as.integer(t %% 4 == 2)`
	`Q3 <- as.integer(t %% 4 == 3)`
	`Q4 <- as.integer(t %% 4 == 0)`
	`# Q1 je referencni (t %% 4 == 1)`
		Vždy o jednu méně dummy než sezón – jinak hrozí multikolinearita.

`lm() s trendem`	`m <- lm(y ~ t + Q2 + Q3 + Q4)`
	`summary(m)`
	`fitted(m)  # vyrovnane hodnoty`
		Odhaduje lineární trend a sezónní odchylky; $\hat{\gamma}_j$ = odchylka j-tého čtvrtletí od referenčního.

`Predikce`	`t_n <- 21:24`
	`nd <- data.frame(`
	`  t  = t_n,`
	`  Q2 = as.integer(t_n %% 4 == 2),`
	`  Q3 = as.integer(t_n %% 4 == 3),`
	`  Q4 = as.integer(t_n %% 4 == 0))`
	`predict(m, newdata = nd)`
		Predikce na budoucí kvartály; sestavit `data.frame` s t a dummy proměnnými pro každé nové pozorování.