VYSOKÁ ŠKOLA EKONOMICKÁ V PRAZE
FAKULTA INFORMATIKY A STATISTIKY

STATISTIKA PRO INFORMATIKY

VZORCE PRO 4ST204

Obsah

1 Popisná Statistika **4**
1.1 Četnosti . . . 4
1.1.1 Absolutní četnost . . . 4
1.1.2 Součet absolutních četností . . . 4
1.1.3 Relativní Četnost . . . 4
1.1.4 Součet relativních četností . . . 4
1.1.5 Kumulativní absolutní četnost . . . 5
1.1.6 Kumulativní relativní četnost . . . 5
1.2 Charakteristiky polohy . . . 6
1.2.1 Aritmetický průměr . . . 6
1.2.2 Vážený aritmetický průměr (z četnostní tabulky) . . . 6
1.2.3 Aritmetický průměr pomocí relativních četností . . . 7
1.2.4 Harmonický průměr . . . 8
1.2.5 Geometrický průměr . . . 9
1.2.6 Vztah mezi průměry . . . 9
1.2.7 Medián . . . 10
1.2.8 Kvantily a kvartily . . . 10
1.2.9 Interkvartilové rozpětí (IQR) . . . 11
1.2.10 Modus . . . 12
1.3 Charakteristiky variability . . . 13
1.3.1 Variační rozpětí . . . 13
1.3.2 Rozptyl statistického souboru . . . 13
1.3.3 Výběrový rozptyl . . . 14
1.3.4 Vážený rozptyl . . . 15
1.3.5 Směrodatná odchylka statistického souboru . . . 16
1.3.6 Výběrová směrodatná odchylka . . . 16
1.3.7 Variační koeficient . . . 17
1.3.8 Střední absolutní odchylka (MAD) . . . 17
1.3.9 Detekce odlehlých hodnot – Tukeyovy meze . . . 18

2 Teorie pravděpodobnosti **20**
2.1 Počet pravděpodobnosti . . . 20
2.1.1 Klasická definice pravděpodobnosti . . . 20
2.1.2 Pravděpodobnost komplementárního jevu . . . 20
2.1.3 Horní odhad pravděpodobnosti průniku . . . 20
2.1.4 Průnik nezávislých jevů . . . 20
2.1.5 Sjednocení dvou jevů . . . 21
2.1.6 Sjednocení neslučitelných jevů . . . 21
2.1.7 Podmíněná pravděpodobnost . . . 21
2.1.8 Věta o úplné pravděpodobnosti . . . 21
2.2 Náhodné veličiny . . . 22
2.2.1 Pravděpodobnostní funkce diskrétní náhodné veličiny . . . 22
2.2.2 Distribuční funkce diskrétní náhodné veličiny . . . 22
2.2.3 Pravděpodobnost intervalu . . . 22
2.2.4 Střední hodnota diskrétní náhodné veličiny . . . 23
2.2.5 Rozptyl diskrétní náhodné veličiny . . . 23
2.2.6 Hustota pravděpodobnosti spojité náhodné veličiny . . . 23
2.2.7 Normalizační podmínka hustoty pravděpodobnosti . . . 24
2.2.8 Distribuční funkce spojité náhodné veličiny . . . 24
2.2.9 Pravděpodobnost intervalu spojité náhodné veličiny . . . 24

2.2.10 Střední hodnota spojité náhodné veličiny . . . 25
2.2.11 Rozptyl spojité náhodné veličiny . . . 25
2.2.12 Směrodatná odchylka náhodné veličiny . . . 25
2.3 Vlastnosti střední hodnoty a rozptylu . . . 26
2.3.1 Vlastnosti střední hodnoty $E(X)$ . . . 26
2.3.2 Vlastnosti rozptylu $D(X)$ . . . 26

3 Kombinatorika a Metriky **27**
3.1 Kombinatorika . . . 27

4 Pravděpodobnostní rozdělení **28**
4.1 Diskrétní rozdělení . . . 28
4.1.1 Binomické rozdělení $\mathrm{Bin}(n, p)$ . . . 28
4.1.2 Poissonovo rozdělení $\mathrm{Pois}(\lambda)$ . . . 28
4.1.3 Hypergeometrické rozdělení $\mathrm{Hyper}(N, K, n)$ . . . 29
4.2 Spojitá rozdělení . . . 30
4.2.1 Normální rozdělení $N(\mu, \sigma^2)$ . . . 30
4.2.2 Rovnoměrné rozdělení $U(a, b)$ . . . 31
4.2.3 Exponenciální rozdělení $\mathrm{Exp}(\lambda)$ . . . 32
4.3 Odvozená rozdělení . . . 33
4.3.1 Studentovo t-rozdělení $t(\nu)$ . . . 33
4.3.2 Chí-kvadrát rozdělení $\chi^2(k)$ . . . 34
4.3.3 F-rozdělení $F(k_1, k_2)$ . . . 35

5 Testování hypotéz **37**
5.1 Bodový odhad . . . 37
5.2 Intervaly spolehlivosti a velikost výběru . . . 37
5.2.1 Interval pro průměr (μ) . . . 37
5.2.2 Interval pro podíl (π) . . . 38
5.2.3 Potřebná velikost výběru (n) . . . 39
5.3 Jednovýběrový t-test (střední hodnota) . . . 40
5.4 Dvouvýběrový t-test (Welchův) . . . 41
5.5 Párový t-test . . . 41
5.6 Test proporce (Z-test) . . . 42
5.7 Jednocestná analýza rozptylu (ANOVA) . . . 42
5.8 Chí-kvadrát test dobré shody . . . 43
5.9 Chí-kvadrát test nezávislosti . . . 44

6 Analýza závislosti **46**
6.1 Korelační analýza . . . 46
6.1.1 Pearsonův korelační koeficient . . . 46
6.1.2 Spearmanův korelační koeficient . . . 46
6.2 Jednoduchá lineární regrese . . . 47
6.2.1 Odhad koeficientů (MNČ) . . . 47
6.2.2 Součty čtverců a koeficient determinace R^2 . . . 47
6.2.3 t-test a F-test platnosti modelu . . . 48
6.2.4 Predikce . . . 49

7 Časové řady **50**
7.1 Základní charakteristiky . . . 50
7.1.1 Absolutní přírůstky a tempa růstu . . . 50
7.1.2 Chronologický průměr . . . 50
7.2 Klouzavé průměry . . . 51
7.2.1 Prostý klouzavý průměr (liché m) . . . 51
7.2.2 Centrovaný klouzavý průměr (sudé m) . . . 51
7.3 Trend a sezónnost – regresní přístup . . . 52
7.3.1 Dummy proměnné a model . . . 52
7.3.2 Predikce na budoucí období . . . 52

8 Příloha: Utility funkce v Pythonu **54**
8.1 Užitečné knihovny a základy . . . 54
8.2 Práce s poli (Standardní Python) . . . 54
8.3 Základní Python (Built-in & Math) . . . 55
8.4 Statistika a Matice (Knihovna NumPy a jiné) . . . 56
8.5 Pandas: Analýza dat . . . 58
8.6 Matplotlib a Seaborn: Vizualizace . . . 59
8.7 Náhodné veličiny a rozdělení . . . 59

9 Příloha: Utility funkce v R **63**
9.1 Náhodné veličiny a rozdělení . . . 63
9.2 Práce s daty v R . . . 66

1 Popisná Statistika

1.1 Četnosti

1.1.1 Absolutní četnost

Absolutní četnost i-té hodnoty je počet výskytů dané hodnoty ve výběru.

$$n_i$$

kde

- n_i je počet výskytů i-té hodnoty ve výběru.

1.1.2 Součet absolutních četností

Součet absolutních četností všech hodnot (nebo tříd) ve výběru se rovná celkovému počtu pozorování.

$$\sum_{i=1}^{k} n_i = n$$

kde

- $\sum$ je sumační znak (značí sčítání),
- i je index hodnoty nebo třídy,
- k je počet různých hodnot nebo tříd,
- n_i je absolutní četnost i-té hodnoty (nebo třídy),
- n je celkový počet pozorování.

1.1.3 Relativní Četnost

Relativní četnost i-té hodnoty ve výběru je definována jako podíl absolutní četnosti dané hodnoty a celkového počtu pozorování,

$$p_i = \frac{n_i}{n}$$

kde

- p_i je relativní četnost i-té hodnoty,
- n_i je absolutní četnost i-té hodnoty (kolikrát se hodnota vyskytla),
- n je celkový počet pozorování v souboru.

1.1.4 Součet relativních četností

Součet relativních četností všech hodnot (nebo tříd) ve výběru je roven jedné.

$$\sum_{i=1}^{k} p_i = 1$$

kde

- $\sum$ je sumační znak (značí sčítání),
- i je index hodnoty nebo třídy,
- k je počet různých hodnot nebo tříd,
- p_i je relativní četnost i-té hodnoty (nebo třídy).

1.1.5 Kumulativní absolutní četnost

Kumulativní absolutní četnost i-té hodnoty je součet absolutních četností všech hodnot až do i-té (včetně).

$$N_i = \sum_{j=1}^{i} n_j$$

kde

- N_i je kumulativní absolutní četnost i-té hodnoty,
- n_j je absolutní četnost j-té hodnoty,
- i je index hodnoty nebo třídy.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`cumsum(ni)`	`ni <- c(5, 10, 8, 7)` `Ni <- cumsum(ni)`	Vrací kumulativní součty vektoru absolutních četností.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.cumsum(ni)`	`import numpy as np`
	`ni = np.array([5, 10, 8, 7])`
	`Ni = np.cumsum(ni)`
		Vrací kumulativní součty pole absolutních četností.

1.1.6 Kumulativní relativní četnost

Kumulativní relativní četnost i-té hodnoty je součet relativních četností všech hodnot až do i-té (včetně). Odpovídá hodnotám empirické distribuční funkce; platí $P_k = 1$.

$$P_i = \sum_{j=1}^{i} p_j$$

kde

- P_i je kumulativní relativní četnost i-té hodnoty,
- p_j je relativní četnost j-té hodnoty,
- i je index hodnoty nebo třídy.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`cumsum(pi)`	`ni <- c(5, 10, 8, 7)`
	`pi <- ni / sum(ni)`
	`Pi <- cumsum(pi)`
		Vrací kumulativní relativní četnosti.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.cumsum(pi)`	`import numpy as np`
	`ni = np.array([5, 10, 8, 7])`
	`pi = ni / ni.sum()`
	`Pi = np.cumsum(pi)`
		Vrací kumulativní relativní četnosti.

1.2 Charakteristiky polohy

1.2.1 Aritmetický průměr

Aritmetický průměr (výběrový průměr) je definován jako součet všech hodnot statistického souboru dělený počtem pozorování.

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

kde

- $\bar{x}$ je aritmetický průměr,
- $\sum$ je sumační znak (součet hodnot),
- x_i je i-tá hodnota statistického souboru,
- i je index hodnoty,
- n je počet pozorování.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`mean(x)`	`x <- c(1,2,3,4,5)` `mean(x)`	Vrací aritmetický průměr hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.mean(x)`	`import numpy as np`
	`x = np.array([1,2,3,4,5])`
	`np.mean(x)`
		Vrací aritmetický průměr pole pomocí knihovny `numpy`.

1.2.2 Vážený aritmetický průměr (z četnostní tabulky)

Pokud jsou data zadána pomocí četnostní tabulky, aritmetický průměr lze vypočítat jako vážený průměr hodnot.

$$\bar{x} = \frac{\sum_{i=1}^{k} x_i n_i}{\sum_{i=1}^{k} n_i}$$

kde

- $\bar{x}$ je aritmetický průměr,
- $\sum$ je sumační znak (součet),
- x_i je i-tá hodnota znaku,
- n_i je absolutní četnost i-té hodnoty,
- k je počet různých hodnot nebo tříd,
- $\sum_{i=1}^{k} n_i$ je celkový počet pozorování.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`weighted.mean(x, w)`	`x <- c(1,2,3)`
	`w <- c(2,3,5)`
	
	`weighted.mean(x, w)`
		Vrací vážený průměr hodnot ve vektoru `x` s váhami `w`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.average(x, weights=w)`	`import numpy as np`
	
	`x = np.array([1,2,3])`
	`w = np.array([2,3,5])`
	
	`np.average(x, weights=w)`
		Vrací vážený průměr hodnot ve vektoru `x` s váhami `w`.

1.2.3 Aritmetický průměr pomocí relativních četností

Pokud jsou data vyjádřena pomocí relativních četností, lze aritmetický průměr vypočítat jako vážený součet hodnot.

$$\bar{x} = \sum_{i=1}^{k} x_i p_i$$

kde

- $\bar{x}$ je aritmetický průměr,
- $\sum$ je sumační znak (součet),
- x_i je i-tá hodnota znaku,
- p_i je relativní četnost i-té hodnoty,
- i je index hodnoty,
- k je počet různých hodnot nebo tříd.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`sum(x * p)`	`x <- c(1,2,3)`
	`p <- c(0.2,0.3,0.5)`
	
	`sum(x * p)`
		Vrací aritmetický průměr vypočtený pomocí relativních četností.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.sum(x * p)`	`import numpy as np`
	
	`x = np.array([1,2,3])`
	`p = np.array([0.2,0.3,0.5])`
	
	`np.sum(x * p)`
		Vrací aritmetický průměr vypočtený pomocí relativních četností pomocí knihovny `numpy`.

1.2.4 Harmonický průměr

Harmonický průměr je definován jako podíl počtu pozorování a součtu převrácených hodnot jednotlivých pozorování.

$$\bar{x}_H = \frac{n}{\sum_{i=1}^{n} \frac{1}{x_i}}$$

kde

- $\bar{x}_H$ je harmonický průměr,
- n je počet pozorování,
- $\sum$ je sumační znak (součet),
- x_i je i-tá hodnota statistického souboru,
- $\frac{1}{x_i}$ je převrácená hodnota i-tého pozorování.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`n / sum(1/x)`	`x <- c(1,2,4,5)`
	`n <- length(x)`
	
	`n / sum(1/x)`
		Vrací harmonický průměr hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`scipy.stats.hmean(x)`	`from scipy.stats import hmean`
	
	`x = [1,2,4,5]`
	
	`hmean(x)`
		Vrací harmonický průměr pomocí funkce `hmean` z knihovny `scipy.stats`.

1.2.5 Geometrický průměr

Geometrický průměr je definován jako n-tá odmocnina součinu všech hodnot statistického souboru.

$$\bar{x}_G = \sqrt[n]{\prod_{i=1}^{n} x_i} = \sqrt[n]{x_1 \cdot x_2 \cdots x_n}$$

kde

- $\bar{x}_G$ je geometrický průměr,
- $\prod$ je znak pro součin (násobení všech hodnot),
- x_i je i-tá hodnota statistického souboru,
- i je index hodnoty,
- n je počet pozorování,
- $\sqrt[n]{\cdot}$ značí n-tou odmocninu.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`exp(mean(log(x)))`	`x <- c(1,2,3,4)`
	
	`exp(mean(log(x)))`
		Vrací geometrický průměr hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`scipy.stats.gmean(x)`	`from scipy.stats import gmean`
	
	`x = [1,2,3,4]`
	
	`gmean(x)`
		Vrací geometrický průměr pomocí funkce `gmean` z knihovny `scipy.stats`.

1.2.6 Vztah mezi průměry

$$\bar{x}_H \leq \bar{x}_G \leq \bar{x}$$

kde

- $\bar{x}_H$ je harmonický průměr,
- $\bar{x}_G$ je geometrický průměr,
- $\bar{x}$ je aritmetický průměr.

1.2.7 Medián

Medián je hodnota, která rozděluje uspořádaný statistický soubor na dvě stejně početné části. Medián také vyjadřuje 50% kvantil.

$$\tilde{x} = \begin{cases} x_{(\frac{n+1}{2})}, & \text{je-li } n \text{ liché,} \\ \frac{x_{(\frac{n}{2})}+x_{(\frac{n}{2}+1)}}{2}, & \text{je-li } n \text{ sudé.} \end{cases}$$

kde

- $\tilde{x}$ je medián,
- $x_{(i)}$ je i-tá hodnota v uspořádaném statistickém souboru,
- n je počet pozorování.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`median(x)`	`x <- c(1,3,2,5,4)` `median(x)`	Vrací medián hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.median(x)`	`import numpy as np`
	
	`x = np.array([1,3,2,5,4])`
	`np.median(x)`
		Vrací medián hodnot ve vektoru `x`.

1.2.8 Kvantily a kvartily

Kvantily rozdělují uspořádaný statistický soubor na části se stejným počtem pozorování.

q-kvantil je hodnota x_q, pro kterou platí

$$P(X \leq x_q) = q$$

kde

- x_q je q-kvantil,
- $q \in (0, 1)$ je pořadí kvantilu,
- $P(X \leq x_q)$ je pravděpodobnost, že náhodná veličina nabývá hodnot menších nebo rovných x_q.

Speciálním případem kvantilů jsou kvartily, které rozdělují data na čtyři stejně velké části.

$$Q_1 = x_{0.25}, \qquad Q_2 = x_{0.5}, \qquad Q_3 = x_{0.75}$$

kde

- Q_1 je první kvartil (25% dat je menších),
- Q_2 je druhý kvartil, který odpovídá mediánu,
- Q_3 je třetí kvartil (75% dat je menších).

Implementace v R

Funkce	Příklad použití	Vysvětlení

`quantile(x)`	`x <- c(1,2,3,4,5,6,7,8)`
	
	`quantile(x)`
		Vrací kvantily datového vektoru.

`quantile(x, probs=c(0.25, 0.5, 0.75))`	`x <- c(1,2,3,4,5,6,7,8)`
	
	`quantile(x, probs=c (0.25,0.5,0.75))`
		Vrací první, druhý a třetí kvartil.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.quantile(x,q)`	`import numpy as np`
	
	`x = np.array ([1,2,3,4,5,6,7,8])`
	
	`np.quantile(x,0.5)`
		Vrací q-kvantil pole.

`np.quantile(x, [0.25,0.5,0.75])`	`import numpy as np`
	
	`x = np.array ([1,2,3,4,5,6,7,8])`
	
	`np.quantile(x ,[0.25,0.5,0.75])`
		Vrací první, druhý a třetí kvartil.

1.2.9 Interkvartilové rozpětí (IQR)

Interkvartilové rozpětí (IQR) je rozdíl mezi třetím a prvním kvartilem. Vyjadřuje rozptyl prostředních 50 % dat.

$$IQR = Q_3 - Q_1$$

kde

- IQR je interkvartilové rozpětí,

- Q_1 je první kvartil,
- Q_3 je třetí kvartil.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`IQR(x)`	`x <- c(1,2,3,4,5,6,7,8)`
	
	`IQR(x)`
		Vrací interkvartilové rozpětí datového vektoru.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.quantile(x,0.75)`
`-`
`np.quantile(x,0.25)`
	`import numpy as np`
	
	`x = np.array`
	`([1,2,3,4,5,6,7,8])`
	
	`np.quantile(x,0.75) - np.`
	`quantile(x,0.25)`
		Vrací interkvartilové rozpětí pole.

1.2.10 Modus

Modus je hodnota, která se ve statistickém souboru vyskytuje nejčastěji (s nejvyšší absolutní četností). Soubor může mít i více modů. U spojitých proměnných se modus stanovuje po diskretizaci do intervalů.

$$\hat{x} = x_{\arg\max_i n_i}$$

kde

- $\hat{x}$ je modus,
- n_i je absolutní četnost i-té hodnoty,
- $\arg\max_i$ označuje index hodnoty s nejvyšší četností.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`names(which.max(table(x)))`	`x <- c(1, 2, 2, 3, 3, 3, 4)` `names(which.max(table(x)))`	Vrací modus (nejčastější hodnotu) vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`statistics.mode(x)`	`import statistics`
	`x = [1, 2, 2, 3, 3, 3, 4]`
	`statistics.mode(x)`
		Vrací modus pomocí standardní knihovny Pythonu.

1.3 Charakteristiky variability

1.3.1 Variační rozpětí

Variační rozpětí je rozdíl mezi maximální a minimální hodnotou statistického souboru.

$$R = x_{\max} - x_{\min}$$

kde

- R je variační rozpětí,
- $x_{\max}$ je maximální hodnota v souboru,
- $x_{\min}$ je minimální hodnota v souboru.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`max(x) - min(x)`	`x <- c(3,7,2,9,5)`
	
	`max(x) - min(x)`
		Vrací variační rozpětí hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.max(x) - np.min(x)`	`import numpy as np`
	
	`x = np.array([3,7,2,9,5])`
	
	`np.max(x) - np.min(x)`
		Vrací variační rozpětí hodnot ve vektoru `x`.

1.3.2 Rozptyl statistického souboru

Rozptyl vyjadřuje průměrnou kvadratickou odchylku hodnot od aritmetického průměru.

$$s_x^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n}$$

kde

- s_x^2 je rozptyl statistického souboru,
- $\sum$ je sumační znak (součet),
- x_i je i-tá hodnota statistického souboru,
- $\bar{x}$ je aritmetický průměr,

- $x_i - \bar{x}$ je odchylka hodnoty od průměru,
- $(x_i - \bar{x})^2$ je čtverec odchylky,
- n je počet pozorování.

Výpočetní tvar rozptylu:

$$s_x^2 = \frac{\sum_{i=1}^{n} x_i^2}{n} - \left(\frac{\sum_{i=1}^{n} x_i}{n}\right)^2$$

Implementace v R

Funkce	Příklad použití	Vysvětlení
`mean((x - mean(x))^2)`	`x <- c(2,4,6,8)` `mean((x-mean(x))^2)`	Vrací nevýběrový (populační) rozptyl hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.var(x)`	`import numpy as np`
	`x = np.array([2,4,6,8])`
	`np.var(x)`
		Vrací nevýběrový (populační) rozptyl pomocí knihovny `numpy`.

1.3.3 Výběrový rozptyl

Výběrový rozptyl je nezkreslený odhad rozptylu populace a vznikne úpravou rozptylu statistického souboru pomocí Besselovy korekce.

$$S^2 = \frac{n}{n-1} s_x^2$$

kde

- S^2 je výběrový rozptyl,
- s_x^2 je rozptyl statistického souboru,
- n je počet pozorování,
- $n - 1$ je korekce při odhadu rozptylu (Besselova korekce).

Implementace v R

Funkce	Příklad použití	Vysvětlení
`var(x)`	`x <- c(2,4,6,8)` `var(x)`	Vrací výběrový rozptyl hodnot ve vektoru `x` (dělí se $n - 1$).

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.var(x, ddof=1)`	`import numpy as np`
	
	`x = np.array([2,4,6,8])`
	
	`np.var(x, ddof=1)`
		Vrací výběrový rozptyl pomocí knihovny `numpy` (Besselova korekce).

1.3.4 Vážený rozptyl

Vážený rozptyl vyjadřuje variabilitu hodnot znaku, když mají jednotlivé hodnoty různé váhy nebo relativní četnosti.

$$s^2 = \sum_{i=1}^{k} p_i (x_i - \bar{x})^2$$

kde

- s^2 je vážený rozptyl,
- x_i je i-tá hodnota znaku,
- $\bar{x}$ je vážený aritmetický průměr,
- p_i je váha nebo relativní četnost i-té hodnoty,
- k je počet různých hodnot nebo tříd.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`weighted.mean( (x-mean(x))^2, w)`	`x <- c(1,2,3,4)`
	`w <- c(0.1,0.2,0.3,0.4)`
	
	`weighted.mean((x-weighted.`
	`  mean(x,w))^2, w)`
		Vrací vážený rozptyl hodnot s váhami `w`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.average( (x-xbar)**2, weights=w)`	`import numpy as np`
	
	`x = np.array([1,2,3,4])`
	`w = np.array`
	`  ([0.1,0.2,0.3,0.4])`
	
	`xbar = np.average(x,`
	`  weights=w)`
	`np.average((x-xbar)**2,`
	`  weights=w)`
		Vrací vážený rozptyl hodnot s váhami `w` pomocí knihovny `numpy`.

1.3.5 Směrodatná odchylka statistického souboru

Směrodatná odchylka je druhá odmocnina rozptylu statistického souboru.

$$s_x = \sqrt{s_x^2}$$

kde

- s_x je směrodatná odchylka,
- s_x^2 je rozptyl statistického souboru,
- $\sqrt{\cdot}$ značí druhou odmocninu.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`sqrt(mean((x-mean(x))^2))`	`x <- c(2,4,6,8)` `sqrt(mean((x-mean(x))^2))`	Vrací směrodatnou odchylku statistického souboru.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.std(x)`	`import numpy as np`
	`x = np.array([2,4,6,8])`
	`np.std(x)`
		Vrací směrodatnou odchylku pole (nevýběrovou).

1.3.6 Výběrová směrodatná odchylka

Výběrová směrodatná odchylka je odmocnina z výběrového rozptylu.

$$S = \sqrt{S^2}$$

kde

- S je výběrová směrodatná odchylka,
- S^2 je výběrový rozptyl,
- $\sqrt{\cdot}$ značí druhou odmocninu.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`sd(x)`	`x <- c(2,4,6,8)` `sd(x)`	Vrací výběrovou směrodatnou odchylku (dělí se $n-1$).

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.std(x, ddof=1)`	`import numpy as np`
	`x = np.array([2,4,6,8])`
	`np.std(x, ddof=1)`
		Vrací výběrovou směrodatnou odchylku (Besselova korekce).

1.3.7 Variační koeficient

Variační koeficient vyjadřuje relativní variabilitu dat a udává poměr směrodatné odchylky k aritmetickému průměru.

$$v_x = \frac{s_x}{\bar{x}}$$

kde

- v_x je variační koeficient,
- s_x je směrodatná odchylka,
- $\bar{x}$ je aritmetický průměr.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`sd(x) / mean(x)`	`x <- c(2,4,6,8)` `sd(x) / mean(x)`	Vrací variační koeficient hodnot ve vektoru `x`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.std(x) / np.mean(x)`	`import numpy as np`
	`x = np.array([2,4,6,8])`
	`np.std(x) / np.mean(x)`
		Vrací variační koeficient hodnot ve vektoru `x`.

1.3.8 Střední absolutní odchylka (MAD)

Střední absolutní odchylka (medián absolutních odchylek od mediánu) je robustní míra variability odolná vůči odlehlým hodnotám.

$$\text{MAD} = \text{median}\big(|x_i - \tilde{x}|\big)$$

kde

- MAD je střední absolutní odchylka,

- x_i jsou hodnoty statistického souboru,
- $\tilde{x}$ je medián,
- $|\cdot|$ označuje absolutní hodnotu.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`mad(x)`	`x <- c(2, 4, 6, 8, 100)`
	`mad(x)  #`
	`  sk lovan  (x 1.4826)`
	`mad(x, constant=1)#`
	`  ne kalovan  MAD`
		R automaticky škáluje MAD faktorem 1,4826 pro konzistenci se σ normálního rozdělení.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`np.median(np.abs(x - np.median(x)))`	`import numpy as np`
	`x = np.array([2, 4, 6, 8, 100])`
	`np.median(np.abs(x - np.median(x)))`
		Neškalovaný MAD pomocí knihovny `numpy`.

1.3.9 Detekce odlehlých hodnot – Tukeyovy meze

Hodnota je považována za odlehlou (outlier), pokud leží mimo interval ohraničený Tukeyovými mezemi. Tyto meze zobrazuje boxplot automaticky.

$$\text{dolní mez} = Q_1 - 1{,}5 \cdot IQR, \qquad \text{horní mez} = Q_3 + 1{,}5 \cdot IQR$$

kde

- Q_1 je první kvartil,
- Q_3 je třetí kvartil,
- $IQR = Q_3 - Q_1$ je interkvartilové rozpětí.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`Tukeyovy meze`	`q1  <- quantile(x, 0.25)`
	`q3  <- quantile(x, 0.75)`
	`iqr <- IQR(x)`
	`dolni  <- q1 - 1.5 * iqr`
	`horni  <- q3 + 1.5 * iqr`
	`outliers <- x[x < dolni | x > horni]`
		Identifikace odlehlých hodnot. Boxplot tyto meze zobrazuje automaticky jako vousy.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`Tukeyovy meze`	`import numpy as np`
	`q1, q3 = np.quantile(x, [0.25, 0.75])`
	`iqr = q3 - q1`
	`outliers = x[(x < q1 - 1.5*iqr) |`
	`(x > q3 + 1.5*iqr)]`
		Identifikace odlehlých hodnot.

2 Teorie pravděpodobnosti

2.1 Počet pravděpodobnosti

2.1.1 Klasická definice pravděpodobnosti

Pravděpodobnost jevu A při klasické definici pravděpodobnosti je podíl počtu příznivých výsledků a celkového počtu stejně pravděpodobných výsledků.

$$P(A) = \frac{m}{n}$$

kde

- $P(A)$ je pravděpodobnost jevu A,
- m je počet příznivých výsledků,
- n je počet všech možných výsledků.

2.1.2 Pravděpodobnost komplementárního jevu

Pravděpodobnost opačného (komplementárního, doplňkového) jevu k jevu A je rovna jedné minus pravděpodobnost jevu A.

$$P(\overline{A}) = 1 - P(A)$$

kde

- $P(\overline{A})$ je pravděpodobnost opačného jevu k A,
- $P(A)$ je pravděpodobnost jevu A.

2.1.3 Horní odhad pravděpodobnosti průniku

Pravděpodobnost současného nastání dvou jevů nemůže být větší než pravděpodobnost kteréhokoli z nich.

$$P(A \cap B) \leq \min(P(A), P(B))$$

kde

- $P(A \cap B)$ je pravděpodobnost, že nastanou oba jevy současně,
- $P(A)$ je pravděpodobnost jevu A,
- $P(B)$ je pravděpodobnost jevu B,
- $\min(\cdot)$ označuje minimum z daných hodnot.

2.1.4 Průnik nezávislých jevů

Jsou-li jevy A a B nezávislé, pak pravděpodobnost jejich současného nastání je rovna součinu jejich pravděpodobností.

$$P(A \cap B) = P(A)P(B)$$

kde

- $P(A \cap B)$ je pravděpodobnost současného nastání jevů A a B,
- $P(A)$ je pravděpodobnost jevu A,
- $P(B)$ je pravděpodobnost jevu B.

2.1.5 Sjednocení dvou jevů

Pravděpodobnost, že nastane alespoň jeden z jevů A nebo B, je rovna součtu jejich pravděpodobností minus pravděpodobnost jejich současného nastání.

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

kde

- $P(A \cup B)$ je pravděpodobnost, že nastane alespoň jeden z jevů,
- $P(A)$ je pravděpodobnost jevu A,
- $P(B)$ je pravděpodobnost jevu B,
- $P(A \cap B)$ je pravděpodobnost současného nastání jevů A a B.

2.1.6 Sjednocení neslučitelných jevů

Pokud jsou jevy A a B neslučitelné (nemohou nastat současně), pak pravděpodobnost jejich sjednocení je rovna součtu pravděpodobností těchto jevů.

$$P(A \cup B) = P(A) + P(B)$$

kde

- $P(A \cup B)$ je pravděpodobnost, že nastane jev A nebo B,
- $P(A)$ je pravděpodobnost jevu A,
- $P(B)$ je pravděpodobnost jevu B.

2.1.7 Podmíněná pravděpodobnost

Podmíněná pravděpodobnost jevu A za podmínky, že nastal jev B, je pravděpodobnost současného nastání jevů A a B dělená pravděpodobností B.

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0$$

kde

- $P(A \mid B)$ je podmíněná pravděpodobnost jevu A za podmínky B,
- $P(A \cap B)$ je pravděpodobnost současného nastání jevů A a B,
- $P(B)$ je pravděpodobnost jevu B.

Jevy A a B jsou **nezávislé**, právě když $P(A \mid B) = P(A)$, tj. nastání B nemění pravděpodobnost A.

2.1.8 Věta o úplné pravděpodobnosti

Je-li $\{B_1, B_2, \ldots, B_k\}$ úplný systém jevů (vzájemně se vylučují a jejich sjednocení je jistý jev), pak pro libovolný jev A platí

$$P(A) = \sum_{j=1}^{k} P(A \mid B_j)\, P(B_j)$$

kde

- $P(A)$ je pravděpodobnost jevu A,
- $B_1, \ldots, B_k$ jsou vzájemně se vylučující jevy pokrývající celý prostor,
- $P(A \mid B_j)$ je podmíněná pravděpodobnost A za podmínky B_j,
- $P(B_j)$ je pravděpodobnost jevu B_j.

2.2 Náhodné veličiny

2.2.1 Pravděpodobnostní funkce diskrétní náhodné veličiny

Pravděpodobnost, že diskrétní náhodná veličina X nabývá konkrétní hodnoty x.

$$P(x) = P(X = x)$$

kde

- $P(x)$ je pravděpodobnost hodnoty x,
- $P(X = x)$ je pravděpodobnost, že náhodná veličina X má hodnotu x,
- X je náhodná veličina,
- x je konkrétní hodnota náhodné veličiny.

2.2.2 Distribuční funkce diskrétní náhodné veličiny

Distribuční funkce (kumulativní pravděpodobnost) udává pravděpodobnost, že náhodná veličina X bude menší nebo rovna hodnotě x.

$$F(x) = P(X \leq x) = \sum_{x_j \leq x} P(x_j)$$

kde

- $F(x)$ je distribuční funkce,
- $P(X \leq x)$ je pravděpodobnost, že X je menší nebo rovno x,
- $\sum$ je součet pravděpodobností,
- x_j jsou jednotlivé možné hodnoty náhodné veličiny,
- $P(x_j)$ je pravděpodobnost, že $X = x_j$.

2.2.3 Pravděpodobnost intervalu

Pravděpodobnost, že náhodná veličina X nabývá hodnot v intervalu $(x_1, x_2]$.

$$P(x_1 < X \leq x_2) = \sum_{x_1 < x \leq x_2} P(x) = F(x_2) - F(x_1)$$

kde

- $P(x_1 < X \leq x_2)$ je pravděpodobnost, že X leží mezi x_1 a x_2,
- X je náhodná veličina,
- x_1, x_2 jsou hranice intervalu,
- $\sum$ je součet pravděpodobností všech hodnot v intervalu,
- $P(x)$ je pravděpodobnost, že $X = x$,
- $F(x)$ je distribuční funkce.

2.2.4 Střední hodnota diskrétní náhodné veličiny

Střední hodnota (očekávaná hodnota) diskrétní náhodné veličiny je vážený průměr všech možných hodnot, kde váhami jsou jejich pravděpodobnosti.

$$E(X) = \sum_x x\, P(x)$$

kde

- $E(X)$ je očekávaná hodnota náhodné veličiny X,
- $\sum$ je součet přes všechny možné hodnoty,
- x jsou jednotlivé možné hodnoty náhodné veličiny,
- $P(x) = P(X = x)$ je pravděpodobnost, že X nabude hodnoty x.

2.2.5 Rozptyl diskrétní náhodné veličiny

Rozptyl náhodné veličiny vyjadřuje míru variability hodnot náhodné veličiny kolem její střední hodnoty.

$$D(X) = E(X^2) - [E(X)]^2 = \sum_x x^2 P(x) - \left(\sum_x xP(x)\right)^2$$

kde

- $D(X)$ je rozptyl náhodné veličiny X,
- $E(X)$ je očekávaná hodnota náhodné veličiny,
- $E(X^2)$ je očekávaná hodnota druhé mocniny náhodné veličiny,
- $\sum$ je součet přes všechny možné hodnoty,
- x jsou jednotlivé možné hodnoty náhodné veličiny,
- $P(x) = P(X = x)$ je pravděpodobnost, že X nabude hodnoty x.

2.2.6 Hustota pravděpodobnosti spojité náhodné veličiny

Hustota pravděpodobnosti vyjadřuje rychlost změny distribuční funkce spojité náhodné veličiny.

$$f(x) = F'(x)$$

kde

- $f(x)$ je hustota pravděpodobnosti,
- $F(x)$ je distribuční funkce,
- $F'(x)$ je derivace distribuční funkce podle x,
- x je hodnota náhodné veličiny.

2.2.7 Normalizační podmínka hustoty pravděpodobnosti

Celková pravděpodobnost spojité náhodné veličiny přes všechny možné hodnoty je rovna jedné.

$$\int_{-\infty}^{\infty} f(x)\,dx = 1$$

kde

- $\int$ označuje integrál (součet přes všechny hodnoty),
- $f(x)$ je hustota pravděpodobnosti,
- dx je integrační proměnná,
- $-\infty, \infty$ vyjadřují integraci přes všechny možné hodnoty náhodné veličiny.

2.2.8 Distribuční funkce spojité náhodné veličiny

Distribuční funkce spojité náhodné veličiny udává pravděpodobnost, že náhodná veličina X bude menší nebo rovna hodnotě x.

$$F(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)\,dt$$

kde

- $F(x)$ je distribuční funkce,
- $P(X \leq x)$ je pravděpodobnost, že náhodná veličina X je menší nebo rovna x,
- $\int$ označuje integrál,
- $f(t)$ je hustota pravděpodobnosti,
- t je integrační proměnná,
- $-\infty$ je dolní mez integrace,
- x je horní mez integrace.

2.2.9 Pravděpodobnost intervalu spojité náhodné veličiny

Pravděpodobnost, že spojitá náhodná veličina X nabývá hodnot v intervalu $(x_1, x_2]$.

$$P(x_1 < X \leq x_2) = \int_{x_1}^{x_2} f(x)\,dx = F(x_2) - F(x_1)$$

kde

- $P(x_1 < X \leq x_2)$ je pravděpodobnost, že X leží mezi x_1 a x_2,
- X je náhodná veličina,
- x_1, x_2 jsou hranice intervalu,
- $\int$ označuje integrál,
- $f(x)$ je hustota pravděpodobnosti,
- dx je integrační proměnná,
- $F(x)$ je distribuční funkce.

2.2.10 Střední hodnota spojité náhodné veličiny

Střední hodnota (očekávaná hodnota) spojité náhodné veličiny je vážený průměr všech možných hodnot, kde váhami jsou hodnoty hustoty pravděpodobnosti.

$$E(X) = \int_{-\infty}^{\infty} x f(x)\, dx$$

kde

- $E(X)$ je očekávaná hodnota náhodné veličiny X,
- $\int$ označuje integrál,
- x je hodnota náhodné veličiny,
- $f(x)$ je hustota pravděpodobnosti,
- dx je integrační proměnná,
- $-\infty, \infty$ vyjadřují integraci přes všechny možné hodnoty náhodné veličiny.

2.2.11 Rozptyl spojité náhodné veličiny

Rozptyl spojité náhodné veličiny vyjadřuje variabilitu hodnot náhodné veličiny kolem její střední hodnoty.

$$D(X) = \int_{-\infty}^{\infty} x^2 f(x)\, dx - \left[\int_{-\infty}^{\infty} x f(x)\, dx\right]^2$$

kde

- $D(X)$ je rozptyl náhodné veličiny X,
- $\int$ označuje integrál,
- x je hodnota náhodné veličiny,
- $f(x)$ je hustota pravděpodobnosti,
- dx je integrační proměnná,
- $\int x f(x)\, dx$ je očekávaná hodnota $E(X)$,
- $\int x^2 f(x)\, dx$ je očekávaná hodnota $E(X^2)$.

2.2.12 Směrodatná odchylka náhodné veličiny

Směrodatná odchylka vyjadřuje míru variability hodnot náhodné veličiny kolem její střední hodnoty.

$$\sigma = \sqrt{D(X)}$$

kde

- σ je směrodatná odchylka,
- $D(X)$ je rozptyl náhodné veličiny X,
- $\sqrt{\ }$ označuje druhou odmocninu.

2.3 Vlastnosti střední hodnoty a rozptylu

2.3.1 Vlastnosti střední hodnoty $E(X)$

Pro libovolné náhodné veličiny X, Y a konstantu c platí:

$$E(c) = c, \qquad E(cX) = c\,E(X), \qquad E(X + c) = E(X) + c$$
$$E(X + Y) = E(X) + E(Y)$$

Pro **nezávislé** náhodné veličiny X a Y navíc platí:

$$E(X \cdot Y) = E(X) \cdot E(Y)$$

kde

- $E(\cdot)$ označuje střední hodnotu (očekávanou hodnotu),
- c je konstanta,
- X, Y jsou náhodné veličiny.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`mean(c * X)`	`c1 <- 3`
	`X  <- c(1, 2, 3, 4, 5)`
	`mean(c1 * X)  # = c1 * mean(X)`
	`mean(X + c1)  # = mean(X) + c1`
		Ověření linearity střední hodnoty.

2.3.2 Vlastnosti rozptylu $D(X)$

Pro libovolnou náhodnou veličinu X a konstantu c platí:

$$D(c) = 0, \qquad D(cX) = c^2\,D(X), \qquad D(X + c) = D(X)$$

Pro **nezávislé** náhodné veličiny X a Y navíc platí:

$$D(X + Y) = D(X) + D(Y)$$

kde

- $D(\cdot)$ označuje rozptyl,
- c je konstanta,
- X, Y jsou nezávislé náhodné veličiny.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`var_pop(c * X)`	`var_pop <- function(x) mean((x-mean(x))^2)`
	`var_pop(c1 * X)  # = c1^2 * var_pop(X)`
	`var_pop(X + c1)  # = var_pop(X)`
		Vlastnosti populačního rozptylu (dělí n); `var()` v R dělí $n - 1$.

3 Kombinatorika a Metriky

3.1 Kombinatorika

Mějme množinu n prvků, ze které vybíráme k prvků.

- **Permutace (Pořadí všech n prvků):** Bez opakování: $P(n) = n!$
  S opakováním: $P'_{k_1,\ldots,k_m}(n) = \frac{n!}{k_1! \cdot \ldots \cdot k_m!}$
- **Variace (Výběr k prvků z n, záleží na pořadí):** Bez opakování: $V(k,n) = \frac{n!}{(n-k)!}$
  S opakováním: $V'(k,n) = n^k$
- **Kombinace (Výběr k prvků z n, nezáleží na pořadí):** Bez opakování: $K(k,n) = \binom{n}{k} = \frac{n!}{k!(n-k)!}$
  S opakováním: $K'(k,n) = \binom{n+k-1}{k} = \frac{(n+k-1)!}{k!(n-1)!}$

4 Pravděpodobnostní rozdělení

4.1 Diskrétní rozdělení

4.1.1 Binomické rozdělení Bin(n, p)

Popisuje počet úspěchů v n nezávislých pokusech, kde pravděpodobnost úspěchu v každém pokusu je p.

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \ldots, n$$

$$E(X) = np, \qquad D(X) = np(1-p)$$

kde

- n je počet pokusů,
- p je pravděpodobnost úspěchu v jednom pokusu,
- k je počet úspěchů,
- $\binom{n}{k} = \frac{n!}{k!(n-k)!}$ je kombinační číslo.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`dbinom(k, n, p)`	`dbinom(3, size=10, prob =0.3) # P(X=3)`
	`pbinom(3, size=10, prob =0.3) # P(X<=3)`
	`qbinom(0.9, size=10, prob =0.3)# kvantil`
	`rbinom(100,size=10, prob =0.3) # simulace`
		d/p/q/r = hustota / distribuční fce / kvantilová fce / simulace.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`stats.binom.pmf(k, n, p)`	`from scipy.stats import binom`
	`binom.pmf(3, n=10, p=0.3) # P(X=3)`
	`binom.cdf(3, n=10, p=0.3) # P(X<=3)`
	`binom.ppf(0.9, n=10, p=0.3) # kvantil`
		Binomické rozdělení z knihovny `scipy.stats`.

4.1.2 Poissonovo rozdělení Pois(λ)

Popisuje počet náhodných událostí v daném časovém intervalu nebo oblasti, kdy průměrný počet událostí je λ. Vhodné pro vzácné jevy (velké n, malé p).

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \ldots$$

$$E(X) = D(X) = \lambda$$

kde

- $\lambda > 0$ je průměrný počet událostí (intenzita),
- k je počet událostí,
- $e \approx 2{,}718$ je Eulerovo číslo.

Aproximace: pro velké n a malé p platí $\mathrm{Bin}(n, p) \approx \mathrm{Pois}(\lambda)$, kde $\lambda = np$.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`dpois(k, lambda)`	`dpois(2, lambda=4)  # P(X=2)`
	`ppois(2, lambda=4)  # P(X<=2)`
	`qpois(0.9, lambda=4)  # kvantil`
	`rpois(100, lambda=4)  # simulace`
		d/p/q/r = hustota / distribuční fce / kvantilová fce / simulace.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`stats.poisson.pmf(k, mu)`	`from scipy.stats import poisson`
	`poisson.pmf(2, mu=4)  # P(X=2)`
	`poisson.cdf(2, mu=4)  # P(X<=2)`
		Poissonovo rozdělení z knihovny `scipy.stats`.

4.1.3 Hypergeometrické rozdělení Hyper(N, K, n)

Popisuje počet úspěchů při výběru n prvků **bez návratu** z populace N prvků, z nichž K je úspěšných. Rozdíl od binomického: pravděpodobnost úspěchu se mění s každým tahem.

$$P(X = k) = \frac{\binom{K}{k}\binom{N-K}{n-k}}{\binom{N}{n}}, \quad k = \max(0,\, n + K - N), \ldots, \min(n, K)$$

$$E(X) = \frac{nK}{N}, \qquad D(X) = \frac{nK}{N} \cdot \frac{N-K}{N} \cdot \frac{N-n}{N-1}$$

kde

- N je velikost populace,
- K je počet úspěchů v populaci,
- n je velikost výběru,
- k je počet úspěchů ve výběru.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`dhyper(k, K, N-K, n)`	`# N=50, K=20 uspesnych, n=10 vybranych`
	`dhyper(3, m=20, n=30, k=10) # P(X=3)`
	`phyper(3, m=20, n=30, k=10) # P(X<=3)`
	`# argumenty: m=K, n=N-K, k=vyber n`
		d/p/q/r = hustota / distribuční fce / kvantilová fce / simulace.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`stats.hypergeom.pmf(k, M, n, N)`	`from scipy.stats import hypergeom`
	`hypergeom.pmf(3, M=50, n=20, N=10)`
	`# M=N (populace), n=K (uspesne), N=vyber`
		Hypergeometrické rozdělení z knihovny `scipy.stats`.

4.2 Spojitá rozdělení

4.2.1 Normální rozdělení $N(\mu, \sigma^2)$

Nejdůležitější spojité rozdělení. Hustota pravděpodobnosti má tvar symetrické zvonové křivky kolem střední hodnoty μ.

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}$$

$$E(X) = \mu, \qquad D(X) = \sigma^2$$

kde

- μ je střední hodnota (poloha středu),
- σ^2 je rozptyl ($\sigma > 0$ je směrodatná odchylka),
- $e \approx 2{,}718$ je Eulerovo číslo, $\pi \approx 3{,}14159$.

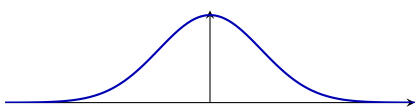

Standardizace

Libovolnou normálně rozdělenou veličinu lze převést na standardní normální $Z \sim N(0,1)$:

$$Z = \frac{X-\mu}{\sigma} \sim N(0,1)$$

Standardní normální rozdělení má $E(Z) = 0$ a $D(Z) = 1$.

Pravidlo 6σ

Oblast $\pm 6\sigma$ kolem střední hodnoty pokrývá prakticky celou distribuci. Pravidlo se využívá v managementu kvality (metodologie *Six Sigma*):

$$P(\mu - 6\sigma \leq X \leq \mu + 6\sigma) \approx 0{,}9999999980$$

Procesy s variabilitou nepřesahující $\pm 6\sigma$ od cílové hodnoty produkují méně než 3,4 závad na milion příležitostí (DPMO).

Implementace v R

Funkce	Příklad použití	Vysvětlení

`dnorm / pnorm / qnorm / rnorm`	`pnorm(185, mean=180, sd=7) # F(185)`
	`qnorm(0.975) # kvantil N(0,1)`
	`rnorm(100, mean=0, sd=1) # simulace`
	`# standardizace (ekvivalentni):`
	`pnorm(185, 180, 7)`
	`pnorm((185-180)/7)`
		d/p/q/r = hustota / distribuční fce / kvantilová fce / simulace.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`stats.norm.cdf(x, loc, scale)`	`from scipy.stats import norm`
	`norm.cdf(185, loc=180, scale=7) # F(185)`
	`norm.ppf(0.975) # kvantil N(0,1)`
	`norm.rvs(size=100) # simulace`
		`loc` $= \mu$, `scale` $= \sigma$.

4.2.2 Rovnoměrné rozdělení $U(a, b)$

Každá hodnota v intervalu $[a, b]$ je stejně pravděpodobná. Hustota pravděpodobnosti je na celém intervalu konstantní.

$$f(x) = \frac{1}{b-a}, \quad x \in [a, b], \qquad f(x) = 0 \text{ jinak}$$

$$E(X) = \frac{a+b}{2}, \qquad D(X) = \frac{(b-a)^2}{12}$$

kde a je dolní mez a b je horní mez intervalu.

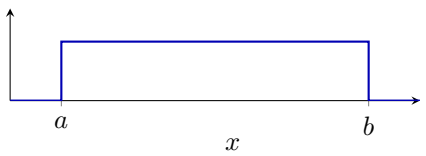

Implementace v R

Funkce	Příklad použití	Vysvětlení

`dunif / punif / qunif / runif`	`dunif(0.5, min=0, max=1) # hustota f(0.5)`
	`punif(0.5, min=0, max=1) # P(X<=0.5)`
	`qunif(0.75, min=0, max=1) # kvantil`
	`runif(100, min=0, max=1) # simulace`
		`min`$= a$, `max`$= b$.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`uniform.cdf(x, loc, scale)`	`from scipy.stats import uniform`
	`# loc=a, scale=b-a`
	`uniform.pdf(0.5, loc=0, scale=1)`
	`uniform.cdf(0.5, loc=0, scale=1) # P(X<=0.5)`
	`uniform.ppf(0.75, loc=0, scale=1) # kvantil`
		`loc`$= a$, `scale`$= b - a$.

4.2.3 Exponenciální rozdělení $\mathrm{Exp}(\lambda)$

Modeluje dobu čekání na první událost Poissonova procesu. Charakteristická vlastnost: **absence paměti** – $P(X > s + t \mid X > s) = P(X > t)$.

$$f(x) = \lambda\, e^{-\lambda x}, \quad x \geq 0$$

$$E(X) = \frac{1}{\lambda}, \qquad D(X) = \frac{1}{\lambda^2}$$

kde $\lambda > 0$ je intenzita (průměrný počet událostí za jednotku času).

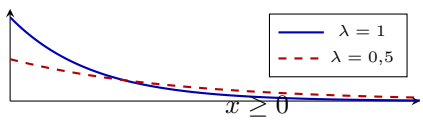

Implementace v R

Funkce	Příklad použití	Vysvětlení

`dexp / pexp / qexp / rexp`	`dexp(1, rate=0.5) # hustota f(1) pro lambda=0.5`
	`pexp(2, rate=0.5) # P(X<=2)`
	`qexp(0.9, rate=0.5) # kvantil`
	`rexp(100, rate=0.5) # simulace`
		`rate=` λ.

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`expon.cdf(x, scale)`	`from scipy.stats import expon`
	`# scale = 1/lambda`
	`expon.pdf(1, scale=2) # hustota pro lambda=0.5`
	`expon.cdf(2, scale=2) # P(X<=2)`
	`expon.ppf(0.9, scale=2) # kvantil`
		`scale=` $1/\lambda$.

4.3 Odvozená rozdělení

4.3.1 Studentovo t-rozdělení $t(\nu)$

Vzniká jako podíl standardní normální veličiny a odmocniny veličiny χ^2 dělené svými stupni volnosti. Klíčové pro testování hypotéz a intervaly spolehlivosti, když **neznáme rozptyl** populace σ^2.

$$E(X) = 0 \ (\nu > 1), \qquad D(X) = \frac{\nu}{\nu - 2} \ (\nu > 2)$$

kde ν jsou stupně volnosti. Pro $\nu \to \infty$ přechází t-rozdělení v $N(0, 1)$.

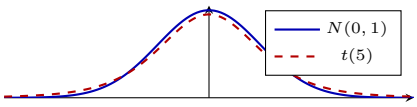

Implementace v R

Funkce	Příklad použití	Vysvětlení

`dt / pt / qt / rt`	`dt(0, df=5) # hustota f(0)`
	`pt(-1.96, df=19) # P(T<=t)`
	`qt(0.975, df=19) # krit. hodnota pro t-test /IS`
	`rt(100, df=10) # simulace`
		`df`$=\nu$ (stupně volnosti).

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`t.pdf / cdf / ppf`	`from scipy.stats import t`
	`t.pdf(0, df=5) # hustota f(0)`
	`t.cdf(-1.96, df=19) # P(T<=t)`
	`t.ppf(0.975, df=19) # krit. hodnota`
	`t.rvs(df=10, size=100) # simulace`
		`df`$=\nu$ (stupně volnosti).

4.3.2 Chí-kvadrát rozdělení $\chi^2(k)$

Vzniká jako součet kvadrátů k nezávislých standardně normálních veličin. Použití: test dobré shody, test nezávislosti v kontingenční tabulce.

$$E(X) = k, \qquad D(X) = 2k$$

kde $k > 0$ jsou stupně volnosti. Rozdělení je pravostranně asymetrické; pro velká k se přibližuje normálnímu.

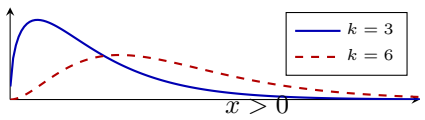

Implementace v R

Funkce	Příklad použití	Vysvětlení

`dchisq / pchisq / qchisq / rchisq`	`dchisq(5, df=3) # hustota f(5)`
	`pchisq(7.81, df=3) # P(X<=7.81)`
	`qchisq(0.95, df=3) # krit. hodnota`
	`rchisq(100, df=3) # simulace`
		`df`= k (stupně volnosti).

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`chi2.pdf / cdf / ppf`	`from scipy.stats import chi2`
	`chi2.pdf(5, df=3) # hustota f(5)`
	`chi2.cdf(7.81, df=3) # P(X<=7.81)`
	`chi2.ppf(0.95, df=3) # krit. hodnota`
	`chi2.rvs(df=3, size=100) # simulace`
		`df`= k (stupně volnosti).

4.3.3 F-rozdělení $F(k_1, k_2)$

Vzniká jako podíl dvou nezávislých veličin χ^2, každé dělené svými stupni volnosti. Použití: ANOVA, F-test celkové platnosti regresního modelu.

$$E(X) = \frac{k_2}{k_2 - 2}\ (k_2 > 2), \qquad D(X) = \frac{2k_2^2(k_1 + k_2 - 2)}{k_1(k_2 - 2)^2(k_2 - 4)}\ (k_2 > 4)$$

kde k_1 jsou stupně volnosti čitatele a k_2 jmenovatele.

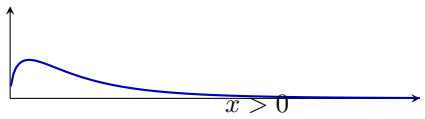

Implementace v R

Funkce	Příklad použití	Vysvětlení

`df / pf / qf / rf`	`df(2, df1=3, df2=10) # hustota f(2)`
	`pf(3.71, df1=3, df2=10) # P(F<=3.71)`
	`qf(0.95, df1=3, df2=10) # krit. hodnota`
	`rf(100, df1=3, df2=10) # simulace`
	`# pozor: df() koliduje s data.frame`
	`# pouzit: stats::df()`
		`df1`= k_1 (čitatel), `df2`= k_2 (jmenovatel).

Implementace v Python

Funkce	Příklad použití	Vysvětlení

`f.pdf / cdf / ppf`	`from scipy.stats import f`
	`f.pdf(2, dfn=3, dfd=10) # hustota f(2)`
	`f.cdf(3.71, dfn=3, dfd=10) # P(F<=3.71)`
	`f.ppf(0.95, dfn=3, dfd=10) # krit. hodnota`
	`f.rvs(dfn=3, dfd=10, size=100) # simulace`
		`dfn`= k_1 (čitatel), `dfd`= k_2 (jmenovatel).

5 Testování hypotéz

5.1 Bodový odhad

Bodový odhad nahrazuje neznámý parametr populace jednou hodnotou vypočtenou z výběru. Výběrový průměr $\bar{x}$ a výběrový rozptyl s^2 jsou **nestranné** odhady (jejich střední hodnota se rovná odhadovanému parametru).

Parametr	**Odhad (vzorec)**	**Implementace v R**
Střední hodnota μ	$\hat{\mu} = \bar{x} = \frac{1}{n}\sum x_i$	`mean(x)`
Rozptyl σ^2	$\hat{\sigma}^2 = s^2 = \frac{\sum(x_i - \bar{x})^2}{n-1}$	`var(x)`
Podíl π	$\hat{p} = x/n$	`sum(x == k) / length(x)`

5.2 Intervaly spolehlivosti a velikost výběru

5.2.1 Interval pro průměr (μ)

Odhadujeme skutečnou střední hodnotu populace μ na základě výběrového průměru $\bar{x}$.

- **Neznámý σ^2 (nebo $n < 30$):** $\bar{x} \pm t_{1-\alpha/2}(n-1) \cdot \frac{s}{\sqrt{n}}$
- **Známý σ^2 (nebo $n \geq 30$):** $\bar{x} \pm z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$

Pro **oboustranný** interval používáme kvantil $1 - \alpha/2$, pro **jednostranný** $1 - \alpha$.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`t.test(x)$conf.int`	`x <- c (163,175,177,165,171,174)` `t.test(x, conf.level = 0.95)$conf.int`	Vrací 95 % IS pro μ (neznámý σ^2).

Ručně (t-rozdělení)	`xbar <- mean(x); s <- sd(x)`
	`n <- length(x); alpha <- 0.05`
	`t_kr <- qt(1 - alpha/2, df = n - 1)`
	`c(xbar - t_kr*s/sqrt(n), xbar + t_kr*s/sqrt(n))`
		Ruční výpočet IS s t-rozdělením.

Ručně (Z, známý σ)	`sigma <- 7`
	`z_kr <- qnorm(1 - alpha/2)`
	`c(xbar - z_kr*sigma/sqrt(n), xbar + z_kr*sigma/sqrt(n))`
		Ruční výpočet IS s normálním rozdělením (velký výběr nebo známý σ).

Implementace v Python

Funkce	Příklad použití	Vysvětlení
Kritická hodnota	`crit = t.ppf(1 - alpha/2, df=n-1)`	Kvantil pro t-interval (neznámé σ). Pro velké n lze nahradit `norm.ppf`.
Mezní chyba	`err = crit * (s / np.sqrt(n))`	Výpočet odchylky; `s` je výběrová směrodatná odchylka.
Meze intervalu	`lower, upper = xbar - err, xbar + err`	Parametr leží v intervalu s pravděpodobností $1 - \alpha$.

5.2.2 Interval pro podíl (π)

Odhadujeme skutečný podíl π z výběrové relativní četnosti $\hat{p} = x/n$. Vždy použijeme normální rozdělení (Z-kvantil).

$$\hat{p} \pm z_{1-\alpha/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Implementace v R

Funkce	Příklad použití	Vysvětlení
`prop.test(x, n)$conf.int`	`prop.test(x=110, n=200, conf.level=0.95)$conf.int`	Wilsonův IS pro proporci (vestavěná funkce).

`Ručně (Waldův IS)`	`x_vol <- 110; n_vol <- 200`
	`p <- x_vol / n_vol`
	`z_kr <- qnorm(0.975)`
	`se <- sqrt(p*(1-p)/n_vol)`
	`c(p - z_kr*se, p + z_kr*se)`
		Waldův IS – jednoduchá normální aproximace.

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`Kritická hodnota`	`z_crit = norm.ppf(1 - alpha / 2)`	Pro podíl se vždy používá normální rozdělení (Z-kvantil).
`Mezní chyba`	`err = z_crit * np.sqrt(p * (1-p) / n)`	Výpočet odchylky pro proporci $\hat{p}$.
`Meze intervalu`	`lower, upper = p - err, p + err`	Parametr leží v intervalu s pravděpodobností $1 - \alpha$.

5.2.3 Potřebná velikost výběru (n)

Minimální rozsah výběru, aby se odhad nemýlil o více než Δ. Výsledek **vždy zaokrouhlit nahoru**.

$$n \geq \left(\frac{z_{1-\alpha/2} \cdot \sigma}{\Delta}\right)^2 \quad \text{(průměr)}, \qquad n \geq \hat{p}(1-\hat{p}) \cdot \left(\frac{z_{1-\alpha/2}}{\Delta}\right)^2 \quad \text{(podíl)}$$

Implementace v R

Funkce	Příklad použití	Vysvětlení

`Minimální n (průměr)`	`alpha <- 0.05; sigma <- 10`
	`delta <- 2  # pozadovana presnost`
	`z_kr <- qnorm(1 - alpha/2)`
	`ceiling((z_kr * sigma / delta)^2)`
		Pro průměr. Δ je cílová přesnost. Výsledek **vždy** zaokrouhli nahoru.

`Minimální n (podíl)`	`p <- 0.5; delta <- 0.05  # +-5 p.b.` `ceiling(p*(1-p)*(z_kr/delta)^2)`	Pro podíl. Používá se pro plánování reprezentativního výzkumu.

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`Minimální n (průměr)`	`n = math.ceil((z_crit * sigma / delta)**2)`	Pro průměr. Δ je cílová přesnost. Výsledek **vždy** zaokrouhli nahoru.
`Minimální n (podíl)`	`n = math.ceil(p*(1-p) * (z_crit/delta)**2)`	Pro podíl.

5.3 Jednovýběrový t-test (střední hodnota)

H$_0$: $\mu = \mu_0$. Testové kritérium má t-rozdělení s $n-1$ stupni volnosti.

$$T = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \sim t(n-1)$$

Typ testu	Alternativa H_1	p-hodnota v R
Levostranný	$\mu < \mu_0$	`pt(T, df=n-1)`
Pravostranný	$\mu > \mu_0$	`1 - pt(T, df=n-1)`
Oboustranný	$\mu \neq \mu_0$	`2*(1 - pt(abs(T), df=n-1))`

Implementace v R

Funkce	Příklad použití	Vysvětlení
`t.test(x, mu=mu0, ...)`	`t.test(x, mu = 25000, alternative = "less")` `# "greater" / "two.sided"`	Automatický t-test z vektoru dat.

`Ručně`	`n <- 49; xbar <- 23500; alpha <- 0.05`
	`mu0 <- 25000; s <- 5500`
	`T <- (xbar - mu0)/(s/sqrt(n))`
	`p_val <- pt(T, df = n - 1)`
	`t_kr  <- qt(alpha, df = n - 1)`
		Ruční výpočet (jednostranný levostranný).

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`stats.ttest_1samp(data, mu0)`	`stats.ttest_1samp(data, popmean=mu0)`	Porovnání průměru vzorku s pevnou hodnotou μ_0.

5.4 Dvouvýběrový t-test (Welchův)

H_0: $\mu_1 = \mu_2$. Welchova aproximace stupňů volnosti (předpokládáme různé rozptyly).

$$T = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$$

Implementace v R

Funkce	Příklad použití	Vysvětlení
`t.test(x1, x2, var.equal=FALSE)`	`t.test(x1, x2, var.equal = FALSE, alternative = "two.sided")`	Welchův test (různé rozptyly).

Ručně (ze souhrnných statistik)	`n1<-38; x1<-5.3875; s1_2<-0.2698`
	`n2<-35; x2<-4.7; s2_2<-0.24`
	`T <- (x1-x2)/sqrt(s1_2/n1+s2_2/n2)`
	`df_w <- (s1_2/n1+s2_2/n2)^2 / ((s1_2/n1)^2/(n1-1)+(s2_2/n2)^2/(n2-1))`
	`p_val <- 2*(1-pt(abs(T), df=df_w))`
		Welch-Satterthwaiteovy stupně volnosti (s_1^2, s_2^2 jsou rozptyly).

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`stats.ttest_ind(A, B)`	`stats.ttest_ind(A, B, equal_var=False)`	Porovnání průměrů dvou nezávislých skupin (Welchův test).

5.5 Párový t-test

H_0: $\mu_d = 0$, kde $d_i = x_{2i} - x_{1i}$ jsou párové rozdíly. Aplikuje jednovýběrový t-test na rozdíly.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`t.test(pred, po, paired=TRUE)`	`t.test(pred, po, paired = TRUE, alternative = "two.sided")`	Porovnání stejné skupiny ve dvou různých situacích (např. před a po zásahu).

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`stats.ttest_rel(po, pred)`	`stats.ttest_rel(po, pred)`	Porovnání stejné skupiny ve dvou různých situacích.

5.6 Test proporce (Z-test)

H$_0$: $\pi = \pi_0$. Testové kritérium:

$$Z = \frac{\hat{p} - \pi_0}{\sqrt{\pi_0(1-\pi_0)/n}} \sim N(0,1)$$

Implementace v R

Funkce	Příklad použití	Vysvětlení
`prop.test(x, n, p=p0, ...)`	`prop.test(x=90, n=150, p=0.5, alternative="two.sided", correct=FALSE)`	Bez Yatesovy korekce odpovídá ručnímu Z-testu.

`Ručně`	`p0 <- 0.5; n <- 150; orel <- 90`
	`phat <- orel/n`
	`Z <- (phat-p0)/sqrt(p0*(1-p0)/n)`
	`z_kr <- qnorm(1 - 0.01/2)`
	`p_val <- 2*(1 - pnorm(abs(Z)))`
		Oboustranný Z-test symetrie mince ($\alpha = 0{,}01$).

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`proportions_ztest`	`from statsmodels.stats.proportion import proportions_ztest`	Z-test proporce. Vrací (Z, p).

5.7 Jednocestná analýza rozptylu (ANOVA)

H$_0$: $\mu_1 = \mu_2 = \cdots = \mu_k$, **H$_1$:** alespoň dva průměry se liší.
Test je vždy **pravostranný**: zamítáme H_0, pokud $F \geq F_{1-\alpha}(k-1, n-k)$.

$$F = \frac{S_m/(k-1)}{S_v/(n-k)} \sim F(k-1, n-k), \quad S_m = \sum_{j=1}^{k} n_j(\bar{x}_j - \bar{x})^2, \quad S_v = \sum_{j=1}^{k}\sum_{i=1}^{n_j}(x_{ij} - \bar{x}_j)^2$$

Implementace v R

Funkce	Příklad použití	Vysvětlení

`aov(y ~ skupina)`	`y <- c(91,81,74,57, 83,72,63,47, 71,69,58,40)`
	`skupina <- factor(rep(c("A","B","C"), each=4))`
	`m <- aov(y ~ skupina)`
	`summary(m)`
		Automatická ANOVA s tabulkou výsledků.

`Skupinové průměry`	`tapply(y, skupina, mean)`	Průměry v každé skupině.
`Kritická hodnota F`	`k <- nlevels(skupina); n <- length(y)` `qf(0.95, df1 = k-1, df2 = n-k)`	Kvantil F-rozdělení pro $\alpha = 0{,}05$.

`Ručně (SS)`	`grand <- mean(y)`
	`SS_m <- sum(tapply(y, skupina, function(g) length(g)*(mean(g)-grand)^2))`
	`SS_v <- sum(tapply(y, skupina, function(g) sum((g-mean(g))^2)))`
	`F_stat <- (SS_m/(k-1))/(SS_v/(n-k))`
		Ruční výpočet součtů čtverců mezi skupinami a uvnitř skupin.

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`stats.f_oneway(A, B, C)`	`stats.f_oneway(A, B, C)`	Testování shody průměrů u tří a více skupin.

5.8 Chí-kvadrát test dobré shody

H_0: výběr odpovídá předpokládanému rozdělení.

$$G = \sum_j \frac{(n_j - e_j)^2}{e_j} \sim \chi^2(k-1), \quad e_j = n \cdot \pi_{0,j}$$

Implementace v R

Funkce	Příklad použití	Vysvětlení

`chisq.test(emp, p=p_teor)`	`emp <- c(A=82, B=38, AB=26, O=69)`
	`p0 <- c(A=0.41,B=0.14,AB=0.07,O=0.38)`
	`chisq.test(emp, p = p0)`
		Automatický test dobré shody. Vektor `p0` musí mít součet 1.

`Ručně`	`teor <- sum(emp) * p0`
	`G <- sum((emp - teor)^2 / teor)`
	`p_val <- 1 - pchisq(G, df= length(emp)-1)`
	`chi_kr <- qchisq(0.99, df= length(emp)-1)`
		Ruční výpočet testové statistiky a p-hodnoty.

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`stats.chisquare(O, f_exp=E)`	`stats.chisquare(O, f_exp=E)`	Test dobré shody. `O` jsou pozorované, `E` očekávané četnosti.

5.9 Chí-kvadrát test nezávislosti

H_0: řádkový a sloupcový znak jsou nezávislé.

$$e_{ij} = \frac{n_{i\bullet}\, n_{\bullet j}}{n}, \qquad G = \sum_{i,j} \frac{(n_{ij} - e_{ij})^2}{e_{ij}} \sim \chi^2\big((r-1)(s-1)\big)$$

Síla závislosti: Cramérovo $V = \sqrt{G/\big(n \cdot (\min(r,s) - 1)\big)} \in [0,1]$.
Interpretace: $<$ 0,1 zanedbatelná · 0,1–0,3 slabá · 0,3–0,5 středně silná · $>$ 0,5 silná.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`chisq.test(tabulka)`	`kt <- matrix(c (1768,807,189,47, 946,1387,746,53, 115,438,288,16), nrow=3, byrow= TRUE)`
	`res <- chisq.test(kt)`
	`res$p.value # p-hodnota`
	`res$expected # teoreticke cetnosti`
		Test nezávislosti z kontingenční tabulky.

`Cramérovo V`	`G <- as.numeric( res$statistic)`
	`n_celk <- sum(kt)`
	`r <- nrow(kt); s_kt <- ncol (kt)`
	`V <- sqrt(G / (n_celk*(min( r,s_kt)-1)))`
	`C <- sqrt(G / (G + n_celk))`
		Síla závislosti: $V \in [0,1]$. Pearsonův C závisí na rozměrech tabulky.

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`stats.chi2_contingency(table)`	`chi2, p, df, exp = stats. chi2_contingency(table)`	Vrací (χ^2, p, df, teoretické četnosti).

6 Analýza závislosti

6.1 Korelační analýza

6.1.1 Pearsonův korelační koeficient

Měří sílu **lineární** závislosti dvou spojitých proměnných.

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \cdot \sum_{i=1}^{n}(y_i - \bar{y})^2}}, \quad r \in [-1, 1]$$

Test H_0: $\rho = 0$: $T = r\sqrt{(n-2)/(1-r^2)} \sim t(n-2)$.
Interpretace $|r|$: $< 0{,}3$ slabá · 0,3–0,7 střední · $> 0{,}7$ silná závislost. Znaménko udává směr.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`cor(x, y, method="pearson")`	`x <- c(1,2,0,5,3,4,2,6,1,3)`
	`y <- c(0,1,0,4,2,3,1,5,0,2)`
	`cor(x, y, method = "pearson")`
		Hodnota korelačního koeficientu $r \in [-1, 1]$.

`cor.test(x, y)`	`cor.test(x, y, method = "pearson")`	Test H_0: $\rho = 0$; vrací p-hodnotu, T a IS pro ρ.

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`stats.pearsonr(x, y)`	`r, p = stats.pearsonr(x, y)`	Vrací korelační koeficient r a p-hodnotu testu H_0: $\rho = 0$.

6.1.2 Spearmanův korelační koeficient

Měří sílu **monotónní** závislosti (neparametrický, odolný vůči odlehlým hodnotám). Počítá se jako Pearsonův koeficient aplikovaný na pořadí hodnot.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`cor(x, y, method="spearman")`	`cor(x, y, method = "spearman")`	Hodnota Spearmanova koeficientu r_s.
`cor.test(x, y, method="spearman")`	`cor.test(x, y, method = "spearman")`	Test H_0: $\rho_s = 0$; vrací p-hodnotu a testovou statistiku.

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`stats.spearmanr(x, y)`	`rho, p = stats.spearmanr(x, y)`	Vrací Spearmanův r_s a p-hodnotu testu $H_0\colon \rho_s = 0$.

6.2 Jednoduchá lineární regrese

6.2.1 Odhad koeficientů (MNČ)

Model: $\hat{y} = b_0 + b_1 x$. Koeficienty minimalizují součet čtverců reziduí $Q = \sum e_i^2$.

$$b_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}, \qquad b_0 = \bar{y} - b_1\bar{x}$$

Implementace v R

Funkce	Příklad použití	Vysvětlení

`lm(y ~ x)`	`m <- lm(cena ~ naklady)`
	`summary(m)  # koef., R^2, testy`
	`coef(m)  # b0 a b1`
	`fitted(m)  # vyrovnane hodnoty`
	`residuals(m)  # rezidua e_i`
		Fituje lineární model; `summary` vrací koeficienty, R^2, t-testy i F-test automaticky.

`Koeficienty ručně`	`x_b <- mean(x); y_b <- mean(y)`
	`b1 <- sum((x-x_b)*(y-y_b)) / sum((x-x_b)^2)`
	`b0 <- y_b - b1 * x_b`
		Ruční výpočet metodou nejmenších čtverců (minimalizace $Q = \sum e_i^2$).

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`stats.linregress(x, y)`	`res = stats.linregress(x, y)`	Vrací `slope` (b_1), `intercept` (b_0), r, p-hodnotu a `stderr`.

6.2.2 Součty čtverců a koeficient determinace R^2

$$S_Y = S_T + S_R, \qquad R^2 = \frac{S_T}{S_Y} \in [0, 1]$$

kde $S_Y = \sum(y_i - \bar{y})^2$ (celkový), $S_T = \sum(\hat{y}_i - \bar{y})^2$ (regresní), $S_R = \sum e_i^2$ (reziduální).

Implementace v R

Funkce	Příklad použití	Vysvětlení

`Součty čtverců a` R^2	`SS_tot <- sum((y - mean(y))^2)`
	`SS_reg <- sum((fitted(m)-mean(y))^2)`
	`SS_res <- sum(residuals(m)^2)`
	`R2 <- SS_reg / SS_tot`
	`summary(m)$r.squared  # zkratka`
		$S_Y = S_T + S_R$; $R^2 = S_T/S_Y$ – podíl rozptylu Y vysvětlený modelem.

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`r_squared`	`r_squared = res.rvalue**2`	R^2 jako čtverec korelačního koeficientu (z `stats.linregress`).

6.2.3 t-test a F-test platnosti modelu

t-test pro b_1: $H_0\colon \beta_1 = 0$; $T = b_1/s_{b_1} \sim t(n-2)$.
F-test modelu: $H_0\colon \beta_1 = 0$; $F = S_T/\big(S_R/(n-2)\big) \sim F(1; n-2)$.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`t-test pro` b_1	`n <- length(x)`
	`se_b1 <- sqrt(SS_res/(n-2) /`
	`sum((x-mean(x))^2) )`
	`t_stat <- b1 / se_b1`
	`qt(0.975, df=n-2)  # krit. hodnota`
	`2*(1-pt(abs(t_stat), df=n-2)) # p-val`
		$H_0\colon \beta_1 = 0$; zamítáme při $\lvert T\rvert \geq t_{1-\alpha/2}(n-2)$.

`F-test modelu`	`F_stat <- (SS_reg/1)/(SS_res/(n-2))` `qf(0.95, df1=1, df2=n-2)`	Pro jednoduchou regresi ekvivalentní t-testu. Výsledek v `summary(m)`.

Implementace v Python

Funkce	Příklad použití	Vysvětlení
p-hodnota pro b_1	`res.pvalue`	p-hodnota testu H_0: $\beta_1 = 0$ (z `stats.linregress`).

6.2.4 Predikce

Bodová predikce střední hodnoty Y pro novou hodnotu x^*: $\hat{y}^* = b_0 + b_1 x^*$.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`predict(m, newdata=...)`	`predict(m, newdata=data.frame(naklady=80))` `predict(m, newdata=data.frame(naklady=80), interval="confidence")`	Bodová predikce i IS pro střední hodnotu Y při nové hodnotě X.

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`Predikce`	`y_hat = res.intercept + res.slope * x_new`	Bodová predikce (z `stats.linregress`).

7 Časové řady

7.1 Základní charakteristiky

7.1.1 Absolutní přírůstky a tempa růstu

$$\begin{aligned} \text{1. diference:} \quad & \Delta y_t = y_t - y_{t-1} \\ \text{Tempo růstu:} \quad & k_t = y_t / y_{t-1} \\ \text{Průměrné tempo:} \quad & \bar{k} = \sqrt[n-1]{y_n / y_1} \end{aligned}$$

Implementace v R

Funkce	Příklad použití	Vysvětlení

`diff(y)`	`y <- c (5274,5288,5297,5318,5338,5356)`
	`diff(y) # 1. diference`
	`diff(diff(y)) # 2. diference`
		Absolutní přírůstky první a druhé řádu.

`Tempo růstu`	`n <- length(y)`
	`tempo <- y[-1] / y[-n]`
	`prum_tempo <- (y[n]/y[1]) ^(1/(n-1))`
		Mezičasové indexy k_t a průměrné tempo růstu (geometrický průměr).

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`np.diff(y)`	`np.diff(y)`	Absolutní přírůstky (1. diference).
`Tempo růstu`	`y[1:] / y[:-1]`	Mezičasové indexy k_t pro NumPy pole `y`.

7.1.2 Chronologický průměr

Pro okamžikovou časovou řadu (stejně dlouhé intervaly):

$$\bar{y} = \frac{\frac{1}{2}y_1 + y_2 + \cdots + y_{n-1} + \frac{1}{2}y_n}{n-1}$$

Implementace v R

Funkce	Příklad použití	Vysvětlení
`Chronologický průměr`	`n <- length(y)` `(y[1]/2 + sum(y[2:(n-1)]) + y[n]/2) / (n-1)`	Průměr okamžikové časové řady; krajní hodnoty mají váhu $\frac{1}{2}$.

Implementace v Python

Funkce	Příklad použití	Vysvětlení
Chronologický průměr	`(y[0]/2 + np.sum(y[1:-1]) + y[-1]/2) / (len(y)-1)`	Průměr okamžikové časové řady.

7.2 Klouzavé průměry

7.2.1 Prostý klouzavý průměr (liché m)

Symetrické okno šířky $m = 2p + 1$: $\tilde{y}_t = \frac{1}{m} \sum_{j=-p}^{p} y_{t+j}$. Odstraňuje sezónnost délky $\leq m$.

Implementace v R

Funkce	Příklad použití	Vysvětlení
`filter(y, rep(1/m, m))`	`m <- 5  # liche m -- prosty KP` `kp <- filter(y, rep(1/m,m), sides=2)`	Prostý klouzavý průměr; `sides=2` = symetrické okno.

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`np.convolve`	`np.convolve(y, np.ones(m)/m, mode='valid')`	Prostý klouzavý průměr (ztratí krajní hodnoty).

7.2.2 Centrovaný klouzavý průměr (sudé m)

Pro sudé m: centrovaný KP = průměr dvou po sobě jdoucích prostých KP délky m. Používá se pro čtvrtletní nebo měsíční data.

Implementace v R

Funkce	Příklad použití	Vysvětlení

Centrovaný KP (sudé m)	`m <- 4  # sude m -- centrovany KP`
	`kp_l <- filter(y, rep(1/m,m), sides=1)`
	`kp_c <- (kp_l + c(NA, kp_l[-length(kp_l)])) / 2`
		`sides=1`: průměr posledních m hodnot. Centrovaný KP = průměr dvou sousedních prostých KP.

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`pd.Series.rolling`	`pd.Series(y).rolling(m).mean()`	Klouzavý průměr délky m (pandas).

7.3 Trend a sezónnost – regresní přístup

7.3.1 Dummy proměnné a model

Model: $y_t = \beta_0 + \beta_1 t + \gamma_1 D_1 + \gamma_2 D_2 + \gamma_3 D_3 + \varepsilon_t$ (sezónnost délky 4; D_j jsou dummy proměnné; 4. čtvrtletí je referenční kategorie).

Implementace v R

Funkce	Příklad použití	Vysvětlení

`Dummy proměnné`	`t <- 1:length(y)`
	`Q2 <- as.integer(t %% 4 == 2)`
	`Q3 <- as.integer(t %% 4 == 3)`
	`Q4 <- as.integer(t %% 4 == 0)`
	`# Q1 je referencni (t %% 4 == 1)`
		Vždy o jednu méně dummy než sezón – jinak hrozí multikolinearita.

`lm() s trendem a sezónností`	`m <- lm(y ~ t + Q2 + Q3 + Q4)`
	`summary(m)`
	`fitted(m)  # vyrovnane hodnoty`
		Odhaduje lineární trend a sezónní odchylky; $\hat{\gamma}_j$ = odchylka j-tého čtvrtletí od referenčního.

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`pd.get_dummies`	`pd.get_dummies(df['quarter'], drop_first=True)`	Automatické dummy proměnné z kategorického sloupce (pandas).

7.3.2 Predikce na budoucí období

Sestavíme `data.frame` s t a dummy proměnnými pro každé nové pozorování.

Implementace v R

Funkce	Příklad použití	Vysvětlení

`predict(m, newdata=...)`	`t_n <- 21:24`
	`nd <- data.frame(`
	`  t  = t_n,`
	`  Q2 = as.integer(t_n %% 4 == 2),`
	`  Q3 = as.integer(t_n %% 4 == 3),`
	`  Q4 = as.integer(t_n %% 4 == 0))`
	`predict(m, newdata = nd)`
		Predikce na budoucí kvartály.

Implementace v Python

Funkce	Příklad použití	Vysvětlení
`model.predict(X_new)`	`model.predict(X_new)`	Predikce na nová data (scikit-learn nebo statsmodels).

8 Příloha: Utility funkce v Pythonu

8.1 Užitečné knihovny a základy

Funkce	Příklad použití	Vysvětlení
`import numpy as np`	`np.array([...])`	Matice, vektory a rychlé matematické operace.
`import pandas as pd`	`pd.DataFrame(matice)`	Analýza tabulek a práce s CSV.
`import matplotlib.pyplot as plt`	`plt.hist(data)`	Tvorba grafů a vizualizace dat.
`math.comb(n, k)`	`math.comb(10, 3)`	Kombinační číslo (výběr k z n).
`List Comprehension`	`[x**2 for x in range(5)]`	Dynamické generování pole pomocí cyklu.

8.2 Práce s poli (Standardní Python)

Funkce	Příklad použití	Vysvětlení
List Comprehension	`[x**2 for x in range(5)]`	Dynamické generování pole pomocí cyklu.
`x[start:stop:krok]`	`pole[1:10:2]`	Výřez (stop je exkluzivní). `[::-1]` pro otočení.
`x.copy()` vs `deepcopy`	`a = b.copy()`	`copy` je plytká, `deepcopy` kopíruje i vnořená pole.
`x.append(v)`	`data.append(10)`	Přidání jednoho prvku na konec pole.
`x.extend(a)`	`data.extend([1,2,3])`	Přidání více prvků na konec pole.

8.3 Základní Python (Built-in & Math)

Funkce	Příklad použití	Vysvětlení
`help(funkce)`	`help(print)`	Dokumentace pro zadanou funkci.
`range(start, stop)`	`list(range(0, 5))`	Vygeneruje sekvenci `[0, 1, 2, 3, 4]`.
`math.log(x, b)`	`math.log(8, 2)`	Logaritmus čísla x o základu b.
`math.sqrt(x)`	`math.sqrt(16)`	Druhá odmocnina čísla.
`math.ceil / floor`	`math.ceil(2.1)`	Zaokrouhlení nahoru (3) / dolů (2).
`math.trunc(x)`	`math.trunc(2.9)`	Odříznutí desetinné části (2).
`math.comb(n, k)`	`math.comb(10, 3)`	Kombinační číslo (počet kombinací k prvků z n).
`def function(...):`	`def funkce(x, y, z):`	Definice vlastní funkce s parametry.

8.4 Statistika a Matice (Knihovna NumPy a jiné)

Funkce	Příklad použití	Vysvětlení
`np.sum(x)`	`np.sum(data, axis=0)`	Součet všech prvků v poli (nebo podél zvolené osy).
`np.mean(x)`	`np.mean(data)`	Průměr všech prvků v poli.
`np.prod(x)`	`np.prod(data)`	Součin všech prvků v poli.
`np.sqrt(x)`	`np.sqrt(data)`	Druhá odmocnina z každého prvku v poli.
`np.random.rand(n)`	`np.random.rand(100)`	Generování pole n náhodných čísel z rovnoměrného rozdělení na $[0, 1)$.
`np.random.uniform(a, b, n)`	`np.random.uniform(10, 50, 100)`	Generuje n náhodných **desetinných** čísel v rozsahu $[a, b)$.
`np.quantile(x, q)`	`np.quantile(x, 0.75, method='midpoint')`	Výpočet kvantilu ($q \in [0, 1]$).
`Modus`	`statistics.multimode(data)`	`Vrací modus z pole (i více prvků)`
`np.log10(x)`	`np.log10(data)`	Dekadický logaritmus (základ 10). Často se používá pro normalizaci dat.
`np.linalg.norm(x, p)`	`np.linalg.norm(x, ord=2)`	Výpočet L^1, L^2 nebo L^∞ (`np.inf`) normy.
`np.insert / np.delete`	`np.insert(A, 1, [..], axis=0)`	Vloží/Smaže řádek (`axis=0`) nebo sloupec (`axis=1`).

Funkce	Příklad použití	Vysvětlení
`stats.gmean(x)`	`stats.gmean(x)`	Geometrický průměr (knihovna Scipy).
`stats.hmean(x)`	`stats.hmean(x, weights =[...])`	Harmonický průměr (knihovna Scipy).
`np.var(x, ddof=0)`	`np.var(data, ddof=0)`	**Klasický rozptyl** s_x^2 (děleno n).
`np.var(x, ddof=1)`	`np.var(data, ddof=1)`	**Výběrový rozptyl** S^2 (děleno $n-1$).
`np.std(x, ddof=0)`	`np.std(data, ddof=0)`	Klasická směrodatná odchylka s_x.
`np.std(x, ddof=1)`	`np.std(data, ddof=1)`	Výběrová směrodatná odchylka S.
`np.ptp(x)`	`np.ptp(data)`	**Variační rozpětí** $R = x_{max} - x_{min}$.
`v_x = std / mean`	`np.std(x) / np.mean(x)`	**Variační koeficient** v_x (relativní variabilita).
`np.where(cond, x, y)`	`np.where(df['am'] == 0, 'aut', 'man')`	**Podmíněný sloupec**: Pokud platí `cond`, vlož `x`, jinak `y` (jako IF v Excelu).

8.5 Pandas: Analýza dat

Funkce	Příklad použití	Vysvětlení
`pd.read_csv(file)`	`pd.read_csv('data.csv')`	Načte data z CSV souboru a vytvoří DataFrame.
`df.describe()`	`df.describe()`	Souhrnné statistiky (průměr, std, kvartily, atd.).
`df[columns]`	`df[["A", "B", "C"]]`	Výběr určitých sloupců.
`Filtrování`	`df[df['Věk'] >= 18]`	Vybere pouze řádky splňující danou podmínku.
`df['A'].isin([list])`	`df[df['mesto'].isin(['Praha', 'Brno'])]`	Vybere řádky, kde hodnota sloupce odpovídá prvkům v seznamu.
`df.loc` vs `df.iloc`	`df.loc[0, 'Sloupec']`	Výběr dat podle **názvů** (`loc`) vs. **pozice** (`iloc`).
`df.isna().sum()`	`df.isna().sum()`	Počet chybějících (null) hodnot v tabulce.
`df.value_counts()`	`df['A'].value_counts()`	Tabulka četností pro kategorická data.
`df.groupby('A')`	`df.groupby('A').mean()`	Výpočet statistik podle kategorií ve sloupci 'A'.
`df.cumsum()`	`df['cetnost'].cumsum()`	**Kumulativní součet**: Pro výpočet kumulativních absolutních/relativních četností.
`pd.crosstab()`	`pd.crosstab(df['A'], df['B'])`	Kontingenční tabulka četností dvou kategorií.
`pd.pivot_table()`	`df.pivot_table(values='C', \dots)`	Univerzální pivotní tabulka.
`df['A'].between(a, b)`	`df[df['mzda'].between(30000, 50000)]`	Filtrování hodnot v uzavřeném intervalu [a, b].

8.6 Matplotlib a Seaborn: Vizualizace

Funkce	Příklad použití	Vysvětlení
`df.boxplot()`	`df.boxplot(column='Y', by='X')`	**Boxplot (Pandas)**: Rozdělení dat do kvartilů dle skupiny.
`plt.hist(x)`	`plt.hist(data, bins=15)`	**Histogram**: Rozdělení četností. `bins` určuje intervaly.
`plt.scatter(x, y)`	`plt.scatter(x, y, alpha=0.5)`	**Bodový graf**: Závislost dvou proměnných.
`plt.title(s)`	`plt.title("Název", fontsize=16)`	Nastaví hlavní nadpis grafu.
`plt.xlabel / ylabel`	`plt.xlabel("Čas [s]")`	Nastaví popisky os x a y.
`plt.legend()`	`plt.legend(loc='upper right')`	Zobrazí legendu (nutný parametr `label` u dat).
`plt.savefig()`	`plt.savefig("graf.pdf")`	Uloží graf na disk.

8.7 Náhodné veličiny a rozdělení

`Importy:`

```
from scipy.stats import norm, binom, poisson, hypergeom, t, chi2, f,
    uniform, expon
```

Normální rozdělení (`norm`)

Spojité rozdělení pro modelování např. času, délky či chyby měření.
Parametry: `x` = zkoumaná hodnota (hranice), `mu` (`loc`) = střední hodnota, `sigma` (`scale`) = směrodatná odchylka, `q` = zadaná pravděpodobnost (pro hledání kvantilu).

Funkce	Příklad použití	Vysvětlení
`norm.cdf(x, mu, sigma)`	`norm.cdf(16, loc=20, scale=4)`	`MÉNĚ NEŽ`: Šance, že hodnota bude maximálně x.
`norm.sf(x, mu, sigma)`	`norm.sf(20, loc=20, scale=4)`	`VÍCE NEŽ`: Ekvivalent `1 - cdf`. Šance, že hodnota překročí x.
`norm.cdf(b) - norm.cdf(a)`	`norm.cdf(28, 20, 4) - norm.cdf(12, 20, 4)`	`MEZI`: Šance, že se hodnota trefí do intervalu (a, b).
`norm.ppf(q, mu, sigma)`	`norm.ppf(0.4, loc=20, scale=4)`	`Hledání kvantilu`: Najde hodnotu x, pro kterou platí $P(X < x) = q$.

Binomické rozdělení (`binom`)

Diskrétní rozdělení. Počet úspěchů v pevně daném počtu nezávislých pokusů.
Aproximace: Pokud je počet pokusů $n \geq 30$ a pravděpodobnost úspěchu $p \leq 0.05$, blíží se Poissonovu rozdělení.
Parametry: `k` = zkoumaný počet úspěchů, `n` = celkový počet pokusů, `p` = pravděpodobnost úspěchu.

Funkce	Příklad použití	Vysvětlení
`binom.pmf(k, n, p)`	`binom.pmf(4, n=10, p=1/6)`	`Pravděpodobnost PŘESNĚ`: Šance, že úspěch nastane přesně k-krát.
`binom.cdf(k, n, p)`	`binom.cdf(2, n=10, p=1/6)`	`Pravděpodobnost NEJVÝŠE`: Šance, že úspěchů bude 0 až k (včetně).
`1 - binom.cdf(k, n, p)`	`1 - binom.cdf(2, n=10, p=1/6)`	`Pravděpodobnost VÍCE NEŽ`: Šance, že úspěchů bude striktně více než k.

Poissonovo rozdělení (`poisson`)

Diskrétní rozdělení. Počet výskytů události za jednotku času nebo prostoru, když známe průměr.
Parametry: `k` = zkoumaný počet událostí, `mu` = průměrný počet událostí (λ).

Funkce	Příklad použití	Vysvětlení
`poisson.pmf(k, mu)`	`poisson.pmf(2, mu=0.4)`	`Pravděpodobnost PŘESNĚ`: Šance, že nastanou přesně k události při průměru μ.
`poisson.cdf(k, mu)`	`poisson.cdf(2, mu=0.4)`	`Pravděpodobnost NEJVÝŠE`: Šance, že událostí bude 0 až k (včetně).
`1 - poisson.cdf(k, mu)`	`1 - poisson.cdf(2, mu=0.4)`	`Pravděpodobnost VÍCE NEŽ`: Šance na více než k událostí.

Hypergeometrické rozdělení (`hypergeom`)

Diskrétní rozdělení. Výběr **bez vracení** z konečné populace (např. zmetky v zásilce).
Aproximace: Pokud $N/M \leq 0.05$, výběr bez vracení se chová téměř jako výběr s vracením (Binomické).
Parametry: `k` = hledané prvky ve výběru, `M` = populace, `n` = hledané prvky v populaci, `N` = velikost výběru.

Funkce	Příklad použití	Vysvětlení
`hypergeom.pmf(k, M, n, N)`	`hypergeom.pmf(0, 200, 10, 5)`	`Pravděpodobnost PŘESNĚ`: Šance na k zmetků ve výběru N z M, kde je celkem n zmetků.

Studentovo t-rozdělení (`t`)

Spojité rozdělení. Používá se pro konstrukci intervalů spolehlivosti a testování (neznáme-li rozptyl populace).
Parametry: `df` = stupně volnosti (ν), `q` = hladina pravděpodobnosti.

Funkce	Příklad použití	Vysvětlení

`t.pdf / cdf / ppf / rvs`	`t.pdf(0, df=5) # hustota f(0)`
	`t.cdf(-1.96, df=19) # P(T<=t)`
	`t.ppf(1 - 0.05/2, df=19) # krit. hodnota`
	`t.rvs(df=10, size=100) # simulace`
		`df`$=\nu$ (stupně volnosti).

Chí-kvadrát rozdělení (`chi2`)

Součet kvadrátů k standardních normálních veličin.
Parametry: `df` $= k =$ stupně volnosti.

Funkce	Příklad použití	Vysvětlení

`chi2.pdf / cdf / ppf / rvs`	`chi2.pdf(5, df=3) # hustota f(5)`
	`chi2.cdf(7.81, df=3) # P(X<=7.81)`
	`chi2.ppf(0.95, df=3) # krit. hodnota`
	`chi2.rvs(df=3, size=100) # simulace`
		`df`= k (stupně volnosti).

F-rozdělení (`f`)

Podíl dvou veličin chi-kvadrát dělených svými stupni volnosti.
Parametry: `dfn` $= k_1$ (čitatel), `dfd` $= k_2$ (jmenovatel).

Funkce	Příklad použití	Vysvětlení

`f.pdf / cdf / ppf / rvs`	`f.pdf(2, dfn=3, dfd=10) # hustota f(2)`
	`f.cdf(3.71, dfn=3, dfd=10) # P(F<=3.71)`
	`f.ppf(0.95, dfn=3, dfd=10) # krit. hodnota`
	`f.rvs(dfn=3, dfd=10, size=100) # simulace`
		`dfn`= k_1 (čitatel), `dfd`= k_2 (jmenovatel).

9 Příloha: Utility funkce v R

9.1 Náhodné veličiny a rozdělení

`dxxx` = hustota pravděpodobnosti, `pxxx` = distribuční funkce $F(x)$, `qxxx` = kvantil, `rxxx` = náhodné číslo.

Normální rozdělení (`norm`)

Spojité rozdělení pro modelování např. výšky, chyby měření či doby čekání.
Parametry: `mean` (μ) = střední hodnota, `sd` (σ) = směrodatná odchylka.

Funkce	Příklad použití	Vysvětlení
`pnorm(x, mean, sd)`	`pnorm(16, mean=20, sd=4)`	`MÉNĚ NEŽ`: $P(X \leq x)$.
`1 - pnorm(x, mean, sd)`	`1 - pnorm(20, mean=20, sd =4)`	`VÍCE NEŽ`: $P(X > x)$.
`pnorm(b,m,s) - pnorm(a,m,s)`	`pnorm(28,20,4) - pnorm (12,20,4)`	`MEZI`: $P(a < X \leq b)$.
`qnorm(q, mean, sd)`	`qnorm(0.975, mean=0, sd=1)`	Kvantil: najde x pro $P(X \leq x) = q$.

Binomické rozdělení (`binom`)

Diskrétní rozdělení. Počet úspěchů v pevně daném počtu nezávislých pokusů.
Aproximace: Pokud je počet pokusů $n \geq 30$ a pravděpodobnost úspěchu $p \leq 0{,}05$, blíží se Poissonovu rozdělení ($\lambda = np$).
Parametry: `size` (n) = celkový počet pokusů, `prob` (p) = pravděpodobnost úspěchu.

Funkce	Příklad použití	Vysvětlení
`dbinom(k, size, prob)`	`dbinom(4, size=10, prob =1/6)`	`PŘESNĚ`: $P(X = k)$.
`pbinom(k, size, prob)`	`pbinom(2, size=10, prob =1/6)`	`NEJVÝŠE`: $P(X \leq k)$.
`1 - pbinom(k, size, prob)`	`1 - pbinom(2, size=10, prob =1/6)`	`VÍCE NEŽ`: $P(X > k)$.

Poissonovo rozdělení (`pois`)

Diskrétní rozdělení. Počet výskytů události za jednotku času nebo prostoru, když známe průměr.
Parametry: `lambda` (λ) = průměrný počet událostí za interval.

Funkce	Příklad použití	Vysvětlení
`dpois(k, lambda)`	`dpois(2, lambda=0.4)`	PŘESNĚ: $P(X = k)$.
`ppois(k, lambda)`	`ppois(2, lambda=0.4)`	NEJVÝŠE: $P(X \leq k)$.
`1 - ppois(k, lambda)`	`1 - ppois(2, lambda=0.4)`	VÍCE NEŽ: $P(X > k)$.

Hypergeometrické rozdělení (`hyper`)

Diskrétní rozdělení. Výběr **bez vracení** z konečné populace (např. zmetky v zásilce).
Aproximace: Pokud $\frac{k}{m+n} \leq 0{,}05$, výběr bez vracení se chová téměř jako výběr s vracením (Binomické).
Parametry: `m` = počet hledaných prvků v populaci, `n` = počet ostatních prvků v populaci, `k` = velikost výběru.

Funkce	Příklad použití	Vysvětlení
`dhyper(x, m, n, k)`	`dhyper(0, m=10, n=190, k=5)`	PŘESNĚ: $P(X = x)$, zde: 0 zmetků z populace 200 (10 zmetků), výběr 5.
`phyper(x, m, n, k)`	`phyper(2, m=10, n=190, k=5)`	NEJVÝŠE: $P(X \leq x)$.

Studentovo t-rozdělení (`t`)

Spojité rozdělení. Používá se pro intervaly spolehlivosti a testování, pokud neznáme rozptyl populace.
Parametry: `df` = stupně volnosti (ν).

Funkce	Příklad použití	Vysvětlení

`dt / pt / qt / rt`	`dt(0, df=5) # hustota f(0)`
	`pt(-1.96, df=19) # P(T <=t)`
	`qt(0.975, df=19) # krit. hodnota pro t-test /IS`
	`rt(100, df=10) # simulace`
		d/p/q/r = hustota / distribuční fce / kvantilová fce / simulace.

Chí-kvadrát rozdělení (`chisq`)

Součet kvadrátů k standardních normálních veličin.
Parametry: `df` = k = stupně volnosti.

Funkce	Příklad použití	Vysvětlení

`dchisq / pchisq / qchisq / rchisq`	`dchisq(5, df=3) # hustota f(5)`
	`pchisq(7.81, df=3) # P(X<=7.81)`
	`qchisq(0.95, df=3) # krit. hodnota`
	`rchisq(100, df=3) # simulace`
		d/p/q/r = hustota / distribuční fce / kvantilová fce / simulace.

F-rozdělení (`f`)

Podíl dvou veličin chi-kvadrát dělených svými stupni volnosti.
Parametry: `df1` $= k_1$ (čitatel), `df2` $= k_2$ (jmenovatel).

Funkce	Příklad použití	Vysvětlení

`df / pf / qf / rf`	`df(2, df1=3, df2=10) # hustota f(2)`
	`pf(3.71, df1=3, df2=10) # P(F<=3.71)`
	`qf(0.95, df1=3, df2=10) # krit. hodnota`
	`rf(100, df1=3, df2=10) # simulace`
	`# pozor: df() koliduje s data.frame`
	`# pouzit: stats::df()`
		d/p/q/r = hustota / distribuční fce / kvantilová fce / simulace.

9.2 Práce s daty v R

Datové typy a konverze

Funkce	Příklad použití	Vysvětlení

`class(x)`	`class(3.14)  # "numeric"`
	`class(TRUE)  # "logical"`
	`class("ahoj")  # "character"`
		Vrátí datový typ objektu.

`is.numeric / is.character ...`	`is.numeric(3.14)  # TRUE`
	`is.integer(3L)  # TRUE`
	`is.logical(FALSE)  # TRUE`
		Ověří datový typ; vrací `TRUE/FALSE`.

`as.numeric(x)`	`as.numeric("3.14")  # 3.14`
	`as.integer(3.7)  # 3`
	`as.character(42)  # "42"`
	`as.logical(0)  # FALSE`
		Konverze na jiný typ.

`is.na(x)`	`is.na(NA)  # TRUE`
	`is.na(NaN)  # TRUE`
	`is.na(Inf)  # FALSE`
	`colSums(is.na(df)) # NA po sl.`
		Detekce chybějící hodnoty (`NA/NaN`).

Vektory

Funkce	Příklad použití	Vysvětlení

`c(...)`	`c(1, 2, 3)`
	`c("a", "b")`
	`c(x, y)  # spojen vektor`
		Vytvoří vektor nebo spojí vektory.

`seq(from, to, by)`	`1:10` `seq(2, 10, by = 2) # 2,4,6,8,10`	Vytvoří sekvenci čísel.

`x[i]`	`x[1]  # prvn prvek`
	`x[1:3]  # prvky 1 3`
	`x[-2]  # v e krom 2.`
	`x[x > 5]  # podm n n v b r`
		Indexování vektoru.

`length(x) /` `rev(x)`	`length(c(1,2,3))  # 3` `rev(c(1,2,3))  # 3 2 1`	Délka vektoru a obrácení pořadí.
`names(x)`	`names(x) <- c("a","b","c")` `x["a"]  # v b r dle jm na`	Pojmenování prvků vektoru.

Data frames

Funkce	Příklad použití	Vysvětlení

`str(df) / summary(df)`	`str(mtcars)`
	`summary(mtcars)`
	`dim(mtcars)  # c(32, 11)`
		Struktura, přehled a rozměry tabulky.

`head(df, n) / tail(df, n)`	`head(mtcars)  # prvn ch 6`
	`head(mtcars, 10)  # prvn ch 10`
	`tail(mtcars)  # posledn ch 6`
		Náhled na prvních / posledních `n` řádků.

`df[r, c] / df$col`	`df[2, 3]  # jeden prvek`
	`df[1, ]  # 1. dek`
	`df[, 2]  # 2. sloupec`
	`df$mpg  # sloupec mpg`
	`df[df$mpg > 20, ]  # podm n n v b r`
		Indexování data.frameu.

`colSums / colMeans`	`colSums(df)`
	`colMeans(df, na.rm = TRUE)`
	`apply(df, 2, mean, na.rm = TRUE)`
		Součet / průměr každého sloupce.

`cbind / rbind`	`cbind(df, novy = c(...)) # sloupec`
	`rbind(df, c(...))  # dek`
	`df[-1, ]  # odebr n 1. dku`
	`df[, -2]  # odebr n 2. sloupce`
		Přidání nebo odebrání řádků / sloupců.

Import a export dat

Funkce	Příklad použití	Vysvětlení
`read.table()`	`read.table("data.csv",` `  sep = ";", header = TRUE)`	Načte textový soubor do data.frameu.

`read.csv()`	`read.csv("data.csv")`
	`read.csv("data.csv", sep =`
	`  ",")`
		Zkratka pro CSV soubory.

`write.table()`	`write.table(mtcars,`
	`  file = "out.csv", sep =`
	`  ";",`
	`  row.names = FALSE)`
		Uloží data.frame do textového souboru.

`getwd() / setwd()`	`getwd()` `setwd("C:/Users/.../data")`	Zjistí nebo nastaví pracovní složku.

Četnosti a diskretizace

Funkce	Příklad použití	Vysvětlení
`table(x)`	`ni <- table(data$kraj)` `pi <- prop.table(ni)`	Absolutní a relativní četnosti.
`cumsum(x)`	`Ni <- cumsum(ni)` `Pi <- cumsum(pi)`	Kumulativní (absolutní / relativní) četnosti.

`cut(x, breaks)`	`cut(x,`
	`  breaks = seq(0, 20, by =`
	`  2),`
	`  include.lowest = TRUE)`
		Diskretizuje spojitou proměnnou do intervalů.

Balíček dplyr

Funkce	Příkl
`filter()`	`mtcar` `mtcar`
`select()`	`mtcar` `  hp`
`mutate()`	`mtcar` `  pw`

`summarise()`	`mtcar`
	`  pr`
	`  od`

`group_by()`	`mtcar`
	`  gr`
	`  su`

`count()`	`mtcar`
	`data`
	`  ar`

`arrange()`	`mtcar`
	`mtcar`
	`  )`

`pull()`	`mtcar` `  fi`

Roura (`|>` nebo `%>%`) předává výsledek vlevo jako první argument funkce vpravo.